

Исследование стартапов и инвестиционной активности

Введение

Цель проекта:

Проанализировать рынок финансирования стартапов для выявления наиболее перспективных рыночных сегментов и типов финансирования с целью формирования инвестиционной стратегии на 2015 год.

Задачи проекта

1. Провести загрузку и предобработку данных:

- Оценить объём, полноту и качество данных.
- Привести названия столбцов к единому стилю.
- Обработать пропущенные и аномальные значения, в частности в ключевых столбцах `funding_total_usd` и `mid_funding_at`.
- Обработать типы данных.
- Удалить неинформативные записи и полные дубликаты.

1. Провести инжиниринг признаков:

- Классифицировать компании по длительности цикла финансирования (единичное, до года, более года).
- Сегментировать рынок на массовые, средние и нишевые категории на основе частоты встречаемости и объединить не-массовые сегменты.

1. Выполнить анализ данных и выбросов:

- Выявить и исключить компании с аномальным объёмом финансирования с помощью метода IQR в разрезе сегментов.
- Определить временные границы данных (годы с 50+ раундами финансирования).
- Проанализировать типы финансирования по объёму привлечённых средств и популярности.

1. Исследовать динамику ключевых показателей:

- Проанализировать динамику типичного размера раунда и общей активности на рынке инвестиций по годам.
- Выявить массовые рыночные сегменты, показавшие рост в 2014 году, и проанализировать их динамику.
- Рассчитать и визуализировать годовую динамику доли возвращённых средств.

1. Сформулировать итоговые выводы и рекомендации.

Содержание проекта

1. Загрузка данных и знакомство с ними

1.1 Предобработка данных

1. Инжиниринг признаков

2.1. Группы по срокам финансирования

2.2. Выделение средних и нишевых сегментов рынка

1. Работа с выбросами и анализ

3.1. Анализируем и помечаем выбросы в каждом из сегментов

3.2. Определяем границы рассматриваемого периода, отбрасываем аномалии

3.3. Анализ типов финансирования по объёму и популярности

1. Анализ динамики

4.1. Динамика предоставления финансирования по годам

4.2. Динамика размера общего финансирования по массовым сегментам рынка для растущих в 2014 году сегментов

4.3. Годовая динамика доли возвращённых средств по типам финансировани

1. Итоговый вывод и рекомендации

Знакомство с данными: загрузка и предобработка

Данные представлены основным и вспомогательным датасетами : датасет -

cb_investments содержит основную информацию, дополнительного датасета — cb_returns , содержит суммы возвратов по типам финансирования в миллионах долларов по годам.

1.1. Вывод общей информации

Загружаем необходимые для работы библиотеки.

In [1]:

```
!pip install phik -q
!pip install missingno
```

```
Requirement already satisfied: missingno in /opt/conda/lib/python3.9/site-packages (0.5.2)
Requirement already satisfied: numpy in /opt/conda/lib/python3.9/site-packages (from missingno) (1.21.1)
Requirement already satisfied: scipy in /opt/conda/lib/python3.9/site-packages (from missingno) (1.9.1)
Requirement already satisfied: seaborn in /opt/conda/lib/python3.9/site-packages (from missingno) (0.11.1)
Requirement already satisfied: matplotlib in /opt/conda/lib/python3.9/site-packages (from missingno) (3.3.4)
Requirement already satisfied: pyparsing!=2.0.4,!=2.1.2,!=2.1.6,>=2.0.3 in /opt/conda/lib/python3.9/site-packages (from matplotlib->missingno) (2.4.7)
Requirement already satisfied: python-dateutil>=2.1 in /opt/conda/lib/python3.9/site-packages (from matplotlib->missingno) (2.8.1)
Requirement already satisfied: pillow>=6.2.0 in /opt/conda/lib/python3.9/site-packages (from matplotlib->missingno) (8.4.0)
Requirement already satisfied: cycler>=0.10 in /opt/conda/lib/python3.9/site-packages (from matplotlib->missingno) (0.11.0)
Requirement already satisfied: kiwisolver>=1.0.1 in /opt/conda/lib/python3.9/site-packages (from matplotlib->missingno) (1.4.4)
Requirement already satisfied: six>=1.5 in /opt/conda/lib/python3.9/site-packages (from python-dateutil>=2.1->matplotlib->missingno) (1.16.0)
Requirement already satisfied: pandas>=0.23 in /opt/conda/lib/python3.9/site-packages
```

(from seaborn->missingno) (1.2.4)
Requirement already satisfied: pytz>=2017.3 in /opt/conda/lib/python3.9/site-packages
(from pandas>=0.23->seaborn->missingno) (2021.1)

```
In [2]: # Импортируем библиотеки
import pandas as pd

import numpy as np

# Загружаем библиотеки для визуализации данных
import matplotlib.pyplot as plt
from matplotlib import cm

import seaborn as sns

import missingno as msno
```

Загружаем данные по проекту.

```
In [3]: # Загружаем файл cb_investments.csv. и создаем копию
df_invest = pd.read_csv("/datasets/cb_investments.zip", sep=';',
                        compression = 'zip',
                        low_memory=False)
df_invest_orig = df_invest.copy()
```

```
In [4]: # Загружаем файл cb_returns.csv.
df_returns = pd.read_csv('/datasets/cb_returns.csv', index_col=0)
```

Выводим информацию, которая необходима для принятия решений о предобработке.

```
In [5]: # Выводим информацию о датафрейме
print('Информация о файле с инвестициями', '\n')
print(df_invest.info())
```

Информация о файле с инвестициями

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 54294 entries, 0 to 54293
Data columns (total 40 columns):
#   Column                                Non-Null Count  Dtype
---  -
0   name                                  49437 non-null  object
1   homepage_url                         45989 non-null  object
2   category_list                        45477 non-null  object
3   market                               45477 non-null  object
4   funding_total_usd                   49438 non-null  object
5   status                               48124 non-null  object
6   country_code                        44165 non-null  object
7   state_code                           30161 non-null  object
8   region                               44165 non-null  object
9   city                                 43322 non-null  object
10  funding_rounds                       49438 non-null  float64
11  participants                         30473 non-null  float64
12  founded_at                           38554 non-null  object
13  founded_month                        38482 non-null  object
14  founded_quarter                      38482 non-null  object
15  founded_year                         38554 non-null  float64
16  first_funding_at                    49438 non-null  object
17  mid_funding_at                      30288 non-null  object
18  last_funding_at                     49438 non-null  object
19  seed                                 49438 non-null  float64
20  venture                             49438 non-null  float64
21  equity_crowdfunding                  49438 non-null  float64
22  undisclosed                          49438 non-null  float64
23  convertible_note                    49438 non-null  float64
```

```

24 debt_financing      49438 non-null float64
25 angel               49438 non-null float64
26 grant               49438 non-null float64
27 private_equity      49438 non-null float64
28 post_ipo_equity     49438 non-null float64
29 post_ipo_debt       49438 non-null float64
30 secondary_market    49438 non-null float64
31 product_crowdfunding 49438 non-null float64
32 round_A             49438 non-null float64
33 round_B             49438 non-null float64
34 round_C             49438 non-null float64
35 round_D             49438 non-null float64
36 round_E             49438 non-null float64
37 round_F             49438 non-null float64
38 round_G             49438 non-null float64
39 round_H             49438 non-null float64

```

dtypes: float64(24), object(16)

memory usage: 16.6+ MB

None

In [6]:

```

# Подсчитаем количество строк с пропусками
missing_raw = df_invest.isna().sum()

# Подсчитываем долю строк с пропусками
missing_percent = round((df_invest.isna().sum() / df_invest.shape[0]),2)*100

missing_data = pd.DataFrame ({
    'Абсолютное значение': missing_raw,
    'Относительное значение': missing_percent
})

print('Пропущенные значения')
display(missing_data)

```

Пропущенные значения

	Абсолютное значение	Относительное значение
name	4857	9.0
homepage_url	8305	15.0
category_list	8817	16.0
market	8817	16.0
funding_total_usd	4856	9.0
status	6170	11.0
country_code	10129	19.0
state_code	24133	44.0
region	10129	19.0
city	10972	20.0
funding_rounds	4856	9.0
participants	23821	44.0
founded_at	15740	29.0
founded_month	15812	29.0
founded_quarter	15812	29.0
founded_year	15740	29.0
first_funding_at	4856	9.0
mid_funding_at	24006	44.0

	Абсолютное значение	Относительное значение
last_funding_at	4856	9.0
seed	4856	9.0
venture	4856	9.0
equity_crowdfunding	4856	9.0
undisclosed	4856	9.0
convertible_note	4856	9.0
debt_financing	4856	9.0
angel	4856	9.0
grant	4856	9.0
private_equity	4856	9.0
post_ipo_equity	4856	9.0
post_ipo_debt	4856	9.0
secondary_market	4856	9.0
product_crowdfunding	4856	9.0
round_A	4856	9.0
round_B	4856	9.0
round_C	4856	9.0
round_D	4856	9.0
round_E	4856	9.0
round_F	4856	9.0
round_G	4856	9.0
round_H	4856	9.0


In [7]:

```
# Визуализация пропусков
plt.figure(figsize = (10,6))
msno.matrix(df_invest)

plt.title('Обзор пропусков в данных', fontsize = 14)

plt.show()
```

<Figure size 720x432 with 0 Axes>



In [8]: `# Выводим несколько строк датафрейма
display(df_invest.head(10))`

	name	homepage_url	category_list	market	funding_total_usd
0	Harvard University	http://harvard.edu	Education	Education	9,00,00,000
1	University of New Brunswick	http://www.unb.ca	NaN	NaN	20,00,000
2	DuPont	http://www.dupont.com	Business Services Agriculture Automotive Inve...	Business Services	90,00,000
3	University of Michigan	http://www.umich.edu/	Education	Education	77,00,000
4	Case Western Reserve University	http://www.case.edu	Education	Education	5,40,000
5	Xavier University	http://www.xavier.edu/	NaN	NaN	1,90,00,000
6	Tulane University	http://tulane.edu/	Education	Education	1,20,00,000
7	Duke University	http://www.duke.edu	Education	Education	87,00,000
8	Virginia Commonwealth University, Richmond	http://www.vcu.edu/	NaN	NaN	60,00,000
9	WeGame	http://www.WeGame.com	Social Media	Social Media	35,00,000

10 rows x 40 columns

Датасет 'cb_investments' содержит 40 столбцов и 54293 строк, в которых представлена детальная информация о компаниях, их финансировании и деятельности.

После первичного анализа данных можно сделать следующие выводы:

- Необходимо превести названия столбцов к единому стилю
- Наблюдаются массовые пропуски в ключевых полях.
- Большинство числовых столбцов (funding_total_usd, seed, venture, и т.д.) имеют тип данных object, потому что в данных встречаются: запятые как разделители, строки - или n/a вместо чисел. Эти поля нужно очистить и привести к числовому типу (float).
- Даты (founded_at, first_funding_at, last_funding_at) — строки, нужно преобразовать в формат datetime.

In [9]:

```
# Выводим информацию о датафрейме
print('Информация о доп. файле с суммами возвратов', '\n')
print(df_returns.info())
```

Информация о доп. файле с суммами возвратов

```
<class 'pandas.core.frame.DataFrame'>
Int64Index: 15 entries, 2000 to 2014
Data columns (total 13 columns):
#   Column                                Non-Null Count  Dtype
---  ---                                ---
0   seed                                15 non-null    float64
1   venture                            15 non-null    float64
2   equity_crowdfunding                 15 non-null    float64
3   undisclosed                         15 non-null    float64
4   convertible_note                   15 non-null    float64
5   debt_financing                     15 non-null    float64
6   angel                              15 non-null    float64
7   grant                              15 non-null    float64
8   private_equity                     15 non-null    float64
9   post_ipo_equity                    15 non-null    float64
10  post_ipo_debt                      15 non-null    float64
11  secondary_market                   15 non-null    float64
12  product_crowdfunding               15 non-null    float64
dtypes: float64(13)
memory usage: 1.6 KB
None
```


In [10]:

```
# Визуализация пропусков
plt.figure(figsize = (10,6))
msno.matrix(df_returns)

plt.title('Обзор пропусков в данных', fontsize = 14)

plt.show()
```

<Figure size 720x432 with 0 Axes>



```
In [11]: # Выводим несколько строк датафрейма
display(df_returns.head(15))
```

	seed	venture	equity_crowdfunding	undisclosed	convertible_note	debt_financing	angel	grant
year								
2000	16.70	55.40	0.00	78.21	0.00	8.66	6.43	0.0
2001	2.88	23.49	0.00	21.50	0.01	4.49	1.18	0.0
2002	6.59	209.42	0.00	25.77	0.02	3.42	3.41	0.0
2003	7.74	233.86	0.00	9.40	0.01	1.09	3.41	0.0
2004	9.93	555.90	0.00	33.19	0.01	13.55	9.18	0.0
2005	26.60	2628.92	0.00	9.51	0.02	35.09	31.06	0.0
2006	61.81	3100.18	0.19	46.74	1.78	113.21	47.75	0.0
2007	70.41	3585.37	0.01	55.37	3.22	125.68	164.51	0.0
2008	89.72	2717.02	0.03	41.02	1.71	397.54	102.83	0.0
2009	160.21	2501.29	0.18	37.50	2.25	394.10	97.21	0.0
2010	265.33	3299.35	0.39	52.15	3.14	503.73	157.21	0.0
2011	317.29	3919.38	0.30	59.36	3.96	572.92	172.17	0.0
2012	373.31	4727.74	0.44	71.04	4.79	694.97	193.03	0.0
2013	442.97	5749.29	1.14	84.40	6.00	848.65	225.87	0.0
2014	530.75	7272.01	1.15	105.72	7.87	1017.75	293.98	0.0

Датасет 'cb_returns' содержит 14 столбцов и 15 строк, в которых представлены агрегированные показатели доходности. Датасет является дополнительным

После первичного анализа данных можно сделать следующие выводы:

- Названия столбцов в едином стиле
- Пропуски отсутствуют

- Дубликатов нет

Общий вывод:

Данные требуют тщательной подготовки. Особое внимание следует уделить финансовым показателям, так как они являются основой для последующего анализа.

Сделайте вывод о полученных данных: каков их объём, соответствуют ли данные описанию, есть ли пропущенные значения, используются ли верные типы данных. Отметьте другие особенности данных, которые вы обнаружите на этой стадии и на которые стоит обратить внимание при предобработке.

1.2. Предобработка данных

Проверяем названия столбцов в датасетах: все ли они точно отражают содержимое данных и оформлены в удобном для работы стиле.

In [12]:

```
print("\nСтолбцы датафрейма инвестиций",df_invest.columns.tolist())
print("\nСтолбцы датафрейма возвратов сумм",df_returns.columns.tolist())
```

Столбцы датафрейма инвестиций ['name', 'homepage_url', 'category_list', 'market', 'funding_total_usd', 'status', 'country_code', 'state_code', 'region', 'city', 'funding_rounds', 'participants', 'founded_at', 'founded_month', 'founded_quarter', 'founded_year', 'first_funding_at', 'mid_funding_at', 'last_funding_at', 'seed', 'venture', 'equity_crowdfunding', 'undisclosed', 'convertible_note', 'debt_financing', 'angel', 'grant', 'private_equity', 'post_ipo_equity', 'post_ipo_debt', 'secondary_market', 'product_crowdfunding', 'round_A', 'round_B', 'round_C', 'round_D', 'round_E', 'round_F', 'round_G', 'round_H']

Столбцы датафрейма возвратов сумм ['seed', 'venture', 'equity_crowdfunding', 'undisclosed', 'convertible_note', 'debt_financing', 'angel', 'grant', 'private_equity', 'post_ipo_equity', 'post_ipo_debt', 'secondary_market', 'product_crowdfunding']

Названия столбцов в returns соответствует стандарту.

Названия столбцов в investments необходимо привести стандарту, есть заглавные буквы и лишние пробелы в названиях столбцов

In [13]:

```
# Удаляем пробелы в начале и конце, приводим к нижнему регистру и заменяем пробелы на _
df_invest.columns = [col.strip().lower().replace(' ', '_') for col in df_invest.columns]

# Выводим столбцы
print("\nОбработанные названия столбцов датафрейма инвестиций:")
print(df_invest.columns.tolist())
```

Обработанные названия столбцов датафрейма инвестиций:

['name', 'homepage_url', 'category_list', 'market', 'funding_total_usd', 'status', 'country_code', 'state_code', 'region', 'city', 'funding_rounds', 'participants', 'founded_at', 'founded_month', 'founded_quarter', 'founded_year', 'first_funding_at', 'mid_funding_at', 'last_funding_at', 'seed', 'venture', 'equity_crowdfunding', 'undisclosed', 'convertible_note', 'debt_financing', 'angel', 'grant', 'private_equity', 'post_ipo_equity', 'post_ipo_debt', 'secondary_market', 'product_crowdfunding', 'round_a', 'round_b', 'round_c', 'round_d', 'round_e', 'round_f', 'round_g', 'round_h']

Уберите в столбце funding_total_usd выделение разрядов и приведите его к числовому типу.

In [14]:

```
# Убираем разделители, приводим к числовому формату
df_invest['funding_total_usd'] = pd.to_numeric(df_invest['funding_total_usd'].str.replace(',', ''))
display(df_invest['funding_total_usd'].head(10))

print(df_invest['funding_total_usd'].dtype)
```

```

0    90000000.0
1    2000000.0
2    9000000.0
3    7700000.0
4     540000.0
5   19000000.0
6   12000000.0
7    8700000.0
8    6000000.0
9    3500000.0
Name: funding_total_usd, dtype: float64
float64

```

Обрабатываем типы данных в столбцах, которые хранят значения даты и времени, если это необходимо.

In [15]:

```

# Преобразование столбцов с датами к типу datetime

date_cols = ['founded_at', 'founded_month', 'first_funding_at', 'mid_funding_at', 'last_

for col in date_cols:
    if col in df_invest.columns:
        df_invest[col] = pd.to_datetime(df_invest[col], errors='coerce')

# Проверка результата
print(df_invest.shape)
print(df_invest.info())

# Выводим строки столбцов с датами
display(df_invest[date_cols].head(20))

```

```

(54294, 40)
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 54294 entries, 0 to 54293
Data columns (total 40 columns):
#   Column                                Non-Null Count  Dtype
---  -
0   name                                 49437 non-null  object
1   homepage_url                        45989 non-null  object
2   category_list                       45477 non-null  object
3   market                             45477 non-null  object
4   funding_total_usd                  40907 non-null  float64
5   status                             48124 non-null  object
6   country_code                       44165 non-null  object
7   state_code                         30161 non-null  object
8   region                             44165 non-null  object
9   city                               43322 non-null  object
10  funding_rounds                      49438 non-null  float64
11  participants                        30473 non-null  float64
12  founded_at                          38553 non-null  datetime64[ns]
13  founded_month                       38482 non-null  datetime64[ns]
14  founded_quarter                     38482 non-null  object
15  founded_year                        38554 non-null  float64
16  first_funding_at                   49428 non-null  datetime64[ns]
17  mid_funding_at                     30288 non-null  datetime64[ns]
18  last_funding_at                    49432 non-null  datetime64[ns]
19  seed                               49438 non-null  float64
20  venture                            49438 non-null  float64
21  equity_crowdfunding                49438 non-null  float64
22  undisclosed                         49438 non-null  float64
23  convertible_note                   49438 non-null  float64
24  debt_financing                     49438 non-null  float64
25  angel                              49438 non-null  float64
26  grant                              49438 non-null  float64
27  private_equity                     49438 non-null  float64
28  post_ipo_equity                     49438 non-null  float64
29  post_ipo_debt                      49438 non-null  float64
30  secondary_market                   49438 non-null  float64
31  product_crowdfunding               49438 non-null  float64

```

```

32 round_a          49438 non-null float64
33 round_b          49438 non-null float64
34 round_c          49438 non-null float64
35 round_d          49438 non-null float64
36 round_e          49438 non-null float64
37 round_f          49438 non-null float64
38 round_g          49438 non-null float64
39 round_h          49438 non-null float64
dtypes: datetime64[ns](5), float64(25), object(10)
memory usage: 16.6+ MB
None

```

	founded_at	founded_month	first_funding_at	mid_funding_at	last_funding_at
0	NaT	NaT	2014-01-06	NaT	2014-01-06
1	1785-01-01	NaT	2014-05-15	NaT	2014-05-15
2	1802-07-19	NaT	2009-07-02	2009-07-02	2009-07-02
3	1817-01-01	NaT	2013-11-21	2013-11-21	2014-11-03
4	1826-01-01	NaT	2014-01-14	NaT	2014-01-14
5	1831-01-01	NaT	2014-10-23	NaT	2014-10-23
6	1834-01-01	NaT	2013-09-05	2013-09-05	2013-12-22
7	1838-01-01	NaT	2014-01-12	NaT	2014-01-12
8	1838-01-01	NaT	2014-09-30	NaT	2014-09-30
9	1840-01-01	NaT	2007-10-01	2007-10-01	2008-03-01
10	1840-09-02	NaT	2011-01-01	2011-01-01	2011-01-01
11	1845-01-01	NaT	2012-10-12	2012-10-12	2012-10-12
12	1847-01-01	NaT	2010-07-19	2010-07-19	2010-07-19
13	1850-01-01	NaT	2014-08-12	NaT	2014-08-12
14	1853-01-01	NaT	2013-07-01	2013-07-01	2013-07-01
15	1854-02-01	NaT	1995-01-01	1995-01-01	1995-01-01
16	1855-02-12	NaT	2014-05-05	NaT	2014-05-05
17	1856-01-01	NaT	2013-09-17	2013-09-17	2014-02-06
18	1856-01-01	NaT	2014-07-30	NaT	2014-07-30
19	1857-01-01	NaT	2014-08-12	NaT	2014-08-12

Тип данных изменен в столбцах `founded_at` `founded_month` `first_funding_at` `mid_funding_at` `last_funding_at` на `datetime`. Столбец `founded_year` содержит только год и числовой формат подходит для хранения такого типа данных. Столбец `founded_quarter` содержит буквенное обозначения квартала, для сохранения формата записи, оставим тип данных `object`.

В датасете `cb_returns` сделайте столбец `year` индексом всего датасета, если не делали это при загрузке.

```

In [16]: print(df_returns.columns)
display(df_returns.head())

```

```

Index(['seed', 'venture', 'equity_crowdfunding', 'undisclosed',
      'convertible_note', 'debt_financing', 'angel', 'grant',
      'private_equity', 'post_ipo_equity', 'post_ipo_debt',
      'secondary_market', 'product_crowdfunding'],
      dtype='object')

```

	seed	venture	equity_crowdfunding	undisclosed	convertible_note	debt_financing	angel	grant	p
year									
2000	16.70	55.40	0.0	78.21	0.00	8.66	6.43	0.0	
2001	2.88	23.49	0.0	21.50	0.01	4.49	1.18	0.0	
2002	6.59	209.42	0.0	25.77	0.02	3.42	3.41	0.0	
2003	7.74	233.86	0.0	9.40	0.01	1.09	3.41	0.0	
2004	9.93	555.90	0.0	33.19	0.01	13.55	9.18	0.0	

Столбец year сделан индексам при загрузке

Обрабатываем текстовые данные, если это необходимо. Пропуски в текстовых столбцах заполним заглушками там, где это понадобится.

In [17]:

```
# Выводим столбцы с типом данных object
text_cols = df_invest.select_dtypes(include='object').columns.tolist()
print(text_cols)
```

```
['name', 'homepage_url', 'category_list', 'market', 'status', 'country_code', 'state_code', 'region', 'city', 'founded_quarter']
```

In [18]:

```
# Перечислим столбцы в которых будут заглушки
placeholder_dict = {'name': 'unknown',
                    'homepage_url': 'unknown',
                    'category_list': 'unknown',
                    'market': 'unknown',
                    'status': 'unknown',
                    'country_code': 'unknown',
                    'state_code': 'unknown',
                    'region': 'unknown',
                    'city': 'unknown',
                    }

# Форматируем все строки 'nan' и пустые строки для дальнейшей обработки
for col in text_cols:
    if col in df_invest.columns:
        df_invest[col] = df_invest[col].replace('nan', np.nan) # строка nan
        df_invest[col] = df_invest[col].replace('', np.nan)    # пустая строка

# Заменяем пропуски заглушками
for col, placeholder in placeholder_dict.items():
    if col in df_invest.columns:
        df_invest[col] = df_invest[col].fillna(placeholder)
```

In [19]:

```
# Проверка результатов
display(df_invest.head(15))
print("\nИнформация о пропусках:")
print(df_invest.isnull().sum())
```

	name	homepage_url	category_list	market	funding_
0	Harvard University	http://harvard.edu	[Education]	Education	90
1	University of New Brunswick	http://www.unb.ca	unknown	unknown	

	name	homepage_url	category_list	market	funding_
2	DuPont	http://www.dupont.com	Business Services Agriculture Automotive Inve...	Business Services	9
3	University of Michigan	http://www.umich.edu/	Education	Education	10
4	Case Western Reserve University	http://www.case.edu	Education	Education	10
5	Xavier University	http://www.xavier.edu/	unknown	unknown	10
6	Tulane University	http://tulane.edu/	Education	Education	10
7	Duke University	http://www.duke.edu	Education	Education	10
8	Virginia Commonwealth University, Richmond	http://www.vcu.edu/	unknown	unknown	10
9	WeGame	http://www.WeGame.com	Social Media	Social Media	10
10	VideoSurf	http://www.videosurf.com	Hardware + Software	Hardware + Software	20
11	Mayne Pharma	http://www.maynepharma.com	Biotechnology	Biotechnology	10
12	Siemens	http://www.siemens.com	Clean Energy Automotive Hardware + Software	Hardware + Software	10
13	University of Rochester	http://www.rochester.edu	unknown	unknown	10
14	University of Florida	http://www.ufl.edu	unknown	unknown	10

15 rows x 40 columns

Информация о пропусках:

name	0
homepage_url	0
category_list	0
market	0
funding_total_usd	13387
status	0
country_code	0
state_code	0
region	0
city	0
funding_rounds	4856
participants	23821
founded_at	15741
founded_month	15812
founded_quarter	15812
founded_year	15740
first_funding_at	4866
mid_funding_at	24006
last_funding_at	4862
seed	4856
venture	4856
equity_crowdfunding	4856
undisclosed	4856
convertible_note	4856
debt_financing	4856

```

angel          4856
grant          4856
private_equity 4856
post_ipo_equity 4856
post_ipo_debt  4856
secondary_market 4856
product_crowdfunding 4856
round_a        4856
round_b        4856
round_c        4856
round_d        4856
round_e        4856
round_f        4856
round_g        4856
round_h        4856
dtype: int64

```

В текстовых столбцах к пропускам применена заглушка unknown. Столбец founded_quarter оставлен без изменений

In [20]:

```

# Нормализация текстовых столбцов
text_cols = df_invest.select_dtypes(include='object').columns
for col in text_cols:
    df_invest[col] = df_invest[col].astype(str) # привести к строке
    df_invest[col] = df_invest[col].str.strip()  # обрезать пробелы по краям
    df_invest[col] = df_invest[col].str.lower()  # привести к нижнему регистру
    df_invest[col] = df_invest[col].str.replace(r'\s+', ' ', regex=True) # нормализация

# Нормализации для category_list
if 'category_list' in df_invest.columns:
    df_invest['category_list'] = df_invest['category_list'].str.replace(r'\s*\|\s*', ' ')
    df_invest['category_list'] = df_invest['category_list'].str.strip()

# Форматируем все строки nan и пустые строки после нормализации
for col in text_cols:
    if col in df_invest.columns:
        df_invest[col] = df_invest[col].replace('nan', np.nan) # строка nan
        df_invest[col] = df_invest[col].replace('', np.nan)    # пустая строка

# Выводим строки
display(df_invest.head())

```

	name	homepage_url	category_list	market	funding_total_usd	stage
0	harvard university	http://harvard.edu	education	education	90000000.0	operational
1	university of new brunswick	http://www.unb.ca	unknown	unknown	2000000.0	operational
2	dupont	http://www.dupont.com	business services agriculture automotive investments	business services	9000000.0	operational
3	university of michigan	http://www.umich.edu/	education	education	7700000.0	operational
4	case western reserve university	http://www.case.edu	education	education	540000.0	operational

5 rows × 40 columns

	name	homepage_url	category_list	market	funding_total_usd	sta
0	harvard university	http://harvard.edu	education	education	90000000.0	opera
1	university of new brunswick	http://www.unb.ca	unknown	unknown	2000000.0	opera
2	dupont	http://www.dupont.com	business services agriculture automotive inve...	business services	9000000.0	opera
3	university of michigan	http://www.umich.edu/	education	education	7700000.0	opera
4	case western reserve university	http://www.case.edu	education	education	540000.0	opera

5 rows × 40 columns

	name	homepage_url	category_list	market	funding_total_usd	sta
0	harvard university	http://harvard.edu	education	education	90000000.0	opera
1	university of new brunswick	http://www.unb.ca	unknown	unknown	2000000.0	opera
2	dupont	http://www.dupont.com	business services agriculture automotive inve...	business services	9000000.0	opera
3	university of michigan	http://www.umich.edu/	education	education	7700000.0	opera
4	case western reserve university	http://www.case.edu	education	education	540000.0	opera

5 rows × 40 columns

	name	homepage_url	category_list	market	funding_total_usd	sta
0	harvard university	http://harvard.edu	education	education	90000000.0	opera
1	university of new brunswick	http://www.unb.ca	unknown	unknown	2000000.0	opera
2	dupont	http://www.dupont.com	business services agriculture automotive inve...	business services	9000000.0	opera
3	university of michigan	http://www.umich.edu/	education	education	7700000.0	opera
4	case western reserve university	http://www.case.edu	education	education	540000.0	opera

5 rows × 40 columns

	name	homepage_url	category_list	market	funding_total_usd	sta
0	harvard university	http://harvard.edu	education	education	90000000.0	opera
1	university of new brunswick	http://www.unb.ca	unknown	unknown	2000000.0	opera
2	dupont	http://www.dupont.com	business services agriculture automotive inve...	business services	9000000.0	opera
3	university of michigan	http://www.umich.edu/	education	education	7700000.0	opera
4	case western reserve university	http://www.case.edu	education	education	540000.0	opera

5 rows x 40 columns

	name	homepage_url	category_list	market	funding_total_usd	sta
0	harvard university	http://harvard.edu	education	education	90000000.0	opera
1	university of new brunswick	http://www.unb.ca	unknown	unknown	2000000.0	opera
2	dupont	http://www.dupont.com	business services agriculture automotive inve...	business services	9000000.0	opera
3	university of michigan	http://www.umich.edu/	education	education	7700000.0	opera
4	case western reserve university	http://www.case.edu	education	education	540000.0	opera

5 rows x 40 columns

	name	homepage_url	category_list	market	funding_total_usd	sta
0	harvard university	http://harvard.edu	education	education	90000000.0	opera
1	university of new brunswick	http://www.unb.ca	unknown	unknown	2000000.0	opera
2	dupont	http://www.dupont.com	business services agriculture automotive inve...	business services	9000000.0	opera
3	university of michigan	http://www.umich.edu/	education	education	7700000.0	opera
4	case western	http://www.case.edu	education	education	540000.0	opera

	name	homepage_url	category_list	market	funding_total_usd	sta
	reserve university					

5 rows × 40 columns

	name	homepage_url	category_list	market	funding_total_usd	sta
0	harvard university	http://harvard.edu	education	education	90000000.0	opera
1	university of new brunswick	http://www.unb.ca	unknown	unknown	2000000.0	opera
2	dupont	http://www.dupont.com	business services agriculture automotive inve...	business services	9000000.0	opera
3	university of michigan	http://www.umich.edu/	education	education	7700000.0	opera
4	case western reserve university	http://www.case.edu	education	education	540000.0	opera

5 rows × 40 columns

	name	homepage_url	category_list	market	funding_total_usd	sta
0	harvard university	http://harvard.edu	education	education	90000000.0	opera
1	university of new brunswick	http://www.unb.ca	unknown	unknown	2000000.0	opera
2	dupont	http://www.dupont.com	business services agriculture automotive inve...	business services	9000000.0	opera
3	university of michigan	http://www.umich.edu/	education	education	7700000.0	opera
4	case western reserve university	http://www.case.edu	education	education	540000.0	opera

5 rows × 40 columns

	name	homepage_url	category_list	market	funding_total_usd	sta
0	harvard university	http://harvard.edu	education	education	90000000.0	opera
1	university of new brunswick	http://www.unb.ca	unknown	unknown	2000000.0	opera
2	dupont	http://www.dupont.com	business services agriculture automotive inve...	business services	9000000.0	opera

	name	homepage_url	category_list	market	funding_total_usd	sta
3	university of michigan	http://www.umich.edu/	education	education	7700000.0	opera
4	case western reserve university	http://www.case.edu	education	education	540000.0	opera

5 rows × 40 columns

Проведена нормализация в столбцах. Текст приведен к нижнему регистру

Обработайте полные дубликаты в данных и пропуски в `funding_total_usd` . избавьтесь от тех строк, которые не несут какой-либо информации либо не содержат данных о финансировании.

In [21]:

```
# Проверяем полные дубликаты в датафрейме
print('Количество полных дубликатов', df_invest.duplicated().sum())

duplicates_mask = df_invest.duplicated(keep='first') # пометка дубликатов, включая полные
duplicates = df_invest[duplicates_mask] # строки-дубликаты

# Выведем строки-дубликаты
display(duplicates)
```

Количество полных дубликатов 4855

	name	homepage_url	category_list	market	funding_total_usd	status	country_code	state
49439	unknown	unknown	unknown	unknown	NaN	unknown	unknown	unl
49440	unknown	unknown	unknown	unknown	NaN	unknown	unknown	unl
49441	unknown	unknown	unknown	unknown	NaN	unknown	unknown	unl
49442	unknown	unknown	unknown	unknown	NaN	unknown	unknown	unl
49443	unknown	unknown	unknown	unknown	NaN	unknown	unknown	unl
...	...	...	...	...	...	...	...	...
54289	unknown	unknown	unknown	unknown	NaN	unknown	unknown	unl
54290	unknown	unknown	unknown	unknown	NaN	unknown	unknown	unl
54291	unknown	unknown	unknown	unknown	NaN	unknown	unknown	unl
54292	unknown	unknown	unknown	unknown	NaN	unknown	unknown	unl
54293	unknown	unknown	unknown	unknown	NaN	unknown	unknown	unl

4855 rows × 40 columns

In [22]:

```
# Удаление дубликатов в исходном датафрейме
df_invest.drop_duplicates(keep='first', inplace=True)

#Размер датафрейма после удаления
print(f"Размер после очистки: {df_invest.shape}")
```

Размер после очистки: (49439, 40)

Удалено 4 855 строк, являющихся полными дубликатами. Размерность датафрейма после удаления составила 49 439 строк и 40 столбцов

In [23]:

```
# Форматируем все строки nan и пустые строки после приведения к нижнему регистру для да
for col in text_cols:
    if col in df_invest.columns:
        df_invest[col] = df_invest[col].replace('nan', np.nan) # строка nan
        df_invest[col] = df_invest[col].replace('', np.nan)     # пустая строка

# Результат после удаления полных дубликатов
print("\nИнформация о пропусках:")
print(df_invest.isnull().sum())
```

Информация о пропусках:

name	0
homepage_url	0
category_list	0
market	0
funding_total_usd	8532
status	0
country_code	0
state_code	0
region	0
city	0
funding_rounds	1
participants	18966
founded_at	10886
founded_month	10957
founded_quarter	10957
founded_year	10885
first_funding_at	11
mid_funding_at	19151
last_funding_at	7
seed	1
venture	1
equity_crowdfunding	1
undisclosed	1
convertible_note	1
debt_financing	1
angel	1
grant	1
private_equity	1
post_ipo_equity	1
post_ipo_debt	1
secondary_market	1
product_crowdfunding	1
round_a	1
round_b	1
round_c	1
round_d	1
round_e	1
round_f	1
round_g	1
round_h	1
dtype: int64	

Проверим единичные пропуски в столбцах

In [24]:

```
fin_columns = ['funding_rounds', 'seed', 'venture', 'equity_crowdfunding', 'undisclosed',
               'convertible_note', 'debt_financing', 'angel', 'grant', 'private_equity',
               'post_ipo_equity', 'post_ipo_debt', 'secondary_market', 'product_crowdfur',
               'round_a', 'round_b', 'round_c', 'round_d', 'round_e', 'round_f', 'round_

fin_columns_pul = [col for col in fin_columns if col in df_invest.columns]

#Выведем перечень финансовых столбцов
print(f"Финансовые столбцы для анализа: {fin_columns_pul}")
```

Финансовые столбцы для анализа: ['funding_rounds', 'seed', 'venture', 'equity_crowdfunding', 'undisclosed', 'convertible_note', 'debt_financing', 'angel', 'grant', 'private_equity', 'post_ipo_equity', 'post_ipo_debt', 'secondary_market', 'product_crowdfunding', 'round_a', 'round_b', 'round_c', 'round_d', 'round_e', 'round_f', 'round_g', 'round_h']

In [25]:

```
# Форматируем все строки nan и пустые строки
for col in fin_columns_pul:
    if col in df_invest.columns:
        df_invest[col] = df_invest[col].replace('nan', np.nan)
        df_invest[col] = df_invest[col].replace('', np.nan)

# Для подстраховки – если всё равно есть тип object:
df_invest[col] = pd.to_numeric(df_invest[col], errors='coerce')

# Удалить строки, если в одном из финансовом столбце пропуск
no_fin = df_invest[fin_columns_pul].isnull().any(axis=1)

delite_count = no_fin.sum()

print(f"Найдено строк с пропусками в финансовых данных: {delite_count}")

# Оставить только строки, где в финансовых столбцах нет пропусков
df_invest = df_invest[~no_fin]

print(f"Размер после очистки: {df_invest.shape}")
print("\nИнформация о пропусках:")
print(df_invest.isnull().sum())
```

Найдено строк с пропусками в финансовых данных: 1
Размер после очистки: (49438, 40)

Информация о пропусках:

name	0
homepage_url	0
category_list	0
market	0
funding_total_usd	8531
status	0
country_code	0
state_code	0
region	0
city	0
funding_rounds	0
participants	18965
founded_at	10885
founded_month	10956
founded_quarter	10956
founded_year	10884
first_funding_at	10
mid_funding_at	19150
last_funding_at	6
seed	0
venture	0
equity_crowdfunding	0
undisclosed	0
convertible_note	0
debt_financing	0
angel	0
grant	0
private_equity	0
post_ipo_equity	0
post_ipo_debt	0
secondary_market	0
product_crowdfunding	0
round_a	0
round_b	0
round_c	0
round_d	0

```

round_e      0
round_f      0
round_g      0
round_h      0
dtype: int64

```

Удалена одна строка. Если сравнивать с результатом после удаления полных дубликатов, можно сделать вывод, что пропуски в финансовых столбцах давала как раз эта строка.

```

In [26]: # Заполняем по комбинации category_list + market
market_city_medians = df_invest.groupby(['category_list', 'market'])['funding_total_usd'].transform('median')
df_invest['funding_total_usd'] = df_invest['funding_total_usd'].fillna(market_city_medians)

```

```

In [27]: # Если остались пропуски, заполняем по market
market_medians = df_invest.groupby('market')['funding_total_usd'].transform('median')
df_invest['funding_total_usd'] = df_invest['funding_total_usd'].fillna(market_medians)

```

```

In [28]: # Если все еще есть пропуски, заполняем общей медианой
overall_median = df_invest['funding_total_usd'].median()
df_invest['funding_total_usd'] = df_invest['funding_total_usd'].fillna(overall_median)

# Проверка результатов
print("\nИнформация о пропусках:")
print(df_invest.isnull().sum())

```

Информация о пропусках:

```

name      0
homepage_url      0
category_list      0
market      0
funding_total_usd      0
status      0
country_code      0
state_code      0
region      0
city      0
funding_rounds      0
participants      18965
founded_at      10885
founded_month      10956
founded_quarter      10956
founded_year      10884
first_funding_at      10
mid_funding_at      19150
last_funding_at      6
seed      0
venture      0
equity_crowdfunding      0
undisclosed      0
convertible_note      0
debt_financing      0
angel      0
grant      0
private_equity      0
post_ipo_equity      0
post_ipo_debt      0
secondary_market      0
product_crowdfunding      0
round_a      0
round_b      0
round_c      0
round_d      0
round_e      0
round_f      0
round_g      0

```

```
round_h          0
dtype: int64
```

Удалили полные дубликаты, значение в столбце `funding_total_usd` заполнили медианой

Заполним пропуски в значениях `mid_funding_at` на основании значений в столбцах `first_funding_at` и `last_funding_at`. В качестве нового значения вместо пропусков используем приблизительно середину интервала между этими двумя датами.

```
In [29]: # Функция для вычисления середины интервала между двумя датами

def fill_mid_funding(row):
    if pd.isna(row['mid_funding_at']) and not pd.isna(row['first_funding_at']) and not
        delta = row['last_funding_at'] - row['first_funding_at']
        return row['first_funding_at'] + delta / 2
    else:
        return row['mid_funding_at']

# Применяем функцию по строкам датафрейма
df_invest['mid_funding_at'] = df_invest.apply(fill_mid_funding, axis=1)
```

```
In [30]: # Проверяем сколько пропусков осталось
missing_after_fill = df_invest['mid_funding_at'].isnull().sum()
print(f"Количество пропусков в mid_funding_at после заполнения: {missing_after_fill}")
```

Количество пропусков в `mid_funding_at` после заполнения: 8

```
In [31]: print(df_invest.info())
```

```
<class 'pandas.core.frame.DataFrame'>
Int64Index: 49438 entries, 0 to 49437
Data columns (total 40 columns):
#   Column                                Non-Null Count  Dtype
---  -
0   name                                  49438 non-null  object
1   homepage_url                         49438 non-null  object
2   category_list                        49438 non-null  object
3   market                               49438 non-null  object
4   funding_total_usd                   49438 non-null  float64
5   status                              49438 non-null  object
6   country_code                        49438 non-null  object
7   state_code                          49438 non-null  object
8   region                              49438 non-null  object
9   city                                49438 non-null  object
10  funding_rounds                       49438 non-null  float64
11  participants                         30473 non-null  float64
12  founded_at                           38553 non-null  datetime64[ns]
13  founded_month                       38482 non-null  datetime64[ns]
14  founded_quarter                      38482 non-null  object
15  founded_year                        38554 non-null  float64
16  first_funding_at                    49428 non-null  datetime64[ns]
17  mid_funding_at                      49430 non-null  datetime64[ns]
18  last_funding_at                     49432 non-null  datetime64[ns]
19  seed                                49438 non-null  float64
20  venture                             49438 non-null  float64
21  equity_crowdfunding                 49438 non-null  float64
22  undisclosed                         49438 non-null  float64
23  convertible_note                    49438 non-null  float64
24  debt_financing                      49438 non-null  float64
25  angel                              49438 non-null  float64
26  grant                               49438 non-null  float64
27  private_equity                      49438 non-null  float64
28  post_ipo_equity                     49438 non-null  float64
29  post_ipo_debt                       49438 non-null  float64
30  secondary_market                    49438 non-null  float64
31  product_crowdfunding                49438 non-null  float64
```

```

32 round_a          49438 non-null float64
33 round_b          49438 non-null float64
34 round_c          49438 non-null float64
35 round_d          49438 non-null float64
36 round_e          49438 non-null float64
37 round_f          49438 non-null float64
38 round_g          49438 non-null float64
39 round_h          49438 non-null float64
dtypes: datetime64[ns](5), float64(25), object(10)
memory usage: 15.5+ MB
None

```

In [32]:

```

# Подсчитаем количество пропусков
missing_raw_end = df_invest.isna().sum()

# Подсчитываем долю строк с пропусками
missing_percent_end = round((df_invest.isna().sum() / df_invest.shape[0]),2)*100

missing_data_end = pd.DataFrame ({
    'Абсолютное значение': missing_raw_end,
    'Относительное значение': missing_percent_end
})

print('Пропущенные значения')
display(missing_data_end)

```

Пропущенные значения

	Абсолютное значение	Относительное значение
name	0	0.0
homepage_url	0	0.0
category_list	0	0.0
market	0	0.0
funding_total_usd	0	0.0
status	0	0.0
country_code	0	0.0
state_code	0	0.0
region	0	0.0
city	0	0.0
funding_rounds	0	0.0
participants	18965	38.0
founded_at	10885	22.0
founded_month	10956	22.0
founded_quarter	10956	22.0
founded_year	10884	22.0
first_funding_at	10	0.0
mid_funding_at	8	0.0
last_funding_at	6	0.0
seed	0	0.0
venture	0	0.0
equity_crowdfunding	0	0.0
undisclosed	0	0.0

	Абсолютное значение	Относительное значение
convertible_note	0	0.0
debt_financing	0	0.0
angel	0	0.0
grant	0	0.0
private_equity	0	0.0
post_ipo_equity	0	0.0
post_ipo_debt	0	0.0
secondary_market	0	0.0
product_crowdfunding	0	0.0
round_a	0	0.0
round_b	0	0.0
round_c	0	0.0
round_d	0	0.0
round_e	0	0.0
round_f	0	0.0
round_g	0	0.0
round_h	0	0.0

In [33]:

```
# Абсолютное и относительное количество удалённых строк по всему датафрейму
total_rows_orig = df_invest_orig.shape[0]
total_rows_new = df_invest.shape[0]
deleted_rows_abs = total_rows_orig - total_rows_new
deleted_rows_percent = deleted_rows_abs / total_rows_orig

print(f"АБСОЛЮТНОЕ ЗНАЧЕНИЕ: удалено строк: {deleted_rows_abs}")
print(f"ОТНОСИТЕЛЬНОЕ ЗНАЧЕНИЕ: удалено {deleted_rows_percent:.2%} от исходного количества строк")
```

АБСОЛЮТНОЕ ЗНАЧЕНИЕ: удалено строк: 4856

ОТНОСИТЕЛЬНОЕ ЗНАЧЕНИЕ: удалено 8.94% от исходного количества строк

Для анализа доли удаленных данных была использована копия первоначального датафрейма. В абсолютном выражении, количество удаленных строк составило - 4 856, что в процентном отношении меньше 10% от общего количества.

Оцените полноту данных и сделайте предварительный вывод о том, достаточно ли данных для решения задач проекта. Какой процент данных был отброшен?

Общий вывод:

В результате предобработки данных были выполнены следующие действия:

- Выполнена загрузка и очистка данных: исправлены ошибки в разделителях, удалены лишние пробелы и приведены названия столбцов к единому формату
- Текстовые пропуски обработаны: во всех ключевых категориальных признаках (например, market, status, region, city) NaN и пустые строки заменены осмысленными заглушками unknown
- Даты приведены к типу datetime, что позволяет проводить временной анализ.
- Удалены дубликаты и некорректные строки, приведены к чистому и стандартизированному виду

- Были заполнены пропуски в ключевых финансовых признаках по медианам по группе либо по общему датасету

Оценка полноты данных: После очистки наблюдается высокий уровень заполненности в ключевых полях. Оставшиеся пропуски в отдельных столбцах не должны оказывать критического влияния на основной анализ. Доля пропущенных либо искусственно заполненных значений относительно общего объёма датасета невелика, большинство записей пригодно для разных типов анализа и построения моделей. Процент удалённых строк относительно небольшой – 8,94%.

Данных достаточно для проведения ключевых этапов анализа.

Для глубокого анализа в узких сегментах, может возникнуть нехватка данных, однако в целом структура и полнота набора позволяют достигнуть цели проекта.

Шаг 2. Инжиниринг признаков

2.1. Группы по срокам финансирования

Разделим компании на три группы:

- Единичное финансирование — был всего один раунд финансирования.
- Срок финансирования до года — между первым и последним раундом финансирования прошло не более года.
- Срок финансирования более года.

Визуализируем соотношение этих групп, создав два графика:

- По количеству компаний: Покажите, какой процент от общего числа компаний относится к каждой из трёх групп.
- По объёму инвестиций: Отобразите, какую долю от общего объёма привлечённых средств получила каждая группа.

In [34]:

```
# Расчёт разницы в днях
df_invest['funding_duration_days'] = (df_invest['last_funding_at'] - df_invest['first_

# Создание категории
def funding_category(row):
    if pd.isna(row['funding_duration_days']) or row['funding_duration_days'] == 0:
        return 'Единичное финансирование'
    elif row['funding_duration_days'] <= 365:
        return 'Срок финансирования до года'
    else:
        return 'Срок финансирования более года'

df_invest['funding_group'] = df_invest.apply(funding_category, axis=1)

# Проверка результата
print(df_invest.columns)
display(df_invest.head(10))
```

```
Index(['name', 'homepage_url', 'category_list', 'market', 'funding_total_usd',
      'status', 'country_code', 'state_code', 'region', 'city',
      'funding_rounds', 'participants', 'founded_at', 'founded_month',
      'founded_quarter', 'founded_year', 'first_funding_at', 'mid_funding_at',
      'last_funding_at', 'seed', 'venture', 'equity_crowdfunding',
```

```
'undisclosed', 'convertible_note', 'debt_financing', 'angel', 'grant',
'private_equity', 'post_ipo_equity', 'post_ipo_debt',
'secondary_market', 'product_crowdfunding', 'round_a', 'round_b',
'round_c', 'round_d', 'round_e', 'round_f', 'round_g', 'round_h',
'funding_duration_days', 'funding_group'],
dtype='object')
```

	name	homepage_url	category_list	market	funding_total_usd
0	harvard university	http://harvard.edu	education	education	90000000.0
1	university of new brunswick	http://www.unb.ca	unknown	unknown	2000000.0
2	dupont	http://www.dupont.com	business services agriculture automotive inve...	business services	9000000.0
3	university of michigan	http://www.umich.edu/	education	education	7700000.0
4	case western reserve university	http://www.case.edu	education	education	540000.0
5	xavier university	http://www.xavier.edu/	unknown	unknown	19000000.0
6	tulane university	http://tulane.edu/	education	education	12000000.0
7	duke university	http://www.duke.edu	education	education	8700000.0
8	virginia commonwealth university, richmond	http://www.vcu.edu/	unknown	unknown	6000000.0
9	wegame	http://www.wegame.com	social media	social media	3500000.0

10 rows x 42 columns

Создали дополнительный категориальный столбец `funding_group`, в котором содержится информация о сроках финансирования. Данные разделены на три группы:

Единичное финансирование,

Финансирование до года,

Финансирования более года.

In [35]:

```
# Подсчёт долей компаний и инвестиций
group_counts = df_invest['funding_group'].value_counts(normalize=True).sort_index()
group_funding = df_invest.groupby('funding_group')['funding_total_usd'].sum()
group_funding_percent = group_funding / group_funding.sum()

summary_group = pd.DataFrame({
    'Доля компаний': group_counts.round(2),
    'Объём инвестиций': group_funding_percent
})

# Добавим абсолютный объём инвестиций и количество компаний
```

```
summary_group['Количество компаний'] = (group_counts * len(df_invest)).astype(int)
summary_group['Объём инвестиций'] = group_funding
summary_group = summary_group.loc[['Единичное финансирование', 'Срок финансирования до
display(summary_group)
```

	Доля компаний	Объём инвестиций	Количество компаний
Единичное финансирование	0.65	2.225959e+11	32244
Срок финансирования до года	0.09	4.770846e+10	4586
Срок финансирования более года	0.26	4.047072e+11	12607

Исходя из данных таблицы можно заметить, что больше половины компаний (65%) получили только одно финансирование. Это говорит о том, что значительная доля компаний не проходит дальше первого раунда инвестиций.

Компаний с финансирование более года 26%, но на них приходится почти две трети общего объема инвестиций. Хотя этих компаний меньше, они привлекают более крупные суммы. Это логичная закономерность, устойчивые и перспективные омпании получают больше раундов и больше инвестиций.

Доля компаний, получающих фионсирование до года - 9%, объем инвестиций по ним также меньше, по сравнению с остальными группами. Такие компании вероятно быстрозавершают проекты.

Для наглядности отобразим результат на графике.

In [36]:


```
# Визуализация
palette = sns.color_palette('coolwarm', n_colors=3)
categories = ['Единичное финансирование', 'Срок финансирования до года', 'Срок финанси

plt.figure(figsize=(14, 6))

# График 1: Доля по количеству компаний
plt.subplot(1, 2, 1)
sns.barplot(x=group_counts.index, y=group_counts.values, palette=palette)
plt.title('Доля компаний по группам финансирования')
plt.ylabel('Доля от общего числа')
plt.xlabel('Группа финансирования')
plt.ylim(0, 1)
plt.xticks(rotation=45)

# График 2: Доля по объёму инвестиций
plt.subplot(1, 2, 2)
sns.barplot(x=group_funding_percent.index, y=group_funding_percent.values, palette=pale
plt.title('Доля инвестиций по группам финансирования')
plt.ylabel('Доля от общего объёма инвестиций')
plt.xlabel('Группа финансирования')
plt.ylim(0, 1)
plt.xticks(rotation=45)

plt.tight_layout()
plt.show()
```



Сравнение долей показывает закономерность: чем больше компания финансируется, тем больший объем инвестиций имеет, но большинство стартапов не доходят до этой стадии.

Общий вывод:

Рынок можно назвать текучем, так как большинство компаний ограничиваются одним раундом инвестиций. Основной объем инвестиций сконцентрирован у меньшей доли компаний, финансирование которых превышает год. Это свидетельствует о сосредоточении инвестиций и более зрелых "игроков".

2.2 Выделение средних и нишевых сегментов рынка

Сегмент рынка компаний указан в столбце `market`. Расчитаем, как часто в датасете встречается каждый из сегментов. Сегменты, к которым относится более 120 компаний, отнесите к массовым, сегменты, в которые входит от 35 до 120 включительно, отнесите к средним, а сегменты до 35 компаний отнесите к нишевым. Рассчитайте, сколько сегментов попадает в каждую из категорий.

Построим график распределения количества компаний в сегментах и отобразим на нём разделение на нишевые и средние сегменты.

```
In [37]: # Проверим, сколько всего уникальных сегментов
print("Уникальных значений market:", df_invest['market'].nunique())
```

Уникальных значений market: 440

```
In [38]: # Рассчитайте количество компаний в каждом сегменте рынка
market_counts = df_invest['market'].value_counts().sort_values(ascending=False)

display(market_counts)
```

```
software          5489
unknown           3961
biotechnology     3761
mobile            2725
e-commerce        2283
...
loyalty programs      1
creative              1
nutrition             1
physical security     1
shoes                 1
Name: market, Length: 440, dtype: int64
```

In [39]:

```
# Посчитаем количество компаний в каждом сегменте
market_counts = df_invest['market'].value_counts().reset_index()
market_counts.columns = ['market', 'company_count']

# Исклучим заглушку 'unknown' из анализа
market_counts_real = market_counts[market_counts['market'] != 'unknown']

display(market_counts_real)
```

	market	company_count
0	software	5489
2	biotechnology	3761
3	mobile	2725
4	e-commerce	2283
5	curated web	2088
...	...	...
435	distributors	1
436	natural language processing	1
437	face recognition	1
438	visualization	1
439	shoes	1

439 rows x 2 columns

In [40]:

```
# Классифицируем сегменты
def classify_segment(x):
    if x > 120:
        return 'Массовый'
    elif 35 <= x <= 120:
        return 'Средний'
    else:
        return 'Нишевый'

# Создаем копию
market_counts_real = market_counts_real.copy()

# Добавляем столбец с типом сегмента
market_counts_real.loc[:, 'segment_type'] = market_counts_real['company_count'].apply(classify_segment)

# Сколько сегментов в каждой категории
segment_summary = (
    market_counts_real['segment_type']
    .value_counts()
    .rename_axis('Тип сегмента')
    .reset_index(name='Количество сегментов')
)

display(segment_summary)

# Проверим первые строки
display(market_counts_real.head(10))
```

	Тип сегмента	Количество сегментов
0	Нишевый	334

	Тип сегмента	Количество сегментов
1	Массовый	53
2	Средний	52

	market	company_count	segment_type
0	software	5489	Массовый
2	biotechnology	3761	Массовый
3	mobile	2725	Массовый
4	e-commerce	2283	Массовый
5	curated web	2088	Массовый
6	enterprise software	1557	Массовый
7	games	1374	Массовый
8	clean technology	1324	Массовый
9	health care	1294	Массовый
10	advertising	1276	Массовый

Из выборки были исключены компании, содержащие в столбце market заглушки, их количество составляет 3 961. Это необходимо, чтобы не исказить распределение по реальным сегментам

Отметим большое количество нишевых сегментов, что отражает ситуация со стартапами, работающими в узких направлениях. Хотя массовые направления встречаются реже, они концентрируют наибольшее количество компаний, а предположительно основной объем инвестиций


In [41]:

```
# График распределения компаний по сегментам
```

```
plt.figure(figsize=(12, 6))
sns.histplot(data=market_counts_real, x='company_count', bins=50, color='#b0c8db', edgecolor='black')
plt.axvline(35, color='#5c7ece', linestyle='--', label='Нишевые (до 35)')
plt.axvline(120, color='#de5640', linestyle='--', label='Средние (35-120)')
plt.title('Распределение количества компаний по сегментам рынка')
plt.xlabel('Количество компаний в сегменте')
plt.ylabel('Число сегментов')
plt.legend()

plt.xlim(0, 150) # Ограничиваем ось x от 0 до 150

plt.show()
```




Большое количество сегментов рынка содержат до 35 компаний — это видно по большому столбцу слева и минимальному числу сегментов, выходящих за эту границу. Средние сегменты встречаются реже — правее синей пунктирной и левее красной линии лишь единичные случаи. Массовых сегментов практически нет на выбранном интервале — срез оси до 150 хорошо показывает, что абсолютное большинство остаётся в области нишевых и средних

Такое распределение может говорить о дробности структуры рынка и потенциале для развития внутри большинства ниш.

In [42]:

```
# Точечная диаграмма
plt.figure(figsize=(10, 6))
sns.stripplot(
    data=market_counts_real,
    x='segment_type',
    y='company_count',
    jitter=True,
    palette={'Массовый': '#b0c8db', 'Средний': '#de5640', 'Нишевый': '#5c7ece', 'Unknown': '#f0f0f0'},
    alpha=0.5,
    size=6
)
plt.title('Точечная диаграмма: размер сегмента по типу')
plt.xlabel('Тип сегмента')
plt.ylabel('Количество компаний в сегменте')
plt.tight_layout()
plt.show()
```



- Основная масса сегментов сосредоточена в близких к нулю значениях. Это говорит о том, что в большинстве сегментов встречается редкие направления с 1-2 компаниями.
- Доля массовых сегментов, с большим количеством компаний, небольшая на фоне общего распределения. Эту ситуацию можно объяснить тем, что массовые сегменты редко встречаются в стартапах, где рынок диверсифицирован по уникальным направлениям
- На графике мы видим длиннохвостое распределение, очень большое количество сегментов с маленьким размером и небольшая часть с существенным количеством компаний

Оставим в столбце `market` только массовые сегменты. Для остальных сегментов заменим значения на заглушки — `niche` для нишевых и `mid` для средних.

In [43]:

```
# Подготовим словарь классификации сегментов для подстановки
segment_map = market_counts_real.set_index('market')['segment_type'].to_dict()

# Создаём копию основного датафрейма и заменяем значения
df_invest = df_invest.copy()

def replace_market(value):
    if value not in segment_map:
        return 'unknown' # для заглушек
    seg_type = segment_map[value]
    if seg_type == 'Массовый':
        return value
    elif seg_type == 'Средний':
        return 'mid'
    else:
        return 'niche'

df_invest['market'] = df_invest['market'].apply(replace_market)
display(df_invest.head(10))
```

	name	homepage_url	category_list	market	funding_total_usd
0	harvard university	http://harvard.edu	education	education	90000000.0
1	university of new brunswick	http://www.unb.ca	unknown	unknown	2000000.0
2	dupont	http://www.dupont.com	business services agriculture automotive inve...	mid	9000000.0
3	university of michigan	http://www.umich.edu/	education	education	7700000.0
4	case western reserve university	http://www.case.edu	education	education	540000.0
5	xavier university	http://www.xavier.edu/	unknown	unknown	19000000.0
6	tulane university	http://tulane.edu/	education	education	12000000.0
7	duke university	http://www.duke.edu	education	education	8700000.0
8	virginia commonwealth university, richmond	http://www.vcu.edu/	unknown	unknown	6000000.0
9	wegame	http://www.wegame.com	social media	social media	3500000.0

10 rows x 42 columns

In [44]:

```
print(df_invest['market'].value_counts().head(15))
print("\nКоличество уникальных значений после объединения:", df_invest['market'].nunique())
```

```
software          5489
mid               3970
unknown          3961
biotechnology     3761
mobile           2725
e-commerce       2283
curated web      2088
enterprise software 1557
games            1374
clean technology  1324
health care      1294
advertising      1276
social media     1173
hardware + software 1155
niche            1097
Name: market, dtype: int64
```

Количество уникальных значений после объединения: 56

После группировки по уникальным значениям, количество сегментов насчитывает 56. Отметим, что сегменты средних и нишевых компаний укрупнены в группы, также отдельно посчитаны заглышки, чтобы не исказить результат.

Отобран топ-15 сегментов по количеству компаний. Наибольшая концентрация наблюдается в сегменте программного обеспечения - 5489. Это может говорить о низком пороге входа на рынок и стабильном интересе инвесторов. Лидирующие позиции занимают biotechnology и mobile, что отражает тренд на развитие инноваций в области медицины и мобильных технологий. Подтверждением этого тренда являются и сегменты e-commerce и curated web, находящиеся в топе.

Отообразим результаты на графике.

In [45]:

```
segment_counts = df_invest['market'].value_counts()
top_n = 15
top_segments = segment_counts.head(top_n)


# Палитра цветов
palette = {
    'mid': '#de5640',
    'niche': '#ec8b5b',
    'unknown': '#5c7ece',
}

# Определим, где начинается каждая категория
# Для этого определим позиции (индексы) сегментов, которые принадлежат к каждой группе
massive_segments = [s for s in top_segments.index if s not in ['mid', 'niche', 'unknown']]
mid_index = top_segments.index.get_loc('mid') if 'mid' in top_segments.index else None
niche_index = top_segments.index.get_loc('niche') if 'niche' in top_segments.index else None

# Построение графика
plt.figure(figsize=(9, 10))
sns.barplot(
    y=top_segments.index,
    x=top_segments.values,
    palette=[palette.get(x, '#d6dee5') for x in top_segments.index]
)

plt.title(f'Топ-{top_n} сегментов рынка с разделением на категории', fontsize=14)
plt.xlabel('Количество компаний', fontsize=12)
plt.ylabel('Сегмент рынка', fontsize=12)

plt.show()
```



После объединения средних и нишевых направлений в общие группы, структура данных стала компактнее, агрегированные группы покажут обобщенные тенденции.

Соотношение типов сегментов говорит о структуре рынка: наибольшее сосредоточение компаний, вероятно и наибольший объем инвестиций находится в массовых сегментах, вроде ИТ и биотехнологий. Однако направления средних компаний тоже занимает значительную долю после укрупнения.

Общий вывод

При большом числе нишевых направлений, основная предпринимательская активность сосредоточена в нескольких массовых сегментах. Это указывает на зрелость ИТ сегмента, биотехнологий и мобильных коммуникаций, а также интерес к данным сферам.


Шаг 3. Работа с выбросами и анализ

3.1. Анализируем и помечаем выбросы в каждом из сегментов

По предобработанному столбцу `funding_total_usd` графическим образом оценим, какой размер общего финансирования для одной компании будет типичным, а какой — выбивающимся. Укажем интервал, в котором лежат типичные значения.

In [46]:

```
plt.figure(figsize=(12, 5))
sns.boxplot(x=df_invest['funding_total_usd'], color='#5c7ece')
plt.xscale('log')
plt.xlim(10**3, 10**9) # ограничим диапазон до 1 млрд USD
plt.title('Распределение общего финансирования компаний (Boxplot, лог шкала)')
plt.xlabel('Объём финансирования, USD (лог)')
plt.show()
```



Наше распределение имеет значительную вариацию: от тысяч до миллиардов долларов, чтобы ящик с усами выглядел показательно, использована логарифмическая шкала по оси X.

На графике мы видим длинный правый хвост, выбросы значительно превышают медиану, это указывает, что в распределении есть отдельные компании с очень большим объемом финансирования. Разпрос сильно увеличивается справа, что характерно для финансирования стартапов. Типичные значения лежат в коробке, это "норма" рынка, далее будем рассматривать именно эту часть выборки.

Общий вывод:

Распределение финансирования по компаниям сильно неравномерно, рынок характеризуется большинством компаний с небольшими суммами финансирования и меньшим количеством крупных игроков, привлекающим огромные суммы.

Такая структура распределения типична для венчурного рынка, где финансирование концентрируется на малом числе стартапов с высоким ростом, в то время как большая часть получит минимальные средства и ограничивается одним раундом инвестиций.

In [47]:

```
# Проверим данные
print(df_invest['market'].unique()[:10])

print(df_invest['funding_total_usd'].describe())
```

```
['education' 'unknown' 'mid' 'social media' 'hardware + software'
 'biotechnology' 'niche' 'hospitality' 'enterprise software'
 'manufacturing']
count      4.943800e+04
mean       1.365370e+07
std        1.536148e+08
min        1.000000e+00
25%        4.092990e+05
```

50% 1.890000e+06
75% 7.196369e+06
max 3.007950e+10
Name: funding_total_usd, dtype: float64

In [48]:

```
# Посмотрим типичные значения для каждого сегмента
```

```
segment_stats = df_invest.groupby('market')['funding_total_usd'].describe()  
display(segment_stats)
```

	count	mean	std	min	25%	50%	75%	
market								
advertising	1276.0	1.194733e+07	4.063520e+07	1000.0	723937.50	3181739.0	10000000.00	1.7
analytics	760.0	1.271819e+07	5.832305e+07	10000.0	600000.00	3400000.0	9362500.00	1.7
apps	282.0	2.285473e+06	5.560694e+06	7500.0	120000.00	500000.0	1475000.00	5.0
automotive	204.0	1.943991e+07	1.170119e+08	500.0	514765.25	3135060.0	6654625.00	1.4
big data	166.0	1.005630e+07	2.615099e+07	11700.0	326250.00	2000000.0	5975000.00	2.0
biotechnology	3761.0	2.041725e+07	5.532878e+07	1000.0	1584998.00	5400000.0	20500000.00	2.4
clean technology	1324.0	3.519059e+07	9.793073e+07	3000.0	1894766.00	7500000.0	24000000.00	1.2
cloud computing	170.0	1.057605e+07	2.413516e+07	10000.0	600000.00	1860000.0	9347265.50	2.0
consulting	525.0	6.411120e+06	2.168662e+07	100.0	388349.00	1890000.0	3000000.00	3.9
curated web	2088.0	6.082052e+06	2.682355e+07	1000.0	300000.00	1217500.0	3456152.00	7.6
design	164.0	1.189763e+07	5.759397e+07	1.0	230035.00	790831.5	2974331.50	5.4
e-commerce	2283.0	1.178119e+07	5.362402e+07	100.0	341250.00	1653598.0	4500000.00	1.0
education	1026.0	7.227887e+06	3.465126e+07	890.0	265016.00	1200000.0	3215987.75	7.5
enterprise software	1557.0	1.539582e+07	6.638205e+07	5000.0	1290008.00	5070000.0	13000000.00	2.0
entertainment	243.0	9.667540e+06	3.997770e+07	317.0	50000.00	360000.0	2250000.00	5.0
fashion	425.0	1.000085e+07	3.704789e+07	30.0	500000.00	2200000.0	3750000.00	4.0
finance	1007.0	2.135763e+07	1.884802e+08	1000.0	685000.00	4663524.0	10000000.00	5.8
financial services	132.0	1.261206e+07	6.441133e+07	7500.0	493750.00	1800000.0	5760173.00	7.2
games	1374.0	8.830061e+06	3.360586e+07	100.0	493383.25	2000000.0	5572500.00	5.8
hardware + software	1155.0	1.263433e+07	4.149506e+07	1100.0	883229.50	3145348.5	10405647.00	1.7
health and wellness	992.0	1.343238e+07	9.157510e+07	3750.0	477744.50	1800000.0	6041750.00	2.6
health care	1294.0	2.592005e+07	6.769325e+07	5000.0	1500000.00	6703000.0	24267500.00	1.5
hospitality	502.0	1.392032e+07	6.999985e+07	500.0	473205.00	2000000.0	3075500.00	8.0
internet	298.0	3.242984e+07	3.367067e+08	2500.0	400000.00	1000000.0	3175000.00	5.7
manufacturing	787.0	1.314495e+07	6.213373e+07	4900.0	1245096.50	3232637.5	9975001.00	1.5
marketplaces	235.0	4.168681e+06	1.362066e+07	60.0	118958.00	425000.0	1612950.00	1.0
media	125.0	4.397451e+06	8.853868e+06	19252.0	300000.00	1400000.0	4000000.00	5.8
medical	281.0	6.539698e+06	2.576263e+07	100.0	110000.00	110000.0	2121849.00	3.3

	count	mean	std	min	25%	50%	75%	
market								
medical devices	122.0	2.005351e+07	3.853227e+07	20000.0	1000000.00	3000000.0	14875000.00	2.5
messaging	346.0	8.877337e+06	2.949972e+07	10000.0	631370.00	2000000.0	5400000.00	3.6
mid	3970.0	1.376785e+07	9.119104e+07	929.0	300000.00	1300000.0	6000000.00	3.5
mobile	2725.0	2.088147e+07	5.769378e+08	291.0	475000.00	2000000.0	6000000.00	3.0
music	328.0	9.523782e+06	6.103768e+07	1000.0	274613.25	1224985.0	3000000.00	1.0
networking	201.0	1.423070e+07	7.201416e+07	1000.0	400000.00	700000.0	6000000.00	7.4
news	403.0	9.576112e+06	5.681626e+07	1000.0	176770.00	1352569.0	3600000.00	1.0
niche	1097.0	1.437946e+07	7.469716e+07	100.0	200000.00	1219000.0	4400000.00	1.4
nonprofits	150.0	5.375450e+06	1.798137e+07	3000.0	250000.00	993500.0	3400000.00	1.5
photography	253.0	1.151864e+07	5.641950e+07	1000.0	250000.00	1500000.0	3200000.00	7.0
public relations	181.0	9.511983e+06	3.353087e+07	3000.0	600000.00	4476231.0	5268664.00	3.2
real estate	434.0	1.113771e+07	4.735941e+07	1000.0	500000.00	2000000.0	2687500.00	6.0
saas	333.0	8.654188e+06	3.671526e+07	6000.0	350000.00	1000000.0	3250000.00	5.6
sales and marketing	134.0	4.441438e+06	1.101809e+07	118.0	138750.00	667875.0	3100000.00	6.2
search	356.0	9.444478e+06	3.319094e+07	1000.0	447183.00	1549831.0	3621118.50	4.4
security	626.0	1.659071e+07	5.147768e+07	10000.0	1201162.50	6000000.0	13200000.00	8.0
semiconductors	522.0	2.504172e+07	3.888414e+07	35000.0	4927113.50	12498182.0	29508247.00	4.2
social media	1173.0	6.926536e+06	7.373162e+07	1000.0	161160.00	800000.0	2100000.00	2.4
social network media	187.0	3.217758e+06	8.590300e+06	10000.0	191250.00	669283.0	2048550.00	9.0
software	5489.0	9.817264e+06	3.579175e+07	22.0	588384.00	2312944.0	7100000.00	1.0
sports	278.0	5.955037e+06	4.235287e+07	400.0	200000.00	450000.0	2000000.00	6.0
startups	158.0	2.483317e+06	6.372800e+06	1000.0	127944.75	570966.0	1593051.75	4.9
technology	273.0	3.775718e+07	1.202963e+08	2000.0	675000.00	2654250.0	20000000.00	1.3
transportation	174.0	2.237061e+07	1.251962e+08	100.0	208395.50	208395.5	2663750.00	1.5
travel	413.0	1.149871e+07	5.073581e+07	2500.0	325000.00	1600000.0	4371960.00	7.9
unknown	3961.0	6.603742e+06	1.012260e+08	14.0	200000.00	409299.0	841046.00	5.0
video	234.0	1.076022e+07	4.214976e+07	10000.0	775000.00	1720131.5	6075000.00	5.9
web hosting	481.0	2.715372e+07	8.065212e+07	3766.0	1998990.00	8204976.0	22100000.00	1.0

In [49]:

```
# Функция для выявления выбросов методом IQR
def detect_outliers_iqr(data, column):
    """Возвращает Series с True, если значение является выбросом по IQR."""
    Q1 = data[column].quantile(0.25)
    Q3 = data[column].quantile(0.75)
    IQR = Q3 - Q1
    lower = Q1 - 1.5 * IQR
    upper = Q3 + 1.5 * IQR
    return (data[column] < lower) | (data[column] > upper)

# Добавим столбец с отметкой выбросов
```

```
df_invest['outlier_IQR'] = False

for seg in df_invest['market'].unique():
    seg_mask = df_invest['market'] == seg
    df_invest.loc[seg_mask, 'outlier_IQR'] = detect_outliers_iqr(df_invest[seg_mask],

display(df_invest.head(5))
```

	name	homepage_url	category_list	market	funding_total_usd	sta
0	harvard university	http://harvard.edu	education	education	90000000.0	opera
1	university of new brunswick	http://www.unb.ca	unknown	unknown	2000000.0	opera
2	dupont	http://www.dupont.com	business services agriculture automotive inve...	mid	9000000.0	opera
3	university of michigan	http://www.umich.edu/	education	education	7700000.0	opera
4	case western reserve university	http://www.case.edu	education	education	540000.0	opera

5 rows x 43 columns

In [50]:


```
# Рассчитаем долю выбросов по сегментам
outlier_share = (
    df_invest.groupby('market')['outlier_IQR']
    .mean()
    .sort_values(ascending=False)
    .reset_index()
)
outlier_share.columns = ['market', 'share_outliers']

# Определим топ-10 сегментов с наибольшей долей аномального финансирования
top_outlier_segments = outlier_share.head(10)
display(top_outlier_segments)
```

	market	share_outliers
0	transportation	0.189655
1	medical devices	0.180328
2	unknown	0.177228
3	hospitality	0.175299
4	fashion	0.174118
5	entertainment	0.172840
6	video	0.170940
7	medical	0.170819
8	internet	0.167785
9	travel	0.167070

In [51]:

```
# Визуализируем
plt.figure(figsize=(10,6))
plt.barh(top_outlier_segments['market'], top_outlier_segments['share_outliers'], color='blue')
plt.xlabel('Доля компаний с аномальным финансированием')
plt.ylabel('Сегмент рынка')
plt.title('Топ-10 сегментов с наибольшей долей аномального финансирования')
plt.gca().invert_yaxis()
plt.show()
```



Наибольшие доли аномальных компаний зафиксированы в сегментах: transportation и medical devices. Это значит, что в сегментах относительно часто встречаются компании с финансированием, отличающимся от типичных значений.

Высокая доля аномалий может свидетельствовать о большой неопределенности в сегментах. Некоторые компании получают значительно больше или меньше финансирования, чем остальные.

В сегментах с максимальной долей аномалий инвесторы с высокой вероятностью столкнутся с вариативностью исходов: можно как заработать на сверхдоходных инвестициях, так и прогореть из-за непредсказуемости рынка.

In [52]:

```
# Типичные значения
typical_values = (
    df_invest.groupby('market')['funding_total_usd']
    .describe()[['25%', '50%', '75%']]
    .rename(columns={'50%': 'median'})
)
display(typical_values.head(10))
```

	25%	median	75%
market			
advertising	723937.50	3181739.0	10000000.0
analytics	600000.00	3400000.0	9362500.0

	25%	median	75%
market			
apps	120000.00	500000.0	1475000.0
automotive	514765.25	3135060.0	6654625.0
big data	326250.00	2000000.0	5975000.0
biotechnology	1584998.00	5400000.0	20500000.0
clean technology	1894766.00	7500000.0	24000000.0
cloud computing	600000.00	1860000.0	9347265.5
consulting	388349.00	1890000.0	3000000.0
curated web	300000.00	1217500.0	3456152.0

Выводы, которые можно сделать на основании данных таблицы


- Типичные значения
 - Большинство сегментов имеют медианные значения финансирования до 5 млн долл.
 - Самые высокие медианы наблюдаются в сегментах: clean technology (7,5 млн долл) и biotechnology (5,4 млн долл.). Эти отрасли требуют больших вложений для разработок, что отражается в больших инвестициях.
- Диапазон типичных значений (Q1–Q3)
 - Наибольший разброс типичных значений у clean technology и biotechnology — до десятков миллионов долларов, что говорит о высокой неоднородности компаний внутри этих сегментов
 - Более устойчивые сегменты с узким диапазоном — apps, curated web, где компании похожи по уровню привлечённых средств.

In [53]:

```
# Отберём 10 самых популярных сегментов
top_markets = (
    df_invest['market'].value_counts()
    .head(10)
    .index
)
# Подготовим данные
top_data = df_invest[df_invest['market'].isin(top_markets)]
```

In [54]:

```
# Визуализация boxplot по объёму финансирования
plt.figure(figsize=(12, 6))
plt.boxplot(
    [top_data[top_data['market'] == m]['funding_total_usd'].dropna() for m in top_markets],
    labels=top_markets,
    showfliers=False, # без выбросов
)
plt.xticks(rotation=45)
plt.title('Типичные диапазоны финансирования по сегментам (Q1–Q3)')
plt.ylabel('Объём финансирования, USD')
plt.grid(axis='y', linestyle='--', alpha=0.7)
plt.show()
```



Boxplot показывает значительное количество выбросов справа почти во всех сегментах — особенно у biotechnology и clean technology. Это указывает, что в этих отраслях встречаются компании, получившие исключительно крупное финансирование, сильно выделяющееся на фоне типичных значений.

Рынок стартапов очень неоднородный, цифровые компании требуют меньше ресурсов, а проекты с научной и производственной базой затрачивают гораздо больше инвестиций.

In [55]:

```
# Визуализация медианных значений
plt.figure(figsize=(12, 6))
plt.bar(top_markets, typical_values.loc[top_markets, 'median'], color='#5c7ece')
plt.xticks(rotation=45)
plt.title('Медианные значения объёмов финансирования по сегментам')
plt.ylabel('Медианный объём финансирования, USD')
plt.grid(axis='y', linestyle='--', alpha=0.7)
plt.show()
```



Основные наблюдения исходя из графика:

- Лидеры по медианному объёму финансирования — это сегменты clean technology и biotechnology. Для них медианные, что говорит о значительных инвестициях именно в эти отрасли.
- Высокие медианные значения также у enterprise software и games, что показывает привлекательность этих сегментов для вложений.
- Сегменты real, curated web характеризуются наименьшими медианами. Это свидетельствует о минимальных суммах финансирования для компаний в этих областях.

Сравнение медианных значений помогает выделить “дорогие” и “массовые” ниши рынка и использовать эту информацию для приоритезации инвестиционной стратегии.

Если цель — максимизировать капитализацию стоит обратить внимание на сегменты clean technology, biotechnology и enterprise software, где средние суммы финансирования заметно превосходят остальные отрасли. Оставшиеся сегменты могут быть более привлекательны для малых и средних сделок, либо для стратегий, ориентированных на широкий портфель.

Общий вывод:

Анализ аномалий позволяет расставить приоритеты, опираясь на индивидуальный риск-профиль в каждом сегменте, а сравнение медианных значений помогает выделить “дорогие” и “массовые” ниши рынка и использовать эту информацию для приоритезации инвестиционной стратегии.

Если цель — максимизировать капитализацию стоит обратить внимание на сегменты clean technology, biotechnology и enterprise software, где средние суммы финансирования заметно превосходят остальные отрасли. Оставшиеся сегменты могут быть более привлекательны для малых и средних сделок, либо для стратегий, ориентированных на широкий портфель.

3.2 Определяем границы рассматриваемого периода, отбрасываем аномалии

Проверим полноту данных за 2014 год. Затем исключим из датасета компании, которые ранее получили аномальное финансирование.

После исключения аномальных записей, на основе столбцов `mid_funding_at` и `funding_rounds` оставим в датасете данные только об определённых компаниях. Они должны были получать финансирование в годы, когда было зафиксировано 50 или более раундов финансирования.

In [56]:

```
# Проверим распределение по годам – сколько записей есть за каждый год
years = df_invest['mid_funding_at'].dt.year.value_counts().sort_index()

display(years)
```

```
1921.0    1
1960.0    3
1973.0    1
1974.0    2
1979.0    1
1982.0    3
1983.0    1
1984.0    5
1985.0    5
1986.0    4
1987.0    6
1988.0    2
1989.0    4
1990.0   12
1991.0    9
1992.0   12
1993.0   14
1994.0   12
1995.0   18
1996.0   24
1997.0   20
1998.0   45
1999.0   93
2000.0  148
2001.0   91
2002.0  111
2003.0  131
2004.0  205
2005.0  917
2006.0 1595
2007.0 2413
2008.0 2990
2009.0 3680
2010.0 4685
2011.0 5935
2012.0 7470
2013.0 10256
2014.0  8506
Name: mid_funding_at, dtype: int64
```

Данные позволяют оценить распределение по годам, подробнее рассмотрим 2014 г. в разрезе месяцев.

In [57]:

```
# Посмотрим, сколько записей за 2014 год
print(f"Количество записей за 2014 год: {years.get(2014, 0)}")

# Проверим, есть ли данные за все месяцы 2014 года
months_2014 = (
    df_invest[df_invest['mid_funding_at'].dt.year == 2014]
    ['mid_funding_at'].dt.month.value_counts().sort_index()
)
display(months_2014)
```

Количество записей за 2014 год: 8506

```
1    1013
2     750
3     829
4     818
5     774
6     932
7     874
8     774
9     699
10    651
11    362
12     30
```

Name: mid_funding_at, dtype: int64

Исходя из полученных данных, можно сделать вывод, что данные за 2014 г. полные, отсутствуют "пустые" месяцы.

```
In [58]: # Минимальная и максимальная даты в 2014 году – чтобы окончательно убедиться, что охва
dates_2014 = df_invest[df_invest['mid_funding_at'].dt.year == 2014]['mid_funding_at']
print(f"Минимальная дата: {dates_2014.min()}")
print(f"Максимальная дата: {dates_2014.max()}")
```

Минимальная дата: 2014-01-01 00:00:00

Максимальная дата: 2014-12-31 00:00:00

```
In [59]: df_outliers = df_invest[df_invest['outlier_IQR'] == True]

# Исключаем аномальные компании
df_clean = df_invest[~df_invest['name'].isin(df_outliers['name'])]
print(f"Размер исходного датасета: {df_invest.shape[0]}")
print(f"Размер после удаления аномалий: {df_clean.shape[0]}")
```

Размер исходного датасета: 49438

Размер после удаления аномалий: 42496

После очистки выбросов, размер данных составляет - 42 496 строк.

```
In [60]: # Группируем по годам и считаем количество раундов
rounds_by_year = df_clean.groupby(df_clean['mid_funding_at'].dt.year)['funding_rounds']

# Выбираем только годы, где было 50 и более раундов
active_years = rounds_by_year[rounds_by_year >= 50].index
print("Годы, в которых ≥50 раундов финансирования:", list(active_years))

# Оставляем только компании, получавшие финансирование в эти годы
df_final = df_clean[df_clean['mid_funding_at'].dt.year.isin(active_years)]
print(f"Размер датасета после фильтрации по активным годам: {df_final.shape[0]}")

display(df_final.head(10))
```

Годы, в которых ≥50 раундов финансирования: [1999.0, 2000.0, 2001.0, 2002.0, 2003.0, 2004.0, 2005.0, 2006.0, 2007.0, 2008.0, 2009.0, 2010.0, 2011.0, 2012.0, 2013.0, 2014.0]

Размер датасета после фильтрации по активным годам: 42299

	name	homepage_url	category_list	market	funding_total
2	dupont	http://www.dupont.com	business services agriculture automotive inve...	mid	9000
4	case western reserve university	http://www.case.edu	education	education	5400
9	wegame	http://www.wegame.com	social media	social media	3500

	name	homepage_url	category_list	market	funding_tot
11	mayne pharma	http://www.maynepharma.com	biotechnology	biotechnology	2705
12	siemens	http://www.siemens.com	clean energy automotive hardware + software	hardware + software	8900
13	university of rochester	http://www.rochester.edu	unknown	unknown	405
16	michigan state university	http://msu.edu	education universities	education	3900
19	laclede group	http://www.thelacledegrou.com	utilities	niche	3800
21	lsu, baton rouge	http://lsu.edu	education	education	2000
22	watkins hire	http://watkinshire.co.uk	enterprise software	enterprise software	15300

10 rows × 43 columns

Результат после выполнения всех шагов:

1. Проверено, что данные за 2014 год полные, информация присутствует по каждому месяцу
2. Аномальные компании исключены.
3. Оставлены только годы с достаточным числом наблюдений, а именно более 50 раундов.
Получившийся диапазон дат: 1999-2014 гг.
4. Получен финальный очищенный датасет `df_final`, пригодный для дальнейшего анализа структуры и динамики инвестиций.

3.3. Анализ типов финансирования по объёму и популярности

Построим график, который покажет, какие типы финансирования в сумме привлекли больше всего денег. Будем ориентироваться на значения в столбцах `seed`, `venture`, `equity_crowdfunding`, `undisclosed`, `convertible_note`, `debt_financing`, `angel`, `grant`, `private_equity`, `post_ipo_equity`, `post_ipo_debt`, `secondary_market` и `product_crowdfunding`.

Также построим график, который покажет популярность разных типов финансирования — какие типы финансирования чаще всего используются компаниями, то есть встречаются в датасете наибольшее количество раз.

Сравним графики и выделим часто используемые типы финансирования, которые при этом характеризуются небольшими объёмами, и наоборот — те, что встречаются редко, но при этом характеризуются значительным объёмом предоставленных сумм.

In [61]:

```
# Список столбцов с типами финансирования
funding_types = [
    'seed', 'venture', 'equity_crowdfunding', 'undisclosed',
    'convertible_note', 'debt_financing', 'angel', 'grant',
    'private_equity', 'post_ipo_equity', 'post_ipo_debt',
    'secondary_market', 'product_crowdfunding'
```

```

]

# Суммарный объём инвестиций по каждому типу
funding_sums = df_final[funding_types].sum().sort_values(ascending=False)

# Популярность (сколько компаний имело ненулевое значение)
funding_counts = (df_final[funding_types] > 0).sum().sort_values(ascending=False)

# Объединим в один DataFrame
funding_summary = pd.DataFrame({
    'total_usd': funding_sums,
    'company_count': funding_counts
}).sort_values('total_usd', ascending=False)

# Добавим подписи с типами финансирования
funding_summary.reset_index(inplace=True)
funding_summary.rename(columns={'index': 'funding_type'}, inplace=True)

display(funding_summary)

```

	funding_type	total_usd	company_count
0	venture	1.086809e+11	17514
1	seed	8.976399e+09	13152
2	debt_financing	7.262982e+09	3094
3	private_equity	3.818493e+09	565
4	angel	2.278402e+09	2873
5	grant	1.670441e+09	967
6	undisclosed	1.653620e+09	765
7	post_ipo_equity	1.495505e+09	144
8	convertible_note	5.040403e+08	505
9	post_ipo_debt	2.267183e+08	25
10	equity_crowdfunding	2.094566e+08	510
11	product_crowdfunding	1.659131e+08	199
12	secondary_market	4.507580e+07	6

Основываясь на данных таблицы отметим, что самый популярный по сумме и числу компаний тип финансирования - венчурное. Этот тип абсолютно доминирует по обоим показателям.

Второе и третье места занимают посевное (seed) и заемное (debt_financing) финансирование.

Среди "второстепенных" форматов встречаются private_equity, angel и grant, последующие типы занимают значительно меньшие доли по объемам финансирования и числу компаний.

Визуализируем отдельно типы финансирования по объемам инвестиций и количеству компаний.

In [62]:

```



plt.figure(figsize=(14,6))

# График 1 – общий объём инвестиций
plt.subplot(1,2,1)
funding_sums.plot(kind='bar', color='#86a7d4')
plt.title('Суммарные объёмы инвестиций по типам финансирования')
plt.ylabel('Общий объём, USD')
plt.xticks(rotation=70)

```

```
# График 2 – популярность типов финансирования
plt.subplot(1,2,2)
funding_counts.plot(kind='bar', color='#de5640')
plt.title('Популярность типов финансирования (количество компаний)')
plt.ylabel('Количество компаний')
plt.xticks(rotation=70)

plt.tight_layout()
plt.show()
```



Венчурное и посевное финансирование – базовые пути привлечения средств для стартапов и молодых компаний, здесь основной поток проектов и средств.

Долговое финансирование и бизнес-ангелы также играют значительную роль, хоть и более нишевую.

Прочие инструменты используются либо отдельными компаниями, либо специализируются на редких сценариях (выкупы, гранты, секьюритизация)


In [63]:

```
# Построим график
plt.figure(figsize=(10,6))
sns.scatterplot(
    data=funding_summary,
    x='company_count', y='total_usd',
    s=200, color='#de5640'
)

# Подписи к точкам
for i in range(len(funding_summary)):
    plt.text(
        funding_summary['company_count'][i] + 50,
        funding_summary['total_usd'][i],
        funding_summary['funding_type'][i],
        fontsize=9
    )

plt.title('Объём инвестиций vs популярность типов финансирования')
plt.xlabel('Количество компаний (популярность)')
plt.ylabel('Общий объём инвестиций, USD')
plt.xscale('log')
plt.yscale('log')

plt.tight_layout()
plt.show()
```



Визуализация, совмещающая объем инвестиций и число компаний позволяет сделать дополнительные выводы о структуре рынка финансирования.

Если разделить типы финансирования на категории, получем следующую градацию:

- venture. Этот тип финансирования доминирует в разных направлениях, это подтверждает лидерство венчурного капитала как главной точки притяжения средств и стартапов в рынке
- seed и debt_financing. Вторая категория с большим числом компаний, однако по суммарному объему они уступают. Это свидетельствует тому, что посевное и долговое финансирование часто привлекается малыми суммами или короткими раундами.
- private_equity и angel. Следующая категория имеет довольно умеренные объемы инвестиций, но встречается у большего количества компаний, чем сугубо нишевые инструменты
- Прочие типы (crowdfunding, secondary_market и др.). Прочие типы располагаются в левом нижнем углу: и число компаний и общие объемы средств здесь минимальны. Данные типы остаются очень редкими по сравнению с массовыми подходами

Общий вывод:

Таким образом, можно сделать вывод, что структуру рынка определяют несколько классических типов финансирования. Это ценно при принятии решений о запуске нового стартапа или выборе инвестиционной стратегии.

Построим график суммарных объёмов возвратов от разных типов финансирования за весь период на основе дополнительного датасета.

In [64]:

```
# Суммарные объёмы возвратов за весь период
returns_sum = df_returns[funding_types].sum().sort_values(ascending=False)

# Для таблицы с данными
returns_sum_df = returns_sum.reset_index()
returns_sum_df.columns = ['Тип финансирования', 'Суммарный объём возвратов (USD)']
display(returns_sum_df)
```

	Тип финансирования	Суммарный объем возвратов (USD)
0	venture	40578.62
1	debt_financing	4734.85
2	private_equity	3587.33
3	seed	2382.24
4	angel	1509.23
5	post_ipo_equity	1104.96
6	undisclosed	730.88
7	post_ipo_debt	91.03
8	convertible_note	34.79
9	secondary_market	5.20
10	equity_crowdfunding	3.83
11	product_crowdfunding	1.86
12	grant	0.00

Как и с объемами инвестиций, венчурное финансирование занимает лидирующую позицию по возвратам - 40 578 дол. Это в разы больше, чем у других типов, что оправдано его главенствующей позиции по количеству компаний и объемам финансирования.

Заемное финансирование и частный капитал на втором и третьем месте. Их суммарная доля значительно меньше возвратов по венчурному финансированию, однако также отражает их значимость для возврата инвестиций.

Посевное финансирование и бизнес-ангелы также дают значительные возвраты, но масштаб их значительно меньше.

Отсальные типы показывают почти нулевые возвраты по сравнению с лидерами.

Форматы с самыми большими возвратами полностью совпадают с лидерами по объемам финансирования и количеству компаний, получается возвратная активность идет вслед за массовыми инвестициями.

In [65]:

```
# Построим график
plt.figure(figsize=(10,6))
returns_sum.plot(kind='bar', color='#86a7d4')

plt.title('Суммарные объёмы возвратов по типам финансирования за весь период')
plt.ylabel('Объём возвратов, USD')
plt.xlabel('Тип финансирования')
plt.xticks(rotation=45, ha='right')
plt.grid(axis='y', linestyle='--', alpha=0.6)
plt.tight_layout()
plt.show()
```




Диаграмма наглядно показывает, что рынок возвратов практически полностью формируется за счет венчурного, долгового и частично акционерного финансирования, альтернативные же формы пока не обеспечивают ощутимой доли возвратов.

Общий вывод:

Максимальная эффективность наблюдается там же, где сосредоточено основное движение средств, а именно в венчурном и договом финансировании.

Остальные источники либо несут более высокий риск невозврата, либо имеют изначально невозвратную модель.

При планировании инвестиционной стратегии, стоит обратить внимание на массовые и институциональные формы финансирования, так как там максимальны и сами инвестиции и возвраты.

Шаг 4. Анализ динамики

4.1 Динамика предоставления финансирования по годам

Используя столбцы `funding_total_usd` и `funding_rounds`, рассчитаем для каждой компании средний объём одного раунда финансирования.

На основе получившейся таблицы построим графики, отражающие:

- динамику типичного размера средств, которые стартапы получали в рамках одного раунда финансирования;
- динамику общего количества раундов за каждый год, то есть насколько активно происходили инвестиции на рынке (чем больше раундов, тем выше активность).

In [66]:

```
# Сделаем копию df_final
df_final=df_final.copy()
```

```
# Создаем столбец с средним финансированием за раунд
df_final.loc[:, 'avg_funding_per_round'] = df_final.apply(
    lambda row: row['funding_total_usd'] / row['funding_rounds']
    if row['funding_rounds'] and row['funding_rounds'] > 0 else None,
    axis=1)
```

In [67]:

```
# Берём год из столбца mid_funding_at для группировки
df_final['year'] = df_final['mid_funding_at'].dt.year

# Средний размер раунда по годам (медиана)
median_funding = df_final.groupby('year')['avg_funding_per_round'].median()

# Общее количество раундов за год
total_rounds = df_final.groupby('year')['funding_rounds'].sum()

df_table = pd.DataFrame ({ 'Средний размер раунда': median_funding,
                           'Общее количество раундов': total_rounds

})

display(df_table)
```

	Средний размер раунда	Общее количество раундов
year		
1999	1.054755e+06	88.0
2000	1.653598e+06	144.0
2001	1.000000e+06	85.0
2002	1.500000e+06	148.0
2003	1.160058e+06	159.0
2004	2.000000e+06	207.0
2005	3.750000e+06	975.0
2006	3.000000e+06	1804.0
2007	2.125000e+06	2851.0
2008	1.890000e+06	3783.0
2009	1.400000e+06	4709.0
2010	1.217258e+06	6376.0
2011	1.000000e+06	8347.0
2012	7.633337e+05	10708.0
2013	6.472500e+05	14387.0
2014	6.696415e+05	8729.0

По данным таблицы можно заметить, что до 2005 г. количество раундов было сравнительно небольшим, затем начинается стремительный рост. Пик количества раундов зафиксирован в 2013 г. в 2014г. наблюдается спад, но показатель все равно намного выше начала периода.

К 2014 году типичные суммы финансирования за раунд существенно уменьшаются, в 2013 зафиксировано падение до исторического минимума за период наблюдения.

In [68]:

```
fig, ax1 = plt.subplots(figsize=(12, 6))

color1 = 'tab:blue'
ax1.set_xlabel('Год')
ax1.set_ylabel('Медиана финансирования за раунд (USD)', color=color1)
ax1.plot(median_funding.index, median_funding.values, color=color1, marker='o', label=
ax1.tick_params(axis='y', labelcolor=color1)
ax1.set_yscale('log')

ax2 = ax1.twinx() # второй график поверх первого
color2 = 'tab:red'
ax2.set_ylabel('Общее количество раундов', color=color2)
ax2.plot(total_rounds.index, total_rounds.values, color=color2, marker='x', label='Коли
ax2.tick_params(axis='y', labelcolor=color2)

plt.title('Динамика финансирования по годам')
fig.tight_layout()
plt.show()
```



В период с 2005 г. по 2014 г. рынок прошел фазу роста раундов и падение среднего размера финансирования, отражая эволюцию от концентрации капиталов к массовому финансированию многих компаний небольшими чеками. Это может свидетельствовать о росте конкуренции и приоритете на раннее финансирование большего числа проектов.

Средний размер финансирования за раунд:

- В начале 2000-х годов наблюдается рост среднего размера финансирования
- Пик среднего размера финансирования в рамках одного раунда пришелся на 2005 г.
- После 2005 г. наблюдается спад с минимальным значением в 2013 г.

Общее количество раундов.

- До 2005 года количество раундов "стелится" по оси X и не превышает 250. Далее заметен быстрый но плавный рост с пиком количества в 2013 г.
- В 2014 г. можем заметить резкий спад, но количество не достигает показателей начала отчетного периода.

Общий вывод:

Рынок пережил смещение фокуса: от крупных инвестиционных раундов к большому числу небольших сделок.

Такая динамика характерна для зрелых рынков: после этапа массовых крупных вложений появляется большой поток малых инновационных проектов, что повышает общее количество раундов, но снижает их средний размер.

4.2 Динамика размера общего финансирования по массовым сегментам рынка для растущих в 2014 году сегментов

Составим сводную таблицу, в которой указывается суммарный размер общего финансирования `funding_total_usd` по годам и сегментам рынка. Отберите из неё только те сегменты, которые показывали рост размера суммарного финансирования в 2014 году по сравнению с 2013.

На графике отразим, как менялся суммарный размер общего финансирования в каждом из отобранных сегментов по годам, за которые у вас достаточно данных. Для рассмотрения возьмем только массовые сегменты, а средние и нишевые исключим.

In [69]:

```
# mass_segments – список массовых сегментов, уже известный из вашего этапа сегментации
mass_segments = [m for m in df_invest['market'].unique() if m not in ['mid', 'niche',

print(mass_segments)

# Группируем по году и сегменту
df_final['funding_year'] = df_final['mid_funding_at'].dt.year

pivot = (
    df_final[df_final['market'].isin(mass_segments)]
    .groupby(['funding_year', 'market'])['funding_total_usd']
    .sum()
    .unstack('market')
)
display(pivot)
```

```
['education', 'social media', 'hardware + software', 'biotechnology', 'hospitality', 'enterprise software', 'manufacturing', 'finance', 'design', 'nonprofits', 'software', 'curated web', 'health care', 'health and wellness', 'media', 'clean technology', 'financial services', 'web hosting', 'e-commerce', 'automotive', 'medical', 'fashion', 'security', 'networking', 'analytics', 'semiconductors', 'public relations', 'travel', 'consulting', 'real estate', 'technology', 'music', 'advertising', 'games', 'mobile', 'sports', 'medical devices', 'internet', 'photography', 'news', 'messaging', 'search', 'video', 'transportation', 'marketplaces', 'entertainment', 'saas', 'cloud computing', 'big data', 'sales and marketing', 'apps', 'social network media', 'startups']
```

	market	advertising	analytics	apps	automotive	big data	biotechnology	cloud technology
funding_year								
	1999	3531739.0	10774916.0	NaN	NaN	NaN	NaN	
	2000	17651739.0	14822803.0	NaN	NaN	NaN	NaN	
	2001	8778321.0	3400000.0	NaN	NaN	NaN	NaN	
	2002	24500000.0	7500000.0	NaN	NaN	NaN	NaN	3.439044e+08
	2003	17500000.0	7240000.0	NaN	4530000.0	NaN	8.553118e+07	9.114794e+07
	2004	20592159.0	3000000.0	NaN	NaN	NaN	5.051964e+07	5.042795e+07
	2005	134522978.0	85814044.0	NaN	6270120.0	NaN	4.908636e+08	2.692000e+08

	market	advertising	analytics	apps	automotive	big data	biotechnology	cloud technology
funding_year								
2006	208272991.0	139701311.0	1310600.0	12660000.0	NaN	9.143005e+08	7.327389e	
2007	560609648.0	52229000.0	NaN	21500000.0	7780000.0	1.718242e+09	6.472112e	
2008	558201716.0	169977840.0	3550000.0	62613695.0	8002515.0	1.561893e+09	3.146288e	
2009	564654052.0	168149327.0	7219000.0	39610671.0	597375.0	3.515655e+09	1.783640e	
2010	635653520.0	261339904.0	6623779.0	20831976.0	28440000.0	4.742051e+09	1.418411e	
2011	420319734.0	381083373.0	23374071.0	88992403.0	60569158.0	4.941364e+09	1.552450e	
2012	609707463.0	527501889.0	23162806.0	51391760.0	77913341.0	4.741833e+09	1.004586e	
2013	640044065.0	662271367.0	31949970.0	157193246.0	86698922.0	5.582112e+09	1.368883e	
2014	261981896.0	204768649.0	60270450.0	121195122.0	67311607.0	2.453047e+09	8.084818e	

16 rows × 53 columns

```
In [70]: # Защита от пропусков: сравниваем только там, где есть оба года
growing_segments = [
    seg for seg in pivot.columns
    if ((2013 in pivot.index) and (2014 in pivot.index) and (pivot.loc[2014, seg] > pivot.loc[2013, seg]))
]
pivot_grow = pivot[growing_segments]
```

```
In [71]: # Получаем список цветов из палитры coolwarm для нужного количества линий
cmap = plt.get_cmap('coolwarm')
n_lines = len(pivot_grow.columns)
colors = [cmap(i / (n_lines - 1)) for i in range(n_lines)]

# Строим каждую линию с индивидуальным цветом из палитры
ax = pivot_grow.plot(figsize=(12, 6), marker='o', color=colors)

plt.title('Динамика суммарного общего финансирования по массовым сегментам с ростом в 2014 году')
plt.xlabel('Год')
plt.ylabel('Сумма финансирования (USD)')
plt.legend(title='Сегмент рынка')
plt.tight_layout()
plt.show()
```



На графике показана динамика суммарного объёма финансирования по массовым сегментам рынка, которые показали рост именно в 2014 году.

Максимальный и самый устойчивый рост с 2010-х годов демонстрируют такие сегменты, как apps, medical devices, technology и transportation. Эти сегменты показывают самые высокие значения к 2014 году, их траектории резко идут вверх относительно других.

Для некоторых сегментов (например, media, manufacturing) траектория характеризуется чередованием подъёмов и спадов. Это может быть результатом того, что крупные суммы периодически сконцентрированы в отдельных компаниях/сделках.

4.3 Годовая динамика доли возвращённых средств по типам финансирования

Выясним какая часть вложенных или выданных денег со временем возвращается обратно инвесторам или финансистам. Для каждого года и каждого вида финансирования рассчитаем нормированные значения возврата средств: то есть какую долю возвращённые средства составляют от предоставленных. При этом слишком большие аномальные значения, то есть неадекватные выбросы, заменим на пропуски.

In [72]:

```
# Ваши типы финансирования
types = ['seed', 'venture', 'equity_crowdfunding', 'undisclosed', 'convertible_note',
         'debt_financing', 'angel', 'grant', 'private_equity', 'post_ipo_equity',
         'post_ipo_debt', 'secondary_market', 'product_crowdfunding']

# Создаём DataFrame для результирующих долей
return_shares = pd.DataFrame()

for t in types:
    # Проверим, есть ли оба столбца (привлечённые и возвращённые средства)
    returned_col = f'{t}_return' if f'{t}_return' in df_returns.columns else t
    funded_col = f'{t}_in' if f'{t}_in' in df_final.columns else t
    if (returned_col in df_returns.columns) and (funded_col in df_final.columns):
        year = df_final['year'] if 'year' in df_final.columns else df_returns['year']
        # Группируем по году (sum на всякий случай, если не агрегированы)
        funded_sums = df_final.groupby('year')[funded_col].sum()
        returned_sums = df_returns.groupby('year')[returned_col].sum()
        # Совмещаем годы (на всякий случай)
```

```

aligned = pd.DataFrame({'funded': funded_sums, 'returned': returned_sums})
share = aligned['returned'] / (aligned['funded'] + 1e-60)
# Отображаем неадекватные выбросы (>2)
share[share > 2] = np.nan
return_shares[t] = share
return_shares.index.name = 'year'

display(return_shares)

```

	seed	venture	equity_crowdfunding	undisclosed	convertible_note	debt_financing	
year							
1999	NaN	NaN	NaN	NaN	NaN	NaN	
2000	9.964712e-07	2.417205e-07	0.000000e+00	1.440261e-06	0.000000e+00	8.660000e-07	2.6691
2001	1.079592e-06	2.146251e-07	0.000000e+00	5.874833e-07	NaN	4.490000e-06	1.1801
2002	6.297066e-07	6.822818e-07	0.000000e+00	1.099500e-06	NaN	2.233882e-07	1.1361
2003	5.052762e-07	8.087120e-07	0.000000e+00	9.143969e-07	NaN	1.038095e-06	6.0571
2004	5.874096e-07	1.135038e-06	0.000000e+00	4.276793e-06	NaN	6.478101e-07	9.9631
2005	7.671189e-07	6.170206e-07	0.000000e+00	1.529281e-06	NaN	3.867917e-07	7.3691
2006	9.673958e-07	4.094705e-07	NaN	8.034343e-07	1.663181e-07	1.133213e-06	7.1631
2007	3.938426e-07	3.668525e-07	NaN	7.048514e-07	3.462445e-07	6.920703e-07	8.6501
2008	3.120898e-07	2.298760e-07	NaN	3.488738e-07	7.368210e-08	9.963940e-07	4.3461
2009	5.912725e-07	2.022899e-07	8.781897e-08	4.785965e-07	5.659243e-08	4.635438e-07	6.5321
2010	5.650443e-07	2.381049e-07	5.270270e-08	3.243115e-07	7.434976e-08	4.679763e-07	6.5521
2011	2.860011e-07	2.989291e-07	9.703450e-08	2.551149e-07	5.536280e-08	5.649806e-07	4.9851
2012	2.048407e-07	3.729013e-07	2.919915e-08	2.134733e-07	4.561021e-08	5.444443e-07	5.4951
2013	1.543150e-07	4.099347e-07	3.007824e-08	2.933601e-07	5.125769e-08	5.492888e-07	5.6371
2014	2.953557e-07	9.420555e-07	7.989156e-09	6.411329e-07	9.233247e-08	1.494410e-06	1.3801

In [73]:


```

# Визуализация

plt.figure(figsize=(12, 7))
for i, t in enumerate(return_shares.columns):
    plt.plot(return_shares.index, return_shares[t], marker='o', label=t, color=colors[i])
plt.title('Доля возвращённых средств по типам финансирования')
plt.xlabel('Год')
plt.ylabel('Доля возврата (вернулось/привлечено)')
plt.grid(True, linestyle='--', alpha=0.5)

```

```
plt.legend(title='Тип финансирования')
plt.tight_layout()
plt.show()
```



На графике показана динамика суммарного объёма финансирования по массовым сегментам рынка, которые показали рост именно в 2014 году.

Максимальный и самый устойчивый рост с 2010-х годов демонстрируют такие сегменты, как apps, medical devices, technology и transportation. Эти сегменты показывают самые высокие значения к 2014 году, их траектории резко идут вверх относительно других.

В некоторых сегментах наблюдаются заметные скачки — например, apps в 2012 и 2013 годах. Это может свидетельствовать о крупных сделках или появлении новых кластеров компаний.

Общий вывод:

К 2014 году наиболее быстрый и устойчивый рост наблюдается в сегментах apps, medical devices, technology, transportation и частично internet. Именно в этих секторах массовый рынок концентрирует основную часть дополнительных вложений, что указывает на стратегические тренды отрасли и высокую динамику развития данных рынков. Стабильные, но менее резкие темпы роста в остальных сегментах подтверждают диверсификацию инвестиций, но также свидетельствуют, что основные инвестиционные возможности и прорывы сосредоточены в технологических и digital-направлениях.

Построим график, на котором отобразите нормированные значения возврата средств для типов финансирования `venture`, `debt_financing`, `private_equity`, `seed` и `angel`.

In [74]:

```
# Типы финансирования, которые анализируем
selected_types = ['venture', 'debt_financing', 'private_equity', 'seed', 'angel']

return_share = pd.DataFrame()

for t in selected_types:
    # funds — привлечённые за год, returns — возвращённые за год
    funds = df_final.groupby('year')[t].sum()
    returns = df_returns.groupby('year')[t].sum()
```

```

share = returns / (funds + 1e-60)
share[share > 2] = np.nan
return_share[t] = share

returns_share_df = pd.DataFrame(return_share)

display(returns_share_df)

```

	venture	debt_financing	private_equity	seed	angel
year					
1999	NaN	NaN	NaN	NaN	NaN
2000	2.417205e-07	8.660000e-07	0.000000e+00	9.964712e-07	2.669564e-07
2001	2.146251e-07	4.490000e-06	0.000000e+00	1.079592e-06	1.180000e-06
2002	6.822818e-07	2.233882e-07	2.013333e-07	6.297066e-07	1.136667e-06
2003	8.087120e-07	1.038095e-06	NaN	5.052762e-07	6.057203e-07
2004	1.135038e-06	6.478101e-07	NaN	5.874096e-07	9.963380e-07
2005	6.170206e-07	3.867917e-07	4.800000e-07	7.671189e-07	7.369398e-07
2006	4.094705e-07	1.133213e-06	1.053720e-06	9.673958e-07	7.163630e-07
2007	3.668525e-07	6.920703e-07	2.054989e-06	3.938426e-07	8.650830e-07
2008	2.298760e-07	9.963940e-07	6.799254e-07	3.120898e-07	4.346528e-07
2009	2.022899e-07	4.635438e-07	1.004414e-06	5.912725e-07	6.532701e-07
2010	2.381049e-07	4.679763e-07	7.132718e-07	5.650443e-07	6.552452e-07
2011	2.989291e-07	5.649806e-07	9.765566e-07	2.860011e-07	4.985567e-07
2012	3.729013e-07	5.444443e-07	1.069106e-06	2.048407e-07	5.499117e-07
2013	4.099347e-07	5.492888e-07	7.751170e-07	1.543150e-07	5.637171e-07
2014	9.420555e-07	1.494410e-06	1.886652e-06	2.953557e-07	1.380476e-06

Венчурное финансирование (venture) демонстрирует относительно стабильную, пусть и низкую, долю возвратов с редкими всплесками в отдельные годы (например, небольшой подъем в 2008–2010 и рост к 2014 году).

Абсолютные значения доли возвратов для всех типов крайне малы, что говорит о том, что возвращается только небольшая часть от объёма вложенных средств. Это типично для венчурного и посевного финансирования, где высокий риск и доля неудачных инвестиций заложены в саму модель рынка.

In [75]:

```

plt.figure(figsize=(12, 6))
for i, col in enumerate(selected_types):
    plt.plot(returns_share_df.index, returns_share_df[col], marker='o', label=col, color=selected_colors[i])
plt.title('Динамика нормированных возвратов по ключевым типам финансирования')
plt.xlabel('Год')
plt.ylabel('Доля возврата (возвраты / вложения)')
plt.grid(True, linestyle='--', alpha=0.6)
plt.legend(title='Тип финансирования')
plt.tight_layout()
plt.show()

```



С 2010-х годов все типы демонстрируют большую равномерность (меньше разовых сильных колебаний), что говорит о «зрелости» рынка начальных инвестиций и большем контроле над инвестиционными потоками.

В 2014 году почти все типы показывают небольшой рост нормированных возвратов — это может быть связано с качественным улучшением отбора проектов или удачным стечением экономических факторов для экзитов.

Тем не менее, разница между типами финансирования по возвратам незначительна, все кривые располагаются очень близко друг к другу.

Общий вывод:

Для всех видов финансирования наблюдается стабильно низкая доля возвратов вложенных средств. Отдельные пики в динамике связаны скорее со случайными разовыми событиями, а не с устойчивой тенденцией повышения возвратов. Для инвесторов долгосрочная доходность будет определяться способностью находить редкие проекты, кооторые выстрелят, так как ориентироваться на структурный рост возвратов по рынку

Шаг 5. Итоговый вывод и рекомендации

Представьте, что на календаре 2015 год. Опираясь на результаты анализа, дайте рекомендацию заказчику:

- в какую отрасль стоит инвестировать;
- какой тип финансирования при этом будет наиболее уместным.

Подведите итоги проекта:

- опишите, какие шаги были выполнены;
- какие выводы удалось сделать;
- насколько выводы согласуются между собой или, наоборот, вызывают сомнения.

В ходе исследования были выполнены следующие шаги:

- Сбор и подготовка данных: проведена очистка, стандартизация, удаление выбросов и аномалий в инвестиционном датасете (funding_total_usd, funding_rounds, даты, сегменты

рынка).

- Классификация сегментов: построено разбиение рынка на массовые, средние и нишевые сегменты по числу игроков; остальные сегменты отнесены к "niche" или "mid".
- Анализ распределения: визуализировано распределение объемов финансирования, найдены типичные и экстремальные значения, рассчитана медиана/характерные интервалы по сегментам и в целом.
- Динамика по годам: рассчитаны и визуализированы динамика среднего объема раунда, общего числа раундов по годам, а также объема финансирования по отраслям.
- Исследование отраслей-лидеров: идентифицированы сегменты с наибольшим и самым устойчивым ростом по объёму финансирования — apps, technology, medical devices, transportation и др.
- Сравнение типов финансирования: выполнена агрегация долей возвратов, выявлены наиболее успешные форматы (venture и debt financing) как по объёму, так и по числу сделок.
- Оценка возвратов: рассчитаны нормированные значения долей возвратов по каждому типу, отмечена их низкая, но стабильная величина во всем венчурном рынке.
- Сформулированы основные выводы

Выводы по исследованию:

- Выявлено явное лидерство технологических, digital и медицинских секторов по скорости и объёму роста подтверждается по разным метрикам и годам.
- Венчурное финансирование наиболее массовое, устойчивое и возвратное в ключевых сегментах, незаменимо для экспансии в быстрорастущие рынки.
- Большинство альтернативных инструментов и нишевых рынков остаются малозначимы на фоне общего потока, хотя могут быть полезны в отдельных уникальных стратегиях.
- Ожидания по возвратам для индустрии в целом остаются традиционно низкими, сильный эффект производят единичные крупные успешные сделки — это типичная венчурная математика.

Согласованность выводов между собой:

- Ключевые тренды прослеживаются и по динамике общего финансирования, и по числу компаний, и по возвратам капитала, что подтверждает надежность анализа.
- Доля возвратов остаётся очень низкой у всех типов финансирования — это формально согласуется с логикой высокорискованных рынков, но требует внимательности в формировании портфеля. Краткие всплески в отдельных сегментах (angel, grant и др.) связаны скорее с разовыми случаями, чем с устойчивыми возможностями.
- Фокус смещается к инновациям, цифровизации, медицине и сложному транспорту. Именно здесь можно ожидать максимального роста и потенциального выхода на лидирующие мультипликаторы.

Рекомендации заказчику:

Топ-отрасли для инвестирования:

- Технологии (technology, apps, internet)
- Медицинские технологии и биотех (medical devices, medical)
- Транспорт и логистика (transportation)

Эти сегменты в 2013–2014 годах показали наибольший и самый устойчивый рост по суммарному объёму финансирования, демонстрировали лидерство по массе привлекаемых инвестиций и привлекают внимание как венчурных, так и институциональных инвесторов.

Наиболее уместный тип финансирования:

- Венчурное финансирование (venture). Этот формат традиционно лидирует как по совокупному объёму, так и по числу компаний, остаётся главным драйвером развития массовых инновационных отраслей и связан с крупнейшими объёмами возвратов средств.
- Для ранней стадии инноваций также целесообразно seed-инвестирование и (в меньшей степени) debt financing, если нужно минимизировать риски.

Резюме:

В 2015 году инвестору рационально направить средства в технологии и медицину с упором на венчурное и раннее финансирование. Исследование показало, что именно эти сегменты выдают наивысший темп и концентрацию капиталов, а структура рынка полностью соответствует тенденциям чем выше риск, тем выше доходность. Выбор венчурных инструментов на данных рынках — наиболее сбалансированная стратегия для извлечения выгоды из текущего инвестиционного цикла.