

Аналитическая записка

Анализ факторов ДТП на основе проекта «Карта ДТП»

ОГЛАВЛЕНИЕ

1. Введение и цель исследования	2
2. Описание данных.....	3
3. Проверка и подготовка данных.....	4
4. Исследовательский анализ	6
4.1 Распределение ДТП по дням недели	6
4.2 Распределение ДТП по месяцам	6
4.3 Анализ ДТП по водительскому стажу	7
5. Региональное сравнение Кировской и Московской областей	8
6. Основные выводы	10
7. Рекомендации	11

1. Введение и цель исследования

В рамках проекта были проанализированы данные некоммерческого сервиса «Карта ДТП». Проект собирает информацию о дорожно-транспортных происшествиях в России и направлен на повышение безопасности дорожного движения.

Данные «Карты ДТП» позволяют изучать особенности аварийности, выявлять проблемные участки, анализировать условия происшествий и формировать рекомендации для улучшения дорожной инфраструктуры.

В исследовании рассматриваются данные о ДТП в Кировской и Московской областях. Дополнительно используются сведения об участниках происшествий и транспортных средствах.

Цель исследования - изучить данные о дорожно-транспортных происшествиях и выявить особенности аварийности в Кировской и Московской областях.

Для достижения цели были поставлены следующие задачи:

1. Провести первичное изучение данных.
2. Проверить данные на наличие пропусков и дубликатов.
3. Оценить корректность типов данных.
4. Определить, как менялось число ДТП по дням недели и месяцам.
5. Сравнить количество ДТП среди водителей с разным стажем.
6. Проанализировать различия в аварийности между Кировской и Московской областями.
7. Подготовить выводы и рекомендации для заказчика.

2. Описание данных

В проекте использовались несколько датасетов.

Основные датасеты по **Кировской и Московской областям** содержат информацию о ДТП:

- координаты происшествия;
- идентификатор ДТП;
- освещённость;
- ближайшие объекты;
- район или регион;
- схема ДТП;
- адрес;
- погодные условия;
- категория ДТП;
- дата и время происшествия;
- число пострадавших;
- область;
- состояние дорожного покрытия;
- число участников;
- категории участников.

Дополнительные датасеты содержат сведения об участниках ДТП и сведения о транспортных средствах:

- роль участника;
- пол;
- нарушения ПДД;
- состояние здоровья;
- водительский стаж;
- идентификатор ДТП.
- год выпуска;
- марка;
- цвет;
- модель;
- категория;
- идентификатор ДТП.

3. Проверка и подготовка данных

Переименование столбцов

На первом этапе были изучены названия столбцов в датасете по Кировской области. В исходных данных часть названий содержала технические префиксы `geometry` и `properties`. Например, `geometry.coordinates` и `properties.light`;

Для удобства дальнейшей работы названия были сокращены. Например, `geometry.coordinates` был переименован в `coordinates`, `properties.tags` - в `tags`.

Остальные названия были очищены от повторяющегося префикса `properties`.

Переименование не влияет на содержание данных, но делает код более читаемым и снижает вероятность ошибок при обращении к столбцам.

Анализ пропусков

На следующем этапе были изучены пропуски в датасете `Kirovskaya_oblast.csv`. В результате проверки были выявлены пропуски в следующих столбцах:

Рисунок 1 – Наличие пропусков в столбцах

<code>scheme</code>	1137
<code>address</code>	674
<code>point.long</code>	32
<code>point_lat</code>	32
<code>id</code>	0
<code>coordinates</code>	0
<code>tags</code>	0
<code>light</code>	0
<code>region</code>	0
<code>nearby</code>	0
<code>weather</code>	0
<code>category</code>	0
<code>datetime</code>	0
<code>injured_count</code>	0
<code>parent_region</code>	0
<code>road_conditions</code>	0
<code>participants_count</code>	0
<code>participant_categories</code>	0

Наибольшее количество пропусков обнаружено в столбце `scheme`. Этот столбец содержит числовое обозначение схемы конкретной аварии. Автоматически заполнить такие пропуски сложно, так как для этого нужно знать обстоятельства конкретного ДТП.

В столбце `address` также есть значительное количество пропусков. При анализе строк с отсутствующим адресом не было выявлено явных аномалий. Вероятно, адрес не всегда является обязательным полем для заполнения.

Для проверки гипотезы о том, что адрес отсутствует из-за удалённости ДТП от объектов инфраструктуры, был проанализирован столбец `nearby`. В нём хранятся ближайшие объекты. Анализ показал, что не все значения в `nearby` пустые: в строках без адреса встречаются жилые дома, внутридворовые территории, торговые объекты и другие ориентиры. Поэтому гипотеза о том, что пропуск адреса связан только с отсутствием ближайших объектов, не подтверждается полностью.

Пропуски в координатах встречаются редко: по 32 пропуска в столбцах `point_lat` и `point_long`. Однако эти пропуски важны, так как координаты нужны для построения карты ДТП и анализа аварийно-опасных участков.

Проверка дубликатов

После анализа пропусков была выполнена проверка явных дубликатов. Явные дубликаты в данных не обнаружены: результат проверки равен 0.

Также была проверена уникальность идентификаторов ДТП. Количество уникальных значений `id` совпадает с общим количеством идентификаторов. Это означает, что каждое ДТП имеет уникальный идентификатор.

Уникальность идентификаторов особенно важна, так как поле `id` используется для связи данных о ДТП с таблицами участников и транспортных средств.

Проверка типов данных

На этапе проверки типов данных было выявлено, что в датасете по Кировской области 18 столбцов и 14 517 записей.

Типы данных распределены следующим образом:

- `float64` - 3 столбца;
- `int64` - 3 столбца;
- `object` - 12 столбцов.

Основные замечания по типам данных:

1. Столбец `datetime` изначально хранится как `object`, поэтому для временного анализа его необходимо преобразовать в формат `datetime`.
2. В столбце `coordinates` хранится пара координат, но отдельно уже есть столбцы `point_lat` и `point_long`. Для анализа удобнее использовать отдельные столбцы с широтой и долготой.
3. Для `id` достаточно типа `int32`, что позволит снизить объём используемой памяти.
4. Для `participants_count` и `injured_count` можно использовать более компактный тип, например `int8`, так как значения в этих столбцах небольшие.
5. Для `scheme` можно использовать тип `int16`, предварительно обработав пропуски.
6. Столбцы `nearby`, `weather`, `road_conditions`, `participant_categories` содержат списки. Для решения текущих задач их преобразование не требуется.

4. Исследовательский анализ

4.1 Распределение ДТП по дням недели

Для анализа ДТП по времени столбец `datetime` был преобразован в формат даты и времени. Затем были добавлены столбцы с днём недели и месяцем происшествия.

По результатам анализа в Кировской области больше всего ДТП произошло в пятницу, субботу и воскресенье.

Таблица 1 – Количество ДТП по дням недели

День недели	Количество ДТП
Friday	2344
Saturday	2246
Sunday	2054
Monday	2010
Tuesday	1988
Wednesday	1939
Thursday	1936

Наибольшее число ДТП ближе к выходным может быть связано с увеличением транспортной активности, поездками за город, усталостью водителей к концу рабочей недели и более интенсивным движением в выходные дни.

4.2 Распределение ДТП по месяцам

Рассчитано количество ДТП по месяцам и отсортировано по убыванию.

Таблица 2 – Количество ДТП по месяцам

Месяц	Количество ДТП
8	1654
7	1635
6	1421
9	1370
10	1333
11	1200
5	1189
12	1164
1	1069
4	875
2	808
3	799

Наибольшее число ДТП зафиксировано в летние месяцы: августе, июле и июне. Это может быть связано с ростом числа поездок, отпускным сезоном, активным использованием личного транспорта, увеличением количества пешеходов и велосипедистов.

Минимальное количество ДТП наблюдается в феврале и марте.

4.3 Анализ ДТП по водительскому стажу

Для анализа ДТП по стажу использовался датасет с участниками происшествий по Кировской области.

Сначала были отобраны участники с ролью «Водитель». Всего таких записей - 19 753. При этом поле `years_of_driving_experience` заполнено не для всех водителей: 16 909 непустых значений, то есть 2 844 пропуска. Это около 14% от общего числа водителей.

Таблица 3 – Распределение водителей на категории по десятилетиям стажа

Стаж	Количество участников ДТП
0–10 лет	6771
10–20 лет	5049
20–30 лет	2724
30–40 лет	1618
40–50 лет	629
50–60 лет	106
60–70 лет	12

Таблица 4 – Распределение водителей по пятилетним интервалам

Стаж	Количество участников ДТП
0–5 лет	3533
5–10 лет	3238
10–15 лет	2769
15–20 лет	2280
20–25 лет	1587
25–30 лет	1137
30–35 лет	921
35–40 лет	697
40–50 лет	629
50–60 лет	106
60–70 лет	12

Анализ показывает, что с увеличением водительского стажа количество участников ДТП постепенно снижается. Самая многочисленная группа - водители со стажем до 10 лет.

При этом важно учитывать ограничение: данные показывают абсолютное количество участников ДТП, а не риск попадания в ДТП. Для оценки риска необходимо знать общее количество водителей в каждой стажевой группе.

5. Региональное сравнение Кировской и Московской областей

В дополнительной части исследования было проанализировано, как менялось число ДТП по годам в Кировской и Московской областях.

Для Кировской области город Киров был включён в расчёты. Для Московской области Москва была исключена, так как она является отдельным субъектом и может исказить региональное сравнение.

Для сравнения были рассчитаны:

- абсолютное число ДТП по годам;
- число ДТП на 100 тысяч жителей.

Таблица 5 - Кировская область

Год	Количество ДТП	Население, условная единица	ДТП на 100 тыс. жителей
2015	1532	13	117.85
2016	1468	13	112.92
2017	1452	13	111.69
2018	1612	13	124.00
2019	1568	13	120.62
2020	1498	13	115.23
2021	1524	12	127.00
2022	1386	11	126.00
2023	1486	11	135.09
2024	991	11	90.09

Таблица 6 - Московская область

Год	Количество ДТП	Население, условная единица	ДТП на 100 тыс. жителей
2015	6643	72	92.26
2016	5794	73	79.37
2017	5747	74	77.66
2018	5102	75	68.03
2019	5111	76	67.25
2020	4216	77	54.75
2021	3898	85	45.86
2022	3353	85	39.45
2023	3372	86	39.21
2024	2382	87	27.38

В абсолютном выражении ДТП больше в Московской области. Это ожидаемо, так как регион имеет большую численность населения и более высокую транспортную нагрузку.

Однако в пересчёте на 100 тысяч жителей относительный показатель ДТП выше в Кировской области. Это говорит о том, что сравнение регионов только по абсолютному числу ДТП может быть некорректным.

Рисунок 2 - Таблицы с численностью населения Московской и Кировской областях соответственно

Численность населения							
1897 ^[7]	1926 ^[8]	1928 ^[9]	1937 ^[10]	1941 ^[11]	1944 ^[11]	1959 ^[12]	1970 ^[13]
1 391 990	↗4 570 836	↗4 744 200	↗8 173 289	↘5 387 400	↘3 807 400	↗5 863 003	↘5 774 529
1976 ^[14]	1979 ^[15]	1987 ^[16]	1989 ^[17]	1990 ^[18]	1991 ^[18]	1992 ^[18]	1993 ^[18]
↗6 076 000	↗6 359 385	↗6 581 000	↗6 693 623	↗6 700 180	↗6 720 248	↘6 719 121	↘6 704 332
1994 ^[18]	1995 ^[18]	1996 ^[18]	1997 ^[18]	1998 ^[18]	1999 ^[18]	2000 ^[18]	2001 ^[18]
↘6 677 307	↘6 671 785	↘6 660 192	↘6 657 710	↘6 657 149	↘6 653 499	↘6 628 173	↘6 613 469
2002 ^[19]	2003 ^[18]	2004 ^[18]	2005 ^[18]	2006 ^[18]	2007 ^[18]	2008 ^[18]	2009 ^[18]
↗6 618 538	↘6 616 879	↗6 622 017	↗6 629 703	↘6 628 107	↗6 645 672	↗6 672 773	↗6 712 582
2010 ^[20]	2011 ^[18]	2012 ^[21]	2013 ^[22]	2014 ^[23]	2015 ^[24]	2016 ^[25]	2017 ^[26]
↗7 095 120	↗7 106 215	↗7 198 686	↘7 048 084	↗7 133 620	↗7 231 068	↗7 318 647	↗7 423 470
2018 ^[27]	2019 ^[28]	2020 ^[29]	2021 ^[30]	2022 ^[2]	2023 ^[31]	2024 ^[1]	
↗7 503 385	↗7 599 647	↗7 690 863	↗8 524 665	↗8 542 257	↗8 591 736	↗8 651 260	

Численность населения								
1897 ^[4]	1915 ^[5]	1937 ^[6]	1928 ^[7]	1937 ^[6]	1939 ^[8]	1940 ^[9]	1941 ^[10]	1942 ^[11]
3 030 831	↘2 115 600	↗2 387 477	↘2 252 400	↗2 380 337	↘2 226 000	↗2 334 000	↘2 318 000	↘2 091 000
1943 ^[12]	1944 ^[13]	1945 ^[14]	1946 ^[15]	1950 ^[16]	1959 ^[17]	1968 ^[18]	1970 ^[19]	1979 ^[20]
↗2 112 000	↘2 092 000	↘1 836 000	↗1 958 000	↘1 935 000	↘1 913 600	↘1 751 600	↘1 727 348	↘1 661 546
1987 ^[21]	1989 ^[22]	1990 ^[23]	1991 ^[23]	1992 ^[23]	1993 ^[23]	1994 ^[23]	1995 ^[23]	1996 ^[23]
↗1 675 000	↗1 692 655	↘1 651 726	↘1 648 962	↘1 645 091	↘1 641 886	↘1 632 494	↘1 623 370	↘1 609 480
1997 ^[23]	1998 ^[23]	1999 ^[23]	2000 ^[23]	2001 ^[23]	2002 ^[24]	2003 ^[23]	2004 ^[23]	2005 ^[23]
↘1 595 919	↘1 581 490	↘1 568 722	↘1 553 595	↘1 536 772	↘1 503 529	↘1 498 976	↘1 479 342	↘1 461 301
2006 ^[23]	2007 ^[23]	2008 ^[23]	2009 ^[23]	2010 ^[25]	2011 ^[23]	2012 ^[26]	2013 ^[27]	2014 ^[28]
↘1 442 935	↘1 426 917	↘1 413 257	↘1 401 201	↘1 341 312	↘1 338 758	↘1 327 915	↘1 319 076	↘1 310 929
2015 ^[29]	2016 ^[30]	2017 ^[31]	2018 ^[32]	2019 ^[33]	2020 ^[34]	2021 ^[35]	2022 ^[2]	2023 ^[36]
↘1 304 348	↘1 297 474	↘1 291 684	↘1 283 238	↘1 272 109	↘1 262 402	↘1 153 680	↘1 149 176	↘1 138 112
2024 ^[1]								
↘1 129 935								

6. Основные выводы

В ходе проекта были проанализированы данные о ДТП в Кировской и Московской областях. Данные в целом пригодны для анализа: явные дубликаты не обнаружены, идентификаторы ДТП уникальны, поэтому таблицы можно корректно связывать между собой.

В датасете по Кировской области выявлены пропуски в столбцах `scheme`, `address`, `point_lat` и `point_long`. Наибольшее количество пропусков обнаружено в поле `scheme` - 1137 значений. Также есть 674 пропуска в адресах и 32 пропуска в координатах.

Пропуски в адресе не всегда связаны с отсутствием ближайших объектов: в части таких строк заполнено поле `nearby`. Это может говорить о том, что адрес не является обязательным полем или заполняется нерегулярно.

Пропуски в координатах встречаются редко, но являются критичными для пространственного анализа ДТП, так как без них невозможно корректно строить карту происшествий и выявлять аварийно-опасные участки.

Проверка дубликатов показала, что явных дубликатов нет. Идентификаторы ДТП уникальны, что позволяет использовать поле `id` для связи основных данных с таблицами участников и транспортных средств.

Анализ типов данных показал, что часть столбцов можно привести к более подходящим форматам. В первую очередь столбец `datetime` необходимо использовать в формате даты и времени. Также можно оптимизировать числовые типы данных для экономии памяти.

По дням недели больше всего ДТП происходит в пятницу, субботу и воскресенье. Это может быть связано с повышенной транспортной активностью перед выходными и в выходные дни. По месяцам заметна сезонность: наибольшее количество ДТП приходится на летний период, особенно август, июль и июнь. Вероятно, это связано с ростом числа поездок, отпускным сезоном и увеличением активности участников дорожного движения.

Анализ водительского стажа показал, что чаще всего в ДТП участвуют водители со стажем до 10 лет. С увеличением стажа количество участников ДТП постепенно снижается. Однако этот результат отражает только абсолютное количество участников ДТП, а не риск аварии для каждой стажевой группы.

В региональном сравнении абсолютное число ДТП выше в Московской области. При этом в относительном выражении, в пересчёте на 100 тысяч жителей, показатель ДТП выше в Кировской области. Это подтверждает необходимость использовать относительные показатели при сравнении регионов.

7. Рекомендации

Рекомендуется повысить полноту заполнения ключевых полей: координат, адреса, схемы ДТП и водительского стажа. Эти данные важны для анализа причин происшествий, поиска аварийно-опасных участков и оценки характеристик участников ДТП.

Координаты ДТП следует сделать обязательными для заполнения. Даже небольшое количество пропусков в координатах ограничивает возможности пространственного анализа и снижает точность карты ДТП.

Для поля `address` стоит уточнить правила заполнения. Если точный адрес неизвестен, рекомендуется фиксировать ближайший ориентир или причину отсутствия адреса.

Для поля `scheme` нужно определить, используется ли оно в дальнейшей аналитике. Если схема ДТП важна для анализа причин происшествий, её также следует сделать обязательной для заполнения.

Для поля `years_of_driving_experience` рекомендуется добавить отдельные причины отсутствия данных. Например: стаж неизвестен, данные не внесены, водитель не имел прав, водитель скрылся, информация отсутствует в источнике. Это позволит лучше интерпретировать пропуски.

В дальнейшем анализ можно расширить на другие регионы и дополнительно учитывать тип дороги, время суток, погодные условия, плотность населения, состояние дорожного покрытия и особенности дорожной инфраструктуры.

Итоговый вывод

Проект показал, что данные «Карты ДТП» позволяют анализировать временную динамику происшествий, особенности участников ДТП и различия между регионами.

Ключевые закономерности: рост числа ДТП ближе к выходным, сезонное увеличение аварийности летом, высокая доля участников ДТП среди водителей со стажем до 10 лет и более, высокий относительный показатель ДТП в Кировской области по сравнению с Московской.

Главное направление для улучшения - повышение полноты и регулярности заполнения данных. Это позволит заказчику проводить более точный анализ аварийности и разрабатывать более эффективные меры по повышению безопасности дорожного движения.