

Аналитическая записка

Анализ продуктовых метрик и проверка гипотезы сервиса «Яндекс Книги»

ОГЛАВЛЕНИЕ

1. Описание проекта и исходных данных.....	2
2. Расчёт продуктовых метрик	3
3. Проверка гипотезы в Python	6
4. Основные выводы	8
5. Рекомендации	9

1. Описание проекта и исходных данных

В проекте анализируются данные сервиса «Яндекс Книги» о чтении и прослушивании контента за период с 1 сентября по 11 декабря 2024 года.

В первой части с помощью SQL рассчитаны ключевые продуктовые метрики: MAU авторов и произведений, Retention Rate, LTV и средняя выручка за час активности.

Во второй части данные, подготовленные в SQL, использованы для проверки гипотезы в Python. Проверялась гипотеза о том, что пользователи из Санкт-Петербурга проводят в среднем больше времени за чтением и прослушиванием книг, чем пользователи из Москвы.

Цель проекта - проанализировать пользовательскую активность в сервисе «Яндекс Книги», рассчитать ключевые продуктовые метрики с помощью SQL и проверить гипотезу о различиях в поведении пользователей из Москвы и Санкт-Петербурга с помощью Python.

Описание данных

Данные представлены в нескольких таблицах за период с 1 сентября по 11 декабря 2024 года и содержат:

- данные об активности пользователей
- данные о контенте
- данные об авторах контента
- данные о местоположении

Для проверки гипотезы использовались данные, содержащие пользователей из Москвы и Санкт-Петербурга и сумму часов их активности.

2. Расчёт продуктовых метрик

MAU (Monthly Active Users) авторов

На первом этапе был рассчитан MAU авторов - количество уникальных пользователей, которые в течение ноября читали или слушали произведения конкретного автора.

Результат 1 - Топ-3 автора по MAU в ноябре

main_author_name	mau
Андрей Усачев	7107
Лиана Шнайдер	3338
Игорь Носов	3063

Наибольшее количество уникальных читателей и слушателей в ноябре собрал **Андрей Усачёв**. Его MAU составил **7107 пользователей**, что более чем в два раза выше, чем у автора на втором месте.

Вывод: Андрей Усачёв является наиболее популярным автором среди пользователей сервиса в ноябре. Высокий показатель MAU может быть связан с популярностью детского контента, так как часть наиболее популярных произведений относится именно к детской литературе.

MAU (Monthly Active Users) произведений

Далее был рассчитан MAU произведений - количество уникальных пользователей, которые читали или слушали конкретное произведение в ноябре.

Результат 2 - Топ-3 произведения по MAU

main_content_name	published_topic_title_list	main_author_name	mau
Собачка Соня на даче	[Детская проза и поэзия', 'Аудио']	Андрей Усачев	4597
Женькин клад и другие школьные рассказы	['Сказки и фольклор', 'Детская проза и поэзия', 'Аудио']	Игорь Носов	3050
Знаменитая собачка Соня	['Аудиоспектакли', 'Детская проза и поэзия', 'Аудио']	Андрей Усачев	2785

Все три произведения из топа относятся к детскому контенту. В жанрах каждого произведения присутствует категория «**Детская проза и поэзия**».

Вывод: детский контент занимает заметное место в потреблении пользователей сервиса. Особенно выделяются аудиоформаты и аудиоспектакли, что может говорить о востребованности детского аудиоконтента для семейной аудитории.

Retention Rate пользователей

Для анализа удержания была сформирована когорта пользователей, активных 2 декабря. Далее был рассчитан ежедневный Retention Rate до конца доступного периода.

Результат 3 - Результаты расчёта Retention Rate пользователей

day_since_install	retained_users	retention_rate
0	4259	1
1	2698	0.63
2	2550	0.6
3	2421	0.57
4	2231	0.52
5	1994	0.47
6	2129	0.5
7	2287	0.54
8	2274	0.53
9	2207	0.52

На первый день после активности вернулось **63% пользователей**, на второй день - **60%**, далее показатель постепенно снижался.

Минимальное значение Retention Rate было зафиксировано на **пятый день** и составило **47%**. После этого наблюдается небольшой рост: на шестой день удержание составило 50%, на седьмой - 54%.

Вывод: удержание пользователей после 2 декабря снижается в первые пять дней, но затем частично восстанавливается. Это может говорить о том, что часть пользователей возвращается к сервису не ежедневно, а с некоторой периодичностью.

LTV (Lifetime Value) пользователей Москвы и Санкт-Петербурга

LTV рассчитывался исходя из стоимости подписки Яндекс Плюс - **399 рублей в месяц**. В рамках проекта предполагалось, что пользователь приносит 399 рублей за каждый месяц, в котором он был активен в сервисе.

Результат 4 - Результаты расчёта LTV

city	total_users	ltv
Москва	16808	764.55
Санкт-Петербург	12559	731.82

В Москве пользователей больше, чем в Санкт-Петербурге: **16 808 против 12 559**. Средний LTV пользователей Москвы также выше: **764,55 руб. против 731,82 руб.**

Вывод: Москва является более крупным и более доходным сегментом по имеющимся данным. Пользователей в Москве больше, и средний LTV также выше.

Средняя выручка за час чтения или прослушивания

Так как в сервисе используется подписочная модель, классический средний чек не является информативной метрикой. Вместо этого была рассчитана средняя выручка за час чтения или прослушивания по формуле:

Средняя выручка за час = MAU × 399 / сумма часов активности

Результат 5 - Результаты средней выручки за час чтения или прослушивания по месяцам

month	mau	hours	avg_hour_rev
2024-09-01	16320	105539	61.7
2024-10-01	18280	137384	53.09
2024-11-01	18594	145351	51.04

С сентября по ноябрь MAU вырос с **16 320 до 18 594 пользователей**. Суммарное количество часов активности также увеличилось: с **105 539 до 145 351 часов**.

При этом средняя выручка за час снизилась с **61,70 руб.** в сентябре до **51,04 руб.** в ноябре.

Вывод: пользователи стали проводить в сервисе больше времени, но из-за фиксированной стоимости подписки средняя выручка за один час активности снижается. Это не обязательно является негативным сигналом: снижение метрики может отражать рост вовлечённости и более активное использование сервиса.

3. Проверка гипотезы в Python

Формулировка гипотезы

Команда сервиса предположила, что пользователи с более высоким LTV могут быть более лояльными и, следовательно, проводить больше времени за чтением и прослушиванием книг. Для проверки были сравнены пользователи из Москвы и Санкт-Петербурга.

Проверяемая гипотеза: пользователи из Санкт-Петербурга проводят в среднем больше времени за чтением и прослушиванием книг в приложении, чем пользователи из Москвы.

Статистические гипотезы:

Нулевая гипотеза H_0 : среднее время активности пользователей из Санкт-Петербурга не больше, чем среднее время активности пользователей из Москвы.

Альтернативная гипотеза H_1 : среднее время активности пользователей из Санкт-Петербурга больше, чем среднее время активности пользователей из Москвы.

Подготовка данных

Перед проверкой гипотезы данные были загружены в Python и проверены на дубликаты. В исходных данных было **8784 записи**:

- Москва - 6234 записи
- Санкт-Петербург - 2550 записей.

При проверке были обнаружены дубликаты по идентификатору пользователя `ruid`. Всего было найдено **244 дубликата**. Часть пользователей относилась сразу к нескольким городам. Для устранения дублирования каждому пользователю был сопоставлен город с наибольшей суммарной активностью. После этого данные были агрегированы до одного наблюдения на пользователя.

В очищенных данных осталось:

- Москва - **6099 пользователей**;
- Санкт-Петербург - **2441 пользователь**.

Также в ходе предобработки пользователи, попавшие в несколько городов, были обработаны через сопоставление с городом максимальной активности.

Таблица 1 – Статистики после очистки данных

Город	Количество пользователей	Среднее часов	Медиана часов	Максимум часов
Москва	6099	11.08	0.93	857.21
Санкт-Петербург	2441	12.03	1.03	978.76

Среднее и медианное время активности в Санкт-Петербурге немного выше, чем в Москве. Однако различие небольшое, поэтому для проверки его статистической значимости был проведён статистический тест.

Выбранный статистический тест

Для проверки использовался **односторонний t-тест для двух независимых выборок с поправкой Уэлча**.

Выбор теста обоснован тем, что:

- сравниваются две независимые группы пользователей;
- анализируется различие средних значений;
- размеры групп отличаются;
- дисперсии в группах могут быть неодинаковыми.

Уровень статистической значимости был установлен на уровне:

$\alpha = 0,05$

Для проверки использовался односторонний Welch t-test, так как сравниваются средние значения двух независимых групп с разными размерами выборок.

По результатам t-теста были получены значения:

- **t-статистика = 1.00**
- **p-value = 0.16**

Так как p-value = 0.16 больше уровня статистической значимости 0.05, оснований отвергнуть нулевую гипотезу нет.

Вывод: статистически значимых доказательств того, что пользователи из Санкт-Петербурга проводят больше времени за чтением и прослушиванием контента, чем пользователи из Москвы, не выявлено.

4. Основные выводы

1. **Самым популярным автором в ноябре стал Андрей Усачёв.** Его MAU составил 7107 пользователей. Это самый высокий показатель среди авторов.
2. **В топ-3 произведений по MAU вошёл детский контент.** Все три произведения относятся к жанру «Детская проза и поэзия». Это говорит о высокой востребованности детских книг и аудиоформатов.
3. **Retention Rate после 2 декабря снижался до пятого дня.** Минимальное значение удержания составило 47% на пятый день. После этого показатель частично восстановился.
4. **Москва лидирует по числу пользователей и среднему LTV.** В Москве 16 808 пользователей, средний LTV - 764,55 руб. В Санкт-Петербурге 12 559 пользователей, средний LTV - 731,82 руб.
5. **Средняя выручка за час активности снижается.** С сентября по ноябрь показатель снизился с 61,70 руб. до 51,04 руб. Это связано с ростом общего количества часов активности при фиксированной стоимости подписки.
6. **Гипотеза о большей активности пользователей Санкт-Петербурга не подтвердилась.** Несмотря на то что среднее время активности в Санкт-Петербурге немного выше, статистически значимых различий между городами не выявлено.

5. Рекомендации

1. Развивать направление детского контента

Так как в топ популярных произведений вошли детские книги и аудиоформаты, стоит уделить этому направлению больше внимания.

Рекомендуется:

- расширять подборки детской литературы;
- продвигать аудиоспектакли и детские аудиокниги;
- анализировать поведение пользователей, регулярно потребляющих детский контент.

2. Анализировать удержание пользователей после рекламных кампаний

Retention Rate показал снижение до пятого дня после активности. Это может быть важной точкой для повторной коммуникации с пользователем.

Рекомендуется:

- предлагать пользователям персональные подборки;
- отдельно анализировать пользователей, которые не вернулись после первого дня;
- сравнить удержание пользователей, пришедших из разных рекламных каналов.

3. Дополнительно изучить снижение средней выручки за час

Снижение средней выручки за час не обязательно является негативным фактором, так как оно может отражать рост вовлечённости. Однако метрику стоит анализировать в связке с удержанием и LTV.

Рекомендуется:

- отслеживать динамику средней выручки за час в последующие месяцы;
- сравнить показатель по типам контента;
- отдельно изучить аудиокниги и текстовые книги;

4. Проверить различия между городами с помощью дополнительных метрик

Среднее значение может быть чувствительно к выбросам, особенно если у части пользователей очень высокая активность.

Рекомендуется дополнительно сравнить Москву и Санкт-Петербург по следующим метрикам:

- медианное время активности;
- количество сессий на пользователя;
- средняя длительность одной сессии;

Итоговый вывод

Пользователи Москвы формируют более крупный сегмент и имеют более высокий средний LTV по сравнению с пользователями Санкт-Петербурга. При этом статистическая проверка не подтвердила гипотезу о том, что пользователи из Санкт-Петербурга проводят в сервисе больше времени.

Снижение средней выручки за час активности связано с ростом общего времени использования сервиса при фиксированной стоимости подписки. Это может быть положительным сигналом вовлечённости, но требует дальнейшего анализа в связке с удержанием, LTV и сегментами пользователей.