

Проверка гипотезы для сервиса Яндекс Книги

Цели и задачи

Цель проекта — Проверить гипотезу о том, что пользователи из Санкт-Петербурга в среднем проводят больше времени за чтением и прослушиванием контента в приложении Яндекс Книги, чем пользователи из Москвы.

Задачи проекта

- Загрузить и подготовить данные.
- Провести описательный анализ, сравнить размеры групп и их статистики (средние значения, медианы, разброс, распределения метрик) для пользователей Москвы и Санкт-Петербурга, а также для групп А и В A/B-теста.
- Выбрать и применить корректные статистические тесты: t-тест для сравнения средних часов активности между городами и тест для сравнения долей (конверсий) между группами интерфейсного A/B-теста, задать уровень значимости и посчитать p-value.
- Интерпретировать результаты: сделать выводы о принятии или отклонении гипотез, сформулировать возможные причины наблюдаемых эффектов и оценить их практическую значимость для бизнеса.

Описание данных

Данные представлены несколькими датасетами:

- таблица с данными пользователей из Москвы и Санкт-Петербурга с их активностью (суммой часов чтения и прослушивания)
- таблица участников тестов.
- таблица, в которой собраны события 2020 года;

Проверка гипотезы в Python

Данные предобработаны в SQL, и теперь готовы для проверки гипотезы в Python. Загружаем данные пользователей из Москвы и Санкт-Петербурга с суммой часов их активности из файла `yandex_knigi_data.csv`.

Проверим наличие дубликатов в идентификаторах пользователей. Сравним размеры групп, их статистики и распределение.

Гипотеза: пользователи из Санкт-Петербурга проводят в среднем больше времени за чтением и прослушиванием книг в приложении, чем пользователи из Москвы. Попробуйте статистически это доказать, используя одностороннюю проверку гипотезы с двумя выборками:

Нулевая гипотеза $H_0 : \mu_{СПб} \leq \mu_{Москва}$

Среднее время активности пользователей в Санкт-Петербурге не больше, чем в Москве.

Альтернативная гипотеза $H_1 : \mu_{СПб} > \mu_{Москва}$

Среднее время активности пользователей в Санкт-Петербурге больше, и это различие статистически значимо.

Загрузка данных и знакомство с ними

Загружаем данные пользователей из Москвы и Санкт-Петербурга с их активностью (суммой часов чтения и прослушивания).

```
In [1]: import pandas as pd

import numpy as np

from scipy.stats import ttest_ind

from statsmodels.stats.proportion import proportions_ztest

from statsmodels.stats.power import NormalIndPower
```

```
In [2]: df_knigi = pd.read_csv('/datasets/yandex_knigi_data.csv', index_col=0)

print(df_knigi.info())
display(df_knigi.head(5))
```

```
<class 'pandas.core.frame.DataFrame'>
Int64Index: 8784 entries, 0 to 8783
Data columns (total 3 columns):
#   Column  Non-Null Count  Dtype
---  ------  -
0    city      8784 non-null     object
1    puid      8784 non-null     int64
2    hours     8784 non-null     float64
dtypes: float64(1), int64(1), object(1)
memory usage: 274.5+ KB
None
```

	city	puid	hours
0	Москва	9668	26.167776
1	Москва	16598	82.111217
2	Москва	80401	4.656906
3	Москва	140205	1.840556
4	Москва	248755	151.326434

```
In [3]: print(df_knigi['city'].value_counts())
```

```
Москва      6234
Санкт-Петербург  2550
Name: city, dtype: int64
```

```
In [4]: # Дубликаты
dupl = df_knigi.duplicated(subset='puid').sum()
print(dupl)
```

244

```
In [5]: # Выводим дубликаты
show_dupl = df_knigi[df_knigi.duplicated(subset='puid', keep = False)]
```

```
show_dupl = show_dupl.sort_values(by = 'puid')

display(show_dupl.head(10))
```

	city	puid	hours
35	Москва	2637041	10.317371
6247	Санкт-Петербург	2637041	3.883926
134	Москва	9979490	32.415573
6274	Санкт-Петербург	9979490	1.302997
145	Москва	10597984	42.931506
6279	Санкт-Петербург	10597984	9.041320
150	Москва	10815097	9.086655
6283	Санкт-Петербург	10815097	0.323291
187	Москва	13626259	21.104167
6300	Санкт-Петербург	13626259	1.648434

In [6]:

```
# Агрегация часов по пользователю и городу
knigi_agg = (df_knigi
              .groupby(['puid', 'city'], as_index=False)
              .agg({'hours': 'sum'}))

print(knigi_agg.head(10))
```

	puid	city	hours
0	9668	Москва	26.167776
1	16598	Москва	82.111217
2	80401	Москва	4.656906
3	104923	Санкт-Петербург	60.353889
4	140205	Москва	1.840556
5	146427	Санкт-Петербург	0.469559
6	248755	Москва	151.326434
7	295646	Санкт-Петербург	1.258954
8	352567	Москва	8.206369
9	439493	Москва	0.857758

In [7]:

```
# Для пользователя оставляем город с максимальной активностью
knigi_clean = (
    knigi_agg
    .sort_values(by=['puid', 'hours'], ascending=[True, False])
    .drop_duplicates(subset='puid', keep='first')
)

# Проверяем дубликаты повторно
dupl = knigi_clean.duplicated(subset='puid').sum()

print(dupl)
```

0

In [8]:

```
display(knigi_clean['city'].value_counts())
display(knigi_clean.groupby('city')['hours'].describe())
```

```
Москва          6099
Санкт-Петербург  2441
Name: city, dtype: int64
```

	count	mean	std	min	25%	50%	75%	max
city								
Москва	6099.0	11.075176	37.229705	0.000022	0.058889	0.930357	6.025852	857.209373
Санкт-Петербург	2441.0	12.028376	40.521834	0.000025	0.075278	1.025801	6.880545	978.764775

In [9]:

```
#Разделение выборок
```

```
spb = knigi_clean[knigi_clean['city'] == 'Санкт-Петербург']['hours']
moscow = knigi_clean[knigi_clean['city'] == 'Москва']['hours']

print(spb, moscow)
```

```
3      60.353889
5       0.469559
7       1.258954
11      0.089076
12      0.334019
...
8753     5.879444
8759    45.069222
8766     0.211944
8774     4.311841
8782    20.847222
Name: hours, Length: 2441, dtype: float64 0      26.167776
1      82.111217
2       4.656906
4       1.840556
6     151.326434
...
8778     0.003319
8779     0.081234
8780     0.024736
8781     0.209018
8783     0.609346
Name: hours, Length: 6099, dtype: float64
```

В ходе предобработки данных, были выявлены пользователи, относящиеся к нескольким городам, создающие дубликаты. Для устранения дублирования, каждому пользователю был сопоставлен город с наибольшей суммарной активностью, после чего данные были агрегированы до одного наблюдения на пользователя.

Проверка гипотезы в Python

Продублируем гипотезу: пользователи из Санкт-Петербурга проводят в среднем больше времени за чтением и прослушиванием книг в приложении, чем пользователи из Москвы.

Попробуем статистически это доказать, используя одностороннюю проверку гипотезы с двумя выборками:

- Нулевая гипотеза H_0 : Средняя активность пользователей в часах в двух группах (Москва и Санкт-Петербург) не различается.
- Альтернативная гипотеза H_1 : Средняя активность пользователей в Санкт-Петербурге больше, и это различие статистически значимо.

In [10]:

```
stat, p_value = ttest_ind(
    spb,
    moscow,
```

```
        alternative='greater',
        equal_var=False
    )

    print(stat, p_value)
```

1.004793916530622 0.15752715242320128

In [11]:

```
#Принятие решения

alpha = 0.05

if p_value < alpha:
    print('Отвергаем H0: средняя активность пользователей СПб выше, чем в Москве')
else:
    print('Нет оснований отвергать H0: статистически значимых различий не выявлено')
```

Нет оснований отвергать H₀: статистически значимых различий не выявлено

Так как полученное значение p-value выше уровня статистической значимости 0,05, нулевая гипотеза не была отвергнута. Это означает, что среднее время активности пользователей в Санкт-Петербурге выше, чем в Москве, но не значительно.

In [12]:

```
# Проверка перед тестом
print('СПб', spb.shape[0])
print('Москва', moscow.shape[0])
```

СПб 2441
Москва 6099

Аналитическая записка

В ходе анализа проверялись следующие гипотезы:

- H₀: средняя активность пользователей в Москве и Санкт-Петербурге не различается
- H₁: средняя активность пользователей в Санкт-Петербурге выше, чем в Москве

Для проверки гипотез был использован односторонний t-test для двух независимых выборок (Welch t-test). Выбор данного теста обусловлен несколькими факторами: сравниваются средние значения в двух независимых группах, размеры выборок различаются, дисперсии в группах могут быть неодинаковыми.

Установлен следующий уровень статистической значимости: $\alpha = 0,05$.

В результате проведения t-теста, было получено значение:

- t-статистика = 1.00
- p-value = 0.16

Вывод

Так как полученное значение p-value (0.16) превышает уровень статистической значимости (0.05), нет оснований отвергать нулевую гипотезу. Это означает, что статистически значимых доказательств того, что пользователи из Санкт-Петербурга проводят больше времени за чтением и прослушиванием контента, чем пользователи из Москвы, не выявлено.

Возможные причины полученного результата

1. Фактическая разница в средней активности между пользователями Москвы и Санкт-Петербурга может быть небольшой и недостаточной для выявления статистически значимого эффекта при имеющемся объёме данных.
2. Поведение пользователей в крупных городах может быть схожим из-за одинакового уровня доступности сервиса, образа жизни и структуры аудитории, что приводит к близким значениям средней активности.