

Аналитическая записка

Анализ туристической индустрии России

ОГЛАВЛЕНИЕ

1. Введение, задачи исследования и описание данных	2
2. Подготовка данных.....	3
3. Исследовательский анализ данных.....	5
4. Проверка статистических гипотез.....	8
5. Основные выводы	9
6. Рекомендации	10

1. Введение, задачи исследования и описание данных

В рамках проекта проведён анализ данных агрегатора отелей и туристических фирм по субъектам Российской Федерации за 2018–2023 годы. Исследование направлено на изучение туристической инфраструктуры, спроса на размещение в гостиницах, динамики продаж турпакетов, а также региональных различий в туристической индустрии России.

Особое внимание в работе уделено внутреннему туризму, стоимости реализованных турпакетов в 2023 году и изменению туристических предпочтений за последние годы. Результаты анализа могут быть использованы агрегатором отелей для персонализации туристических маршрутов, определения перспективных регионов и разработки маркетинговых стратегий.

Цель проекта

На основе данных агрегатора отелей изучить состояние туристической индустрии России, выявить региональные особенности и проверить гипотезы о стоимости и динамике продаж турпакетов.

Задачи проекта

- Подготовить данные к анализу: проверить пропуски, типы данных и некорректные значения.
- Изучить распределение количества гостиниц, хостелов и санаторно-курортных организаций по регионам за 2018–2023 годы.
- Определить топ-10 регионов России с наибольшей стоимостью реализованных турпакетов в 2023 году.
- Проанализировать динамику среднего количества турпакетов по категориям за 2018–2023 годы.
- Проверить статистические гипотезы о стоимости турпакетов и росте внутреннего туризма.

Описание данных

В проекте использовались четыре таблицы, содержащих:

- информацию о количестве гостиниц, хостелов, санаторно-курортных организаций и мест в них по субъектам Российской Федерации за 2018–2023 годы.
- данные о численности людей, размещённых в гостиницах в 2023 году.
- данные о количестве реализованных турпакетов за 2018–2023 годы.
- данные о стоимости реализованных турпакетов в 2023 году.

2. Подготовка данных

На первом этапе были загружены все необходимые таблицы и проведено первичное знакомство с их структурой.

Исходные названия столбцов были длинными и неудобными для анализа. Для упрощения дальнейшей работы названия были приведены к короткому техническому формату на английском языке.

Например: Число гостиниц, 2023 переименуем в `hotels_2023`;

Такой подход сделал код более читаемым и снизил риск ошибок при обращении к столбцам.

Результат 1 - Переименование столбцов

```
Index(['region', 'hotels_2018', 'hotels_2019', 'hotels_2020', 'hotels_2021',  
      'hotels_2022', 'hotels_2023', 'beds_hotels_2018', 'beds_hotels_2019',  
      'beds_hotels_2020', 'beds_hotels_2021', 'beds_hotels_2022',  
      'beds_hotels_2023', 'hostels_2018', 'hostels_2019', 'hostels_2020',  
      'hostels_2021', 'hostels_2022', 'hostels_2023', 'beds_hostels_2018',  
      'beds_hostels_2019', 'beds_hostels_2020', 'beds_hostels_2021',  
      'beds_hostels_2022', 'beds_hostels_2023', 'spa_orgs_2018',  
      'spa_orgs_2019', 'spa_orgs_2020', 'spa_orgs_2021', 'spa_orgs_2022',  
      'spa_orgs_2023', 'beds_spa_2018', 'beds_spa_2019', 'beds_spa_2020',  
      'beds_spa_2021', 'beds_spa_2022', 'beds_spa_2023'],  
      dtype='object')
```

Проверка типов данных

После переименования столбцов были изучены типы данных в таблицах. В таблице с данными о гостиницах часть числовых столбцов имела тип `object`. В частности, это касалось столбцов с количеством мест в хостелах и санаторно-курортных организациях.

Также в таблицах с турпакетами и стоимостью турпакетов числовые значения в ряде столбцов были представлены как строки. Это могло помешать корректным расчётам средних значений, построению графиков и проведению статистических тестов.

Для решения проблемы числовые столбцы были приведены к числовому формату.

Проверка пропусков

В таблицах нескольких таблиц пропуски не были выявлены.

Особенно часто пропуски встречались в столбцах, связанных с турпакетами, реализованными иностранным гражданам по территории России.

Возможные причины появления пропусков:

- отсутствие продаж по соответствующей категории;
- неполная отчётность по отдельным регионам;
- технические ошибки при сборе или выгрузке данных;
- отсутствие данных по иностранным туристам в ряде субъектов РФ.

В рамках проекта пропуски были заменены на 0, так как отсутствие значения в таких категориях может означать отсутствие реализованных турпакетов.

Обработка некорректных значений

В данных были обнаружены некорректные значения вида ...1. Такие значения не позволяют интерпретировать столбцы как числовые и могут привести к ошибкам при расчётах.

Для дальнейшего анализа некорректные значения были заменены на 0, после чего столбцы были приведены к числовому типу.

Результат 2 – Пропуски в таблице

foreign_in_russia_2022	40
foreign_in_russia_2020	39
foreign_in_russia_2023	39
foreign_in_russia_2021	37
foreign_in_russia_2018	20
foreign_in_russia_2019	19
international_russia_2021	2
international_russia_2018	1
total_tour_packages_2021	1
international_russia_2023	1
international_russia_2022	1
domestic_russia_2021	1
total_tour_packages_2018	0
international_russia_2020	0
domestic_russia_2020	0
total_tour_packages_2020	0
international_russia_2019	0
total_tour_packages_2022	0
domestic_russia_2022	0
domestic_russia_2019	0
domestic_russia_2018	0
total_tour_packages_2023	0
domestic_russia_2023	0
total_tour_packages_2019	0
region	0

dtype: int64


3. Исследовательский анализ данных

Распределение количества гостиниц

Для анализа распределения количества гостиниц по регионам за 2018–2023 годы была построена диаграмма размаха.

По результатам анализа видно, что медианное количество гостиниц по регионам менялось незначительно. При этом верхняя граница распределения увеличивалась к 2023 году. Это говорит о том, что в отдельных регионах число гостиниц росло быстрее, чем в большинстве субъектов РФ. Также на графике присутствуют выбросы - регионы с аномально высоким числом гостиниц. Это может указывать, например, на наличие крупных туристических центров

Рисунок 3 - Диаграмма размаха по количеству гостиниц




Распределение количества хостелов

Для хостелов также была построена диаграмма размаха за 2018–2023 годы.

Распределение показало, что рынок хостелов также развивается неравномерно. В большинстве регионов количество хостелов остаётся относительно небольшим, однако в отдельных субъектах наблюдаются заметные выбросы. Особенно выраженный рост в некоторых регионах отмечается в 2022–2023 годах. Это может говорить о расширении рынка бюджетного размещения в популярных туристических центрах.


Рисунок 4 - Диаграмма размаха по количеству хостелов



Распределение санаторно-курортных организаций

Анализ количества санаторно-курортных организаций показал, что в каждом году есть регионы с очень высокими значениями. В отдельных субъектах количество таких организаций превышает 100–200, тогда как у большинства регионов показатель ниже 50. Это говорит о сильной региональной специализации: санаторно-курортная инфраструктура сосредоточена в ограниченном числе субъектов РФ. Вероятно, это регионы с развитой лечебно-оздоровительной базой или устойчивым спросом на оздоровительный туризм.


Рисунок 5 - Диаграмма размаха по санаторно-курортным организациям



Топ-10 регионов по стоимости турпакетов в 2023 году

Для определения регионов-лидеров была построена горизонтальная столбчатая диаграмма по стоимости реализованных турпакетов в 2023 году. Лидером по стоимости реализованных турпакетов стала Москва. Разрыв между Москвой и остальными регионами оказался значительным. Это указывает на ключевую роль Москвы в туристическом рынке: в регионе сосредоточен высокий платёжеспособный спрос, большое количество туристических фирм и активная деловая среда.

Рисунок 6 - Топ-10 регионов по стоимости турпакетов




Динамика среднего количества турпакетов за 2018–2023 годы

Для анализа динамики продаж турпакетов был построен линейный график по четырём категориям:

- общее количество турпакетов;
- турпакеты по России для граждан России;
- турпакеты за рубеж для граждан России;
- турпакеты по России для иностранных граждан.

График показал, что внутренний туризм продолжает расти и достигает максимального значения в 2023 году. Это может быть связано с изменением туристических предпочтений, ростом интереса к путешествиям по России и ограничениями на международные поездки в предыдущие годы. Международные туры после снижения восстановились, однако всё ещё остаются немного ниже уровня 2019 года. Это говорит о том, что рынок выездного туризма не полностью вернулся к докризисным значениям.

Рисунок 7 - Линейный график динамики турпакетов



4. Проверка статистических гипотез

Гипотеза о средней стоимости реализованных турпакетов

Проверялась гипотеза о том, что средняя стоимость реализованных турпакетов в 2023 году превышает 800 млн рублей.

Были сформулированы гипотезы:

- **H₀**: средняя стоимость реализованных турпакетов в 2023 году равна 800 млн рублей.
- **H₁**: средняя стоимость реализованных турпакетов в 2023 году больше 800 млн рублей.

Для проверки использовался одновыборочный t-тест с альтернативой greater.

Однако в тетради результат теста отобразился как p-value: nan. Это означает, что расчёт требует дополнительной проверки: возможно, в данных остались некорректные значения, пропуски после преобразования типов или бесконечные значения. Поэтому вывод по этой гипотезе следует интерпретировать осторожно.

В текущем виде статистический тест по первой гипотезе нельзя считать полностью корректно завершённым. Перед финальной интерпретацией необходимо повторно проверить столбец total_tour_cost_million_2023 на наличие NaN, некорректных значений и выбросов.

Гипотеза о росте внутреннего туризма в 2023 году

Проверялась гипотеза о том, что в 2023 году россияне стали чаще оформлять турпакеты по России по сравнению с 2022 годом.

Были сформулированы гипотезы:

- **H₀**: среднее количество внутренних турпакетов в 2022 и 2023 годах не различается.
- **H₁**: среднее количество внутренних турпакетов в 2023 году больше, чем в 2022 году.

Для проверки использовался t-тест для двух выборок с односторонней альтернативой.

По результатам теста:

- p-value = 0.431;
- уровень значимости $\alpha = 0.05$.

Так как p-value значительно больше 0.05, нет оснований отвергать нулевую гипотезу.

Следовательно, данные не подтверждают статистически значимый рост количества внутренних турпакетов в 2023 году по сравнению с 2022 годом. Несмотря на то, что среднее количество туров в 2023 году выше, различие может быть случайным.

5. Основные выводы

По итогам исследования можно сделать следующие выводы:

1. Туристическая инфраструктура России распределена по регионам неравномерно. Большинство регионов имеют сравнительно небольшое количество объектов размещения, но отдельные субъекты РФ значительно выделяются по числу гостиниц, хостелов и санаторно-курортных организаций.
2. Количество гостиниц в большинстве регионов за 2018–2023 годы менялось умеренно. При этом в отдельных регионах наблюдается рост, что отражается в увеличении верхней границы распределения.
3. Рынок хостелов также развивается неравномерно. В 2022–2023 годах в некоторых регионах замечен рост числа хостелов, что может указывать на повышение спроса на бюджетное размещение.
4. Санаторно-курортная инфраструктура имеет ярко выраженную региональную концентрацию. В отдельных субъектах количество санаториев значительно выше, чем в большинстве регионов.
5. Москва является лидером по стоимости реализованных турпакетов в 2023 году. Разрыв между Москвой и другими регионами существенный, что подтверждает её доминирующее положение на туристическом рынке.
6. Внутренний туризм демонстрирует положительную динамику и достигает пика в 2023 году.
7. Международный туризм восстанавливается после снижения, однако остаётся немного ниже уровня 2019 года.
8. Гипотеза о статистически значимом росте внутренних турпакетов в 2023 году по сравнению с 2022 годом не подтвердилась.
9. Первая гипотеза о средней стоимости турпакетов требует дополнительной проверки, так как в расчёте t-теста получено значение p-value: nan.

6. Рекомендации

1. Использовать регионы-лидеры для приоритетного продвижения

Москва и другие регионы из топ-10 по стоимости турпакетов должны рассматриваться как приоритетные направления для маркетинговых кампаний. В этих регионах сосредоточен высокий спрос и значительный денежный оборот туристических услуг.

2. Развивать персонализированные рекомендации

Агрегатору стоит использовать данные о популярных направлениях, типах турпакетов и региональных особенностях для персонализации предложений. Например, пользователям можно рекомендовать маршруты по России на основе интереса к внутреннему туризму, санаторному отдыху или бюджетному размещению.

3. Уделить внимание внутреннему туризму

Несмотря на то, что статистический тест не подтвердил значимый рост внутренних турпакетов в 2023 году по сравнению с 2022 годом, визуальная динамика показывает интерес к поездкам по России. Поэтому внутренний туризм остаётся перспективным направлением для развития продукта.

4. Развивать предложения в регионах с выраженной специализацией

Регионы с высоким количеством санаторно-курортных организаций можно использовать для продвижения оздоровительного туризма. Регионы с ростом числа хостелов - для продвижения бюджетных поездок, молодёжного туризма и коротких путешествий.

5. Улучшить качество данных

Для повышения точности будущих исследований необходимо:

- контролировать корректность числовых значений;
- избегать технических значений вроде ...1;
- фиксировать причины пропусков;
- использовать единые форматы для всех таблиц;
- заранее приводить числовые показатели к корректным типам данных;
- документировать правила заполнения нулей и пропусков.

6. Перепроверить первую статистическую гипотезу

Так как в тесте по стоимости турпакетов был получен p -value: nan, рекомендуется повторно проверить данные и пересчитать тест. До исправления расчёта вывод о том, превышает ли средняя стоимость турпакетов 800 млн рублей, нельзя считать надёжным.