

Анализ факторов, влияющих на длительность госпитализации пациентов медицинского центра

Описание проекта

В проекте используются данные федерального медицинского центра ФГБОУ ВО СПбГПМУ. Датасет содержит сведения о пациентах, датах поступления и выписки, регионе проживания, отделении, профиле лечения, источнике финансирования, количестве койко-дней, типе поступления и диагнозах по МКБ.

Анализ направлен на изучение длительности лечения пациентов в стационаре. Особое внимание уделяется выявлению различий между отделениями, оценке сезонной динамики поступлений и проверке статистических гипотез о средней продолжительности

Цель проекта

На основе данных федерального медицинского центра ФГБОУ ВО СПбГПМУ проанализировать длительность госпитализации пациентов и определить факторы, которые могут влиять на время лечения в стационаре.

В рамках проекта необходимо:

1. Подготовить данные к анализу: обработать пропуски, дубликаты и типы данных.
2. Изучить распределение длительности госпитализации пациентов.
3. Определить отделения с наибольшей средней длительностью госпитализации.
4. Проанализировать динамику поступления пациентов по месяцам.
5. Проверить статистические гипотезы о длительности госпитализации.

Описание данных

В работе использовалась таблица, в которой представлены данные о случаях госпитализации пациентов медицинского центра ФГБОУ ВО СПбГПМУ

Шаг 1. Загрузка данных

Загрузим все необходимые данные и ознакомимся с содержанием таблиц.

Задача 1.1 Импорт библиотек

Загружаем необходимые для работы библиотеки

```
In [1]: import pandas as pd
import matplotlib.pyplot as plt
import seaborn as sns
from scipy import stats as st
import numpy as np
```

Задача 1.2 Чтение данных

Прочитаем и сохраним данные в отдельный датафрейм

In [2]:


```
df_hospital = pd.read_csv('/datasets/hospital.csv')

# Проверяем первые строки
df_hospital.head()

display(df_hospital)
```

	Дата_поступления	Дата_выписки	Уникальный_ID	Номер_ИБ	Шифр	Регион
0	01.01.2019	10.01.2019	858042000	1	5.4.1	NaN
1	01.01.2019	01.01.2019	993109000	3	5.13.1	NaN
2	01.01.2019	01.01.2019	993111000	4	5.12.1	NaN
3	01.01.2019	07.01.2019	993110000	2	5.4.1	NaN
4	01.01.2019	05.01.2019	987185000	5	1.1.1	NaN
...	...	...	...	...	...	...
125256	30.12.2023	31.12.2023	714221000	38557	5.666.0	NaN
125257	30.12.2023	06.01.2024	1258807000	38558	5.12.1	Ульяновская обл.
125258	30.12.2023	26.01.2024	1258810000	38560	5.666.1	NaN
125259	30.12.2023	30.12.2023	1258811000	38561	5.666.0	NaN
125260	30.12.2023	30.12.2023	1258820000	10385641	5.666.0	Ленинградская обл.

125261 rows x 14 columns



Шаг 2. Предобработка данных

Выведем название столбцов

In [3]:

```
df_hospital.columns
```

Out [3]:

```
Index(['Дата_поступления', 'Дата_выписки', 'Уникальный_ID', 'Номер_ИБ', 'Шифр',
      'Регион', 'Плательщик', 'Источник_финансирования', 'Отделение',
      'Профиль', 'Койко_дни', 'Планово_экстренно', 'Код_МКБ_при_поступлении',
      'Код_МКБ_при_выписке'],
      dtype='object')
```

Сейчас названия столбцов слишком длинные и сложные, из-за чего трудно читать код и работать с ним. Приведем названия к стандартному виду

Задача 2.1 Переименование колонок

Переведем все названия на английский и запишем их в формате **snake_case**: нижний регистр, слова разделены нижним подчёркиванием — `_`.

```
In [4]: df_hospital.rename(columns={
    'ДАТА_ПОСТУПЛЕНИЯ': 'income_date',
    'ДАТА_ВЫПИСКИ': 'outcome_date',
    'УНИКАЛЬНЫЙ_ID': 'user_id',
    'НОМЕР_ИБ': 'is_num',
    'ШИФР': 'code',
    'РЕГИОН': 'region',
    'ПЛАТЕЛЬЩИК': 'payer',
    'ИСТОЧНИК ФИНАНСИРОВАНИЯ': 'fin_source',
    'ОТДЕЛЕНИЕ': 'dept',
    'ПРОФИЛЬ': 'profile',
    'КОЙКО_ДНИ': 'bed_days',
    'ПЛАНОВО_ЭКСТРЕННО': 'is_plan',
    'КОД_МКБ_ПРИ_ПОСТУПЛЕНИИ': 'income_mkb',
    'КОД_МКБ_ПРИ_ВЫПИСКЕ': 'outcome_mkb'
}, inplace=True)
```

```
In [5]: df_hospital.columns
```

```
Out[5]: Index(['income_date', 'outcome_date', 'user_id', 'is_num', 'code', 'region',
              'payer', 'fin_source', 'dept', 'profile', 'bed_days', 'is_plan',
              'income_mkb', 'outcome_mkb'],
              dtype='object')
```

Задача 2.2 Анализ типа данных, пропусков, замена не соответствующих значений

Перед анализом убедимся, что у каждой колонки правильный тип данных.

Типы данных

Выведем типы данных всех колонок.

```
In [6]: df_hospital.dtypes
```

```
Out[6]: income_date      object
outcome_date    object
user_id         int64
is_num          int64
code            object
region          object
payer           object
fin_source      object
dept            object
profile         object
bed_days        float64
is_plan         object
income_mkb      object
outcome_mkb     object
dtype: object
```

```
In [7]: df_hospital.head(5)
```

Out [7]:

	income_date	outcome_date	user_id	is_num	code	region	payer	fin_source	
0	01.01.2019	10.01.2019	858042000	1	5.4.1	NaN	ОАО "ГСМК" СПб	ОМС	Микрохиру
1	01.01.2019	01.01.2019	993109000	3	5.13.1	NaN	СПб филиал ООО "СМК РЕСО - Мед"	ОМС	Хиру отде
2	01.01.2019	01.01.2019	993111000	4	5.12.1	NaN	ООО "Капитал Медицинское Страхование"	ОМС	Хиру отде
3	01.01.2019	07.01.2019	993110000	2	5.4.1	NaN	ОАО "ГСМК" СПб	ОМС	Инфе отде
4	01.01.2019	05.01.2019	987185000	5	1.1.1	NaN	Коммерческие	Наличный расчет	ПЦ А физиол

Преобразуем текстовые строки, например 15.02.2023 , в объект datetime , для удобства анализа дат.

In [8]:

```
df_hospital['income_date'] = pd.to_datetime(df_hospital['income_date'], format='%d.%m.%Y')
df_hospital['outcome_date'] = pd.to_datetime(df_hospital['outcome_date'], format='%d.%m.%Y')
```

Приведём значения к целочисленному формату.

In [9]:

```
df_hospital['bed_days'] = df_hospital['bed_days'].astype('int64')
```

In [10]:

```
df_hospital.dtypes
```

Out [10]:

income_date	datetime64[ns]
outcome_date	datetime64[ns]
user_id	int64
is_num	int64
code	object
region	object
payer	object
fin_source	object
dept	object
profile	object
bed_days	int64
is_plan	object
income_mkb	object
outcome_mkb	object
dtype:	object

Теперь столбцы bed_days , income_date и outcome_date приведены к правильным форматам.

Посмотрим на размер датафрейма:

In [11]:

```
df_hospital.shape
```

Out [11]: (125261, 14)

И на количество уникальных пациентов:

In [12]:

```
df_hospital['user_id'].nunique()
```

Out[12]: 77019

Это означает, что один и тот же пациент поступал в больницу несколько раз.

Пропуски

Данные часто содержат пропуски, что может мешать анализу. Проверим количество пропущенных значений в каждом датафрейме.

```
In [13]: df_hospital.isnull().sum()
```

```
Out[13]: income_date      0
outcome_date      0
user_id           0
is_num            0
code              0
region           68870
payer             0
fin_source        0
dept              0
profile           0
bed_days          0
is_plan           0
income_mkb        8
outcome_mkb        4
dtype: int64
```

Выведем результаты по убыванию, чтобы сначала отображались колонки с наибольшим количеством пропусков.

```
In [14]: df_hospital.isnull().sum().sort_values(ascending = False)
```

```
Out[14]: region           68870
income_mkb                8
outcome_mkb                4
income_date                0
outcome_date                0
user_id                    0
is_num                     0
code                       0
payer                      0
fin_source                  0
dept                        0
profile                     0
bed_days                    0
is_plan                     0
dtype: int64
```

Представим данные в виде датафрейма и определим долю пропусков.

```
In [15]: df_hospital_info = pd.DataFrame({
    "DataType": df_hospital.dtypes,
    "MissingValues": df_hospital.isnull().sum(),
    "UniqueValues": df_hospital.nunique()
}).sort_values(by="MissingValues", ascending=False)

df_hospital_info['MissingValuesRatio'] = round(df_hospital_info['MissingValues'] / len(df_hospital_info), 2)
```

```
In [16]: df_hospital_info
```

```
Out[16]:
```

	DataType	MissingValues	UniqueValues	MissingValuesRatio
region	object	68870	142	0.55

	DataType	MissingValues	UniqueValues	MissingValuesRatio
income_mkb	object	8	3117	0.00
outcome_mkb	object	4	2779	0.00
income_date	datetime64[ns]	0	1825	0.00
outcome_date	datetime64[ns]	0	1862	0.00
user_id	int64	0	77019	0.00
is_num	int64	0	42243	0.00
code	object	0	88	0.00
payer	object	0	60	0.00
fin_source	object	0	8	0.00
dept	object	0	35	0.00
profile	object	0	43	0.00
bed_days	int64	0	157	0.00
is_plan	object	0	2	0.00

Как видно, осталось несколько пропусков в коде диагноза при поступлении и при выписке. Они составляют незначительный процент от общего объёма данных, поэтому их можно просто удалить.

```
In [17]: df_hospital = df_hospital.dropna(subset=['income_mkb', 'outcome_mkb'])
```

Столбец `region` содержит информацию о месте жительства пациента. Однако нет дополнительных данных для его восстановления, поэтому его следует удалить.

```
In [18]: df_hospital = df_hospital.drop(columns=["region"])
```

```
In [19]: df_hospital.isnull().sum().sort_values(ascending = False)
```

```
Out[19]: income_date      0
outcome_date    0
user_id         0
is_num          0
code            0
payer           0
fin_source      0
dept            0
profile         0
bed_days        0
is_plan         0
income_mkb      0
outcome_mkb     0
dtype: int64
```

Теперь все пропуски удалены.

Дубликаты

Определим количество полных дубликатов.

```
In [20]: df_full_duplicates = df_hospital[df_hospital.duplicated(keep=False)]

df_full_duplicates.shape
```

Out[20]: (8820, 13)

Повторяющихся строк оказалось в значительном количестве. Выведем их

In [21]: df_full_duplicates

Out[21]:

	income_date	outcome_date	user_id	is_num	code	payer	fin_source	
550	2019-01-14	2019-01-31	994080000	732	5.99.0	Фонд-Иногородние	ОМС	Клиника венерологический отдел
551	2019-01-14	2019-01-31	994080000	732	5.99.0	Фонд-Иногородние	ОМС	Клиника венерологический отдел
578	2019-01-14	2019-01-29	268622000	780	5.5.1	Филиал ОАО "СОГАЗ" в Санкт-Петербурге	ОМС	Клиника венерологический отдел
579	2019-01-14	2019-01-29	268622000	780	5.5.1	Филиал ОАО "СОГАЗ" в Санкт-Петербурге	ОМС	Клиника венерологический отдел
622	2019-01-15	2019-01-25	762227000	844	5.4.1	ОАО "ГСМК" СПб	ОМС	Клиника венерологический отдел
...	...	...	...	...	...	...	...	...
125235	2023-12-29	2024-01-01	130826000	38531	5.666.0	ОМС 86 Регион	ОМС	Клиника венерологический отдел
125236	2023-12-29	2023-12-31	207998000	38533	5.666.0	ОМС 86 Регион	ОМС	Педиатрический отдел
125237	2023-12-29	2023-12-31	207998000	38533	5.666.0	ОМС 86 Регион	ОМС	Педиатрический отдел
125241	2023-12-29	2024-01-01	1168777000	38538	5.666.0	ОМС 86 Регион	ОМС	Клиника венерологический отдел
125242	2023-12-29	2024-01-01	1168777000	38538	5.666.0	ОМС 86 Регион	ОМС	Клиника венерологический отдел

8820 rows x 13 columns



Удалим все повторяющиеся строки, оставляя только первую встреченную запись.

In [22]: df_hospital = df_hospital.drop_duplicates(keep="first")

Исследовательский анализ данных

Изучим распределение длительности госпитализации пациентов.

In [23]: display(df_hospital['bed_days'].min(), df_hospital['bed_days'].max())


1
266

Для начала построим гистограмму.

In [24]:

```
plt.figure(figsize=(7, 4))
df_hospital['bed_days'].hist(bins=30, edgecolor='black')
plt.xlabel("Количество дней лечения в стационаре")
plt.ylabel("Частота")
plt.title("Распределение количества дней лечения в стационаре")

plt.show()
```



Можем сделать выводы:

- большинство пациентов провело меньше 10 дней в стационаре;
- распределение смещено влево (right-skewed) – короткие госпитализации встречаются гораздо чаще;
- есть пациенты с пребыванием более 50, 100 и даже 250 дней, но их очень мало;
- это может быть связано с хроническими заболеваниями, реабилитацией или сложными случаями.


Оценим распределение длительности госпитализации пациентов.

In [25]:

```
# Построение боксплота для столбца 'Количество дней лечения в стационаре'
plt.figure(figsize=(16, 3))
sns.boxplot(x=df_hospital['bed_days'])

plt.xlabel("Количество дней лечения в стационаре")
plt.title("Распределение количества дней лечения в стационаре")

plt.show()
```



In [26]:

```
median_days = df_hospital['bed_days'].median()
mean_days = df_hospital['bed_days'].mean()
q1 = df_hospital['bed_days'].quantile(0.25)
q3 = df_hospital['bed_days'].quantile(0.75)
iqr = q3 - q1
min_days = df_hospital['bed_days'].min()
max_days = df_hospital['bed_days'].max()

print(f"Медиана: {median_days} дней")
print(f"Среднее: {mean_days:.1f} дней (может быть завышено выбросами)")
print(f"25-й перцентиль (Q1): {q1} дней")
print(f"75-й перцентиль (Q3): {q3} дней")
print(f"Межквартильный размах (IQR): {iqr} дней")
print(f"Минимальное значение: {min_days} дней")
print(f"Максимальное значение: {max_days} дней")
```

Медиана: 7.0 дней
Среднее: 8.7 дней (может быть завышено выбросами)
25-й перцентиль (Q1): 3.0 дней
75-й перцентиль (Q3): 12.0 дней
Межквартильный размах (IQR): 9.0 дней
Минимальное значение: 1 дней
Максимальное значение: 266 дней

Получаем следующие данные:

- половина пациентов проводит в стационаре не более недели;
- среднее значение (8.7 дней) выше медианы, что говорит о наличии выбросов – пациентов, которые находятся в стационаре гораздо дольше;
- 25% пациентов (Q1) проводят ≤ 3 дней в стационаре, что говорит о значительном количестве краткосрочных госпитализаций;
- максимальное значение — 266 дней.

Средняя длительность госпитализации по отделениям

В некоторых отделениях пациенты находятся дольше. Это может быть связано со спецификой лечения. Выведем среднюю длительность госпитализации по отделениям.

Сгруппируем данные по названию отделения и рассчитаем среднее значения длительности госпитализации в каждой группе (отделении). Затем отсортируем отделения по убыванию среднего времени пребывания

In [27]:

```
dept_stay = df_hospital.groupby("dept")["bed_days"].mean().sort_values(ascending=False)
```

In [28]:

```
dept_stay
```

Out [28]:

```
dept
Отделение анестезиологии-реанимации
45.179487
ПЦ ОАРИТН №1 (новорожденных)
28.723214
ПЦ Отделение Анестезиологии-реанимации для детей с кардиохирургической патологией
26.438095
ПЦ Отделение патологии новорожденных и детей грудного возраста
22.098196
ПЦ Отделение вспомогательных репродуктивных технологий ДС
21.297802
Дневной стационар Кожно-венерологического отделения
14.027322
```

Дневной стационар Гастроэнтерологического отделения
 13.339286
 Микрохирургическое отделение
 13.293007
 Педиатрическое отделение №1
 12.824642
 Дневной стационар эндокринологического отд.
 12.766667
 Отделение для детей с новой коронавирусной инфекцией COVID-19 с палатами реанимации и интенсивной терапии 12.102902
 Дневной стационар П03
 12.032407
 Гастроэнтерологическое отделение
 12.031962
 Дневной стационар П01
 11.953488
 Хирургическое отделение №2
 11.613193
 Онкогематологическое отделение
 11.495935
 Психоневрологическое отд.
 11.464922
 Эндокринологическое отд.
 11.452705
 Хирургическое отд. №1
 10.876696
 Инфекционно-диагностическое
 9.360406
 Кожно-венерологическое отделение
 9.204006
 Педиатрическое отделение №3
 9.195613
 Хирургическое отделение №3
 9.000904
 ПЦ Отделение патологии беременности
 8.374118
 Педиатрическое отделение №2
 7.990047
 Отоларингологическое отделение
 7.342409
 Инфекционное отделение №1
 7.213423
 ПЦ Акушерское физиологическое отделение
 7.117974
 Офтальмологическое
 6.722988
 Гинекологическое отделение перинатального центра
 6.040672
 Дневной стационар П02
 5.270042
 ПЦ Отделение физиологии новорожденных
 4.915015
 Дневной стационар Онкогематологического отделения
 4.229167
 ПЦ ОАРИТ №2 для беременных, рожениц и родильниц
 1.500000
 ПЭМП ДПО
 1.000334
 Name: bed_days, dtype: float64

Самые длительные госпитализации наблюдаются в следующих отделениях:

- отделение анестезиологии-реанимации (45.2 дней) – это логично, так как пациенты в реанимации находятся в тяжёлом состоянии и часто требуют интенсивной терапии;
- ПЦ ОАРИТ №1 (новорождённых) – 28.7 дней – новорождённые с осложнениями или недоношенные дети требуют длительного медицинского наблюдения;
- кардиохирургическая реанимация для детей (26.4 дней) – длительный период наблюдения после сложных операций.


Краткосрочные госпитализации (< 5 дней):

- ПЦ ОАРИТ №2 для беременных, рожениц и родильниц (1.5 дня) – вероятно, связано с коротким наблюдением после родов;
- ПЭМП ДПО (1 день) – возможно, это диагностическое отделение или экстренная помощь, где пациенты не задерживаются.

Определим Топ-10 отделений с наибольшей средней длительностью лечения. Оформим результат в виде горизонтального столбчатого графика.

In [29]:

```
plt.figure(figsize=(10, 7))
dept_stay.head(10).plot(kind='barh', color='skyblue', edgecolor='black')
plt.xlabel("Средняя длительность количества дней лечения")
plt.ylabel("Отделение")
plt.title("Топ-10 отделений по средней длительности лечения")
plt.show()
```



В разные годы рассчитать количество поступивших пациентов по месяцам

Добавим столбец с месяцем госпитализации. Преобразуем столбец даты поступления пациента в отделение в формат «год-месяц» и сгруппируем данные по месяцу госпитализации.

In [30]:

```
df_hospital["Месяц_госпитализации"] = df_hospital["income_date"].dt.to_period("M")
hospitalizations_over_time = df_hospital.groupby("Месяц_госпитализации")["user_id"].nunique()
```

Для визуализации можно использовать линейный график.

In [31]:

```
plt.figure(figsize=(12, 5))
hospitalizations_over_time.plot(color='blue', marker='o', linestyle='--')

plt.xlabel("Дата госпитализации (месяц)")
plt.ylabel("Количество уникальных пациентов")
plt.title("Динамика количества пациентов по месяцам")
plt.grid(True)
plt.show()
```



Проверка гипотез

Проверка гипотез с одной выборкой

Проверим, отличается ли средняя длительность госпитализации пациентов от стандартного срока в 7 дней.

На основе ранее рассчитанных данных, средняя длительность госпитализации в больницах составляет немного больше 7 дней. Однако есть сомнения в актуальности этой гипотезы, поэтому её стоит проверить.

Средняя длительность госпитализации равна 7 дням (стандартный срок госпитализации).

- H_0 : Средняя длительность госпитализации в больницах = 7.
- H_1 : Средняя длительность госпитализации в больницах не равна 7.

Установим параметры, которые будут использоваться для проверки статистической гипотезы:

`expected_mean_time = 7` — это ожидаемое среднее количество дней лечения в стационаре, с которым вы будете сравнивать реальные данные. `alpha = 0.05` — уровень статистической значимости (обычно 5%, или 0.05), который определяет границу для принятия или отклонения нулевой гипотезы.

In [32]:

```
expected_mean_time = 7

alpha = 0.05

results = st.ttest_1samp(
    df_hospital['bed_days'],
    expected_mean_time,
    alternative='two-sided')

print('p-значение:', results.pvalue)

if results.pvalue < alpha:
    print('Отвергаем нулевую гипотезу')
else:
    print('Не получилось отвергнуть нулевую гипотезу')
```

p-значение: 0.0
Отвергаем нулевую гипотезу

Это означает, что у нас недостаточно обоснований, чтобы не отвергнуть нулевую гипотезу. Поэтому с большей вероятностью можно отклонить нулевую гипотезу и сказать, что фактическое среднее время госпитализации в больнице значительно отличается от 7 дней.

Проверим, превышает ли средняя длительность госпитализации пациентов 10 дней

- H_0 : Средняя длительность госпитализации в больницах = 10.
- H_1 : Средняя длительность госпитализации в больницах > 10

```
In [33]: expected_mean_price = 10
alpha = 0.05

results = st.ttest_1samp(
    df_hospital['bed_days'],
    expected_mean_price,
    alternative='greater')

print('p-значение:', results.pvalue)

if results.pvalue < alpha:
    print('Отвергаем нулевую гипотезу')
else:
    print('Не получилось отвергнуть нулевую гипотезу')
```

p-значение: 1.0
Не получилось отвергнуть нулевую гипотезу

```
In [34]: df_hospital['bed_days'].mean()
```

Out[34]: 8.728508060511768

Видно, что p-значение очень большое, а это значит что отвергнуть нулевую гипотезу не получилось. Следовательно, нельзя утверждать, что средняя длительность госпитализации пациентов статистически значительно превышает 10 дней.

Проверка гипотез с двумя выборками

Изучим, различается ли средняя продолжительность лечения в стационаре между плановыми и экстренными пациентами?

- H_0 : Среднее количество дней лечения в стационаре отличается между плановыми и экстренными пациентами одинаково.
- H_1 : Среднее количество дней лечения в стационаре отличается между плановыми и экстренными пациентами различается.

```
In [35]: plan_group = df_hospital[df_hospital["is_plan"] == "Плановая"]["bed_days"]
urgent_group = df_hospital[df_hospital["is_plan"] == "Экстренная"]["bed_days"]
```

```
In [36]: plan_group.mean()
```

Out[36]: 9.716638313138677

```
In [37]: urgent_group.mean()
```

```
Out[37]: 6.248380631481105
```

Время пребывания очень разное. После экстренной госпитализации человек в среднем задерживается на 3 дня меньше.

```
In [38]: alpha = 0.05

results = st.ttest_ind(
    plan_group,
    urgent_group,
    alternative='two-sided')

print('p-значение:', results.pvalue)

if results.pvalue < alpha:
    print('Отвергаем нулевую гипотезу')
else:
    print('Не получилось отвергнуть нулевую гипотезу')
```

```
p-значение: 0.0
Отвергаем нулевую гипотезу
```

Таким образом, нельзя говорить, что среднее количество дней лечения в стационаре отличается между плановыми и экстренными пациентами одинаково. С точки зрения статистики, разница недостаточно значима.

Выводы

Анализ распределения количества дней лечения в стационаре с помощью гистограммы показал, что большинство пациентов пребывают в больнице относительно недолго. Ту же тенденцию подтвердил box plot. Поэтому для нормального функционирования отделений важно было проверить гипотезу: действительно ли средняя продолжительность госпитализации равна неделе?

Вы сравнили среднее по выборке с определённым числом, используя одновыборочный t-тест Стьюдента. В результате теста нулевая гипотеза была отвергнута.

Для анализа максимальной загрузки коечного фонда была проверена гипотеза: превышает ли средняя продолжительность госпитализации 10 дней. В этом случае нулевая гипотеза не была отвергнута. Это означает, что нет достаточных статистических оснований утверждать, что среднее время пребывания пациентов превышает 10 дней. Это говорит о том, что текущая средняя продолжительность госпитализации не создаёт значительных рисков переполнения стационара.

Кроме того нужно было проверить гипотезу, которая затрагивала экстренную и плановую госпитализации. Визуально (например, по средним значениям) разница есть, но важно понять, насколько она значима с точки зрения статистики. Для сравнения двух независимых групп применили t-тест Стьюдента для двух выборок.

Уровень значимости задали в 5%. То есть приняли 5%-ный риск сделать ошибку, если в действительности разницы между группами нет. Другими словами, в 5 случаях из 100 можно случайно обнаружить различие, которого на самом деле нет.

Как это влияет на решение

- Если p-value (результат статистического теста) меньше 0.05 - отвергаем нулевую гипотезу, считаем различие статистически значимым.
- Если p-value больше 0.05 - недостаточно данных, чтобы отвергнуть нулевую гипотезу.

Вы сравнили среднюю длительность госпитализации между экстренными и плановыми пациентами. Получили $p\text{-value} < 0.05$, что говорит о значимых различиях между группами. Это значит, что вероятность того, что разница между средними значениями случайна, меньше 5%. Таким образом, мы отвергаем нулевую гипотезу и утверждаем, что различие между средними значениями групп существует.

Эти результаты можно использовать для оптимизации коечного фонда и планирования загрузки стационара.