

Аналитическая записка

А/В-тестирование алгоритма рекомендаций в развлекательном приложении

ОГЛАВЛЕНИЕ

1. Описание проекта, исходные данных и методология исследования	2
2. Анализ исторических данных	4
3. Подготовка и расчёт параметров А/В-теста	6
4. Проверка корректности проведения А/В-теста	7
5. Анализ результатов эксперимента	9
6. Основные выводы	10
7. Рекомендации	11

1. Описание проекта, исходные данные и методология исследования

В рамках проекта был проведён полный цикл работы с А/В-тестом для развлекательного приложения с бесконечной лентой контента. Приложение работает по модели, похожей на сервисы коротких видео: пользователь открывает ленту, просматривает контент и может продолжать взаимодействие практически без ограничений.

В продукте используются две модели монетизации.

- Первая - платная ежемесячная подписка, которая позволяет пользователям смотреть ленту без рекламы.
- Вторая - показ рекламы пользователям, которые ещё не оформили подписку.

Команда рекомендательных систем разработала новый алгоритм персональных рекомендаций. Предполагалось, что новый алгоритм будет точнее подбирать контент под интересы пользователя, за счёт чего пользователи будут активнее взаимодействовать с лентой и просматривать больше страниц за одну сессию.

Задача аналитика заключалась в том, чтобы подготовить А/В-тест, проверить корректность его проведения и оценить, действительно ли новый алгоритм рекомендаций улучшает пользовательскую вовлечённость. В качестве ключевой метрики была выбрана доля «успешных» сессий, в которых пользователь просмотрел 4 и более страницы.

Цель проекта - оценить влияние нового алгоритма рекомендаций на вовлечённость пользователей в развлекательном приложении с бесконечной лентой контента.

Основная бизнес-гипотеза

Если новый алгоритм рекомендаций показывает пользователям более релевантный и интересный контент, то пользователи будут дольше оставаться в ленте и чаще просматривать 4 и более страницы за одну сессию.

В рамках проекта были выполнены следующие задачи:

1. Изучить исторические данные по пользовательским сессиям.
2. Определить основную метрику для оценки эффективности нового алгоритма.
3. Рассчитать параметры А/В-теста:
 - базовый уровень метрики;
 - минимальный детектируемый эффект;
 - необходимый размер выборки;
 - ориентирующую длительность эксперимента.
4. Проверить корректность запуска А/В-теста:
 - равномерность распределения пользователей по группам;
 - отсутствие пересечений пользователей между группами;
 - сопоставимость групп по устройствам и регионам.
5. Проанализировать результаты завершённого А/В-теста.
6. Проверить статистическую значимость различий между контрольной и тестовой группами.
7. Сформулировать выводы и рекомендации для продуктовой команды.

Описание продукта и бизнес-контекст

Развлекательное приложение строится вокруг бесконечной ленты контента. Чем дольше пользователь взаимодействует с лентой, тем выше потенциальная ценность пользователя для продукта.

Рост вовлечённости может положительно влиять сразу на несколько направлений:

- увеличение времени, проведённого в приложении;
- рост числа просмотренных страниц;
- повышение вероятности регистрации;
- увеличение рекламного инвентаря;
- потенциальный рост конверсии в платную подписку.

Поэтому качество рекомендательного алгоритма является важным фактором для продукта. Если рекомендации становятся более релевантными, пользователь с большей вероятностью продолжит просмотр и совершит больше взаимодействий с контентом.

Описание данных

Для анализа использовались три таблицы.

Исторические данные. sessions_project_history - таблица с историческими данными по сессиям пользователей за период с 2025-08-11 по 2025-09-23.

Эти данные использовались для анализа базового поведения пользователей и расчёта параметров будущего A/B-теста.

Данные за первый день теста. sessions_project_test_part - таблица с данными за первый день проведения A/B-теста, 2025-10-14.

Эти данные использовались для первичной проверки корректности разбиения пользователей на группы.

Данные за весь период теста. sessions_project_test - таблица с данными за весь период проведения A/B-теста с 2025-10-14 по 2025-11-02.

Методология исследования

Выбор ключевой метрики

Для оценки эффективности нового алгоритма была выбрана метрика вовлечённости - доля «успешных» сессий.

Сессия считалась успешной, если пользователь просмотрел 4 и более страницы:

good_session = 1, если page_counter >= 4

good_session = 0, если page_counter < 4

Такой выбор метрики обоснован логикой продукта: если рекомендации стали лучше, пользователь должен чаще продолжать просмотр ленты и преодолевать порог в 4 страницы.

Формулировка гипотез

Для проверки эффекта были сформулированы две гипотезы.

- **Нулевая гипотеза H₀:** доля успешных сессий в группе с новым алгоритмом не отличается от доли успешных сессий в контрольной группе.
- **Альтернативная гипотеза H₁:** доля успешных сессий в группе с новым алгоритмом выше, чем в контрольной группе.

Статистический подход

Для сравнения долей успешных сессий между группами использовался z-тест для двух пропорций.

Дополнительно для проверки сопоставимости групп по количеству дневных сессий использовался t-тест.


2. Анализ исторических данных

На первом этапе был проведён разведочный анализ исторических данных.

Пользовательская активность

Анализ динамики числа пользователей показал, что в начале исторического периода активность пользователей росла, после чего постепенно снижалась к концу периода. Это может быть связано с естественной динамикой пользовательской базы, сезонностью или изменением источников трафика. Количество зарегистрированных пользователей также изменялось во времени. При этом доля зарегистрированных пользователей среди всей аудитории постепенно увеличивалась, что может говорить о росте качества привлечённой аудитории или повышении интереса пользователей к продукту.

Рисунок 1 - Динамика числа всех пользователей и зарегистрированных пользователей




Анализ просмотров страниц

Количество просмотренных страниц за сессию было рассмотрено как основной показатель пользовательской вовлечённости. Распределение показало, что основная часть сессий приходится на 2–4 просмотренные страницы.

Именно поэтому порог в 4 страницы был выбран как критерий успешной сессии: он позволяет отделить более вовлечённые сессии от коротких и менее активных взаимодействий.

Рисунок - 2 Распределение количества просмотренных страниц по сессиям



Базовый уровень ключевой метрики

На исторических данных была рассчитана доля успешных сессий. Она держалась примерно на уровне 30% с умеренными колебаниями по дням.

Это означает, что метрика достаточно стабильна и может использоваться для планирования А/В-теста. Стабильность базовой метрики важна, так как она снижает риск искажения расчётов размера выборки и длительности эксперимента.

Рисунок 3 - Доля успешных сессий по дням



Промежуточный вывод по историческим данным:

Исторические данные подходят для расчёта параметров А/В-теста. Пользовательская активность и ключевая метрика не демонстрируют критических выбросов, а доля успешных сессий находится примерно на уровне 30%.

Таким образом, исторические данные можно использовать как основу для планирования эксперимента.

3. Подготовка и расчёт параметров A/B-теста

Перед запуском эксперимента были рассчитаны основные параметры теста.

Исходные параметры

Таблица 1 – Параметры теста

Параметр	Значение
Уровень значимости	0.05
Мощность теста	80%
Ошибка второго рода	0.2
Базовый уровень метрики	около 30%
MDE	около 3% относительно базового уровня

Размер выборки

По результатам расчёта необходимый размер выборки составил примерно 82 081 наблюдение на каждую группу.

Это означает, что для корректной статистической проверки необходимо собрать достаточное количество сессий как в контрольной, так и в тестовой группе.

Длительность теста

При среднем уровне трафика около 9907 пользователей в день ориентировочная длительность A/B-теста составила примерно 9 дней.

Такой расчёт позволил заранее оценить, сколько времени потребуется для накопления достаточного объёма данных.

4. Проверка корректности проведения А/В-теста

После запуска теста была проведена проверка корректности эксперимента по данным за первый день.


Распределение пользователей по группам

Таблица 2 - Количество уникальных пользователей в группах

Группа	Количество пользователей
А	1477
В	1466

Разница между группами составила 0,74%. Такое отличие является несущественным и не указывает на проблему в распределении трафика.

Рисунок 4 - Число пользователей по группам А и В



Проверка пересечения пользователей

Была проведена проверка, не попал ли один и тот же пользователь одновременно в обе группы. Результат проверки:

Число пользователей, попавших одновременно в группы А и В: 0


Это означает, что группы независимы, а разбиение пользователей выполнено корректно.

Проверка распределения по устройствам

Дополнительно было проанализировано распределение пользователей по типам устройств. В группах А и В структура устройств оказалась похожей: явных перекосов в сторону какой-либо группы не выявлено.

Это важно, потому что поведение пользователей может отличаться в зависимости от устройства. Например, пользователи мобильных устройств могут активнее взаимодействовать с бесконечной лентой, чем пользователи desktop-версий.

Рисунок 5 - Распределение пользователей по устройствам в группах А и В




Проверка распределения по регионам

Также была проверена структура пользователей по регионам. Распределение в группах А и В оказалось сопоставимым. Существенных перекосов между контрольной и тестовой группами не обнаружено.

Это позволяет сделать вывод, что различия в итоговой метрике не должны быть вызваны региональной структурой аудитории.

Рисунок 6 - Распределение пользователей по регионам в группах А и В



Вывод о корректности запуска теста

Проверка первого дня А/В-теста показала, что эксперимент запущен корректно:

- группы близки по размеру;
- пересечений пользователей между группами нет;
- распределение по устройствам сопоставимо;
- распределение по регионам сопоставимо.

Следовательно, можно переходить к анализу итоговых продуктовых метрик.

5. Анализ результатов эксперимента

После завершения А/В-теста был проведён анализ данных за весь период эксперимента.

Проверка сопоставимости групп по трафику

Перед сравнением ключевой метрики была проверена сопоставимость групп по среднему количеству сессий в день.

Таблица 3 - Результаты проверки

Группа	Среднее число сессий в день
А	2477,55
В	2522,70

Для проверки был применён t-тест. Значение p-value составило 0.938.

Так как p-value значительно выше уровня значимости 0.05, статистически значимых различий между группами по среднему числу дневных сессий не выявлено. Это означает, что группы сопоставимы по объёму трафика.

Сравнение ключевой метрики

Таблица 4 - Значение ключевой метрики - доля успешных сессий

Группа	Доля успешных сессий
А, контрольная группа	30,77%
В, тестовая группа	31,83%

Абсолютная разница составила:

$$31,83\% - 30,77\% = 1,06\%$$

Округлённо прирост составил около 1,1 процентного пункта.

Это означает, что в группе с новым алгоритмом пользователи чаще просматривали 4 и более страницы за одну сессию.

Проверка статистической значимости

Для проверки статистической значимости различий использовался z-тест для двух пропорций. Результат:

- p-value = 0.0003

Так как p-value ниже уровня значимости 0.05, нулевая гипотеза отвергается.

Это означает, что различие между группами статистически значимо. Вероятность получить такой результат случайно при условии отсутствия реального эффекта крайне мала.

6. Основные выводы

По итогам исследования были получены следующие выводы.

1. Исторические данные позволили определить базовый уровень пользовательской вовлечённости. Доля успешных сессий составляла примерно 30%.
2. В качестве ключевой метрики была выбрана доля сессий, в которых пользователь просмотрел 4 и более страницы. Эта метрика подходит для оценки эффективности рекомендательного алгоритма, так как напрямую отражает вовлечённость пользователя в ленту.
3. Перед запуском теста были рассчитаны его параметры: уровень значимости 0.05, мощность 80%, минимальный детектируемый эффект около 3% относительно базового уровня.
4. Необходимый размер выборки составил около 82 081 наблюдения на каждую группу.
5. Ориентировочная длительность теста при текущем уровне трафика была оценена примерно в 9 дней.
6. Проверка первого дня эксперимента показала корректное распределение пользователей по группам. В группе А было 1477 пользователей, в группе В - 1466 пользователей, разница составила 0,74%.
7. Пользователей, попавших одновременно в обе группы, обнаружено не было. Это подтверждает независимость выборок.
8. Распределение пользователей по устройствам и регионам в группах А и В оказалось сопоставимым. Явных перекосов в структуре аудитории не выявлено.
9. По итогам всего теста группы были сопоставимы по среднему количеству сессий в день. Р-value t-теста составило 0.938, что говорит об отсутствии статистически значимых различий по трафику.
10. Доля успешных сессий в контрольной группе А составила 30,77%, в тестовой группе В - 31,83%.
11. Абсолютный прирост ключевой метрики составил около 1,1 процентного пункта.
12. Z-тест для двух пропорций показал р-value = 0.0003. Это подтверждает статистическую значимость результата.
13. Новый алгоритм рекомендаций положительно влияет на вовлечённость пользователей и может быть рекомендован к внедрению.

7. Рекомендации

На основании результатов A/B-теста рекомендуется внедрить новый алгоритм рекомендаций в приложение.

Однако внедрение лучше проводить с дополнительным мониторингом, поскольку рост доли успешных сессий показывает улучшение вовлечённости, но не раскрывает полностью влияние на бизнес-результаты.

1. Рекомендации по внедрению

1. Раскатить новый алгоритм рекомендаций на всех пользователей или начать с постепенного расширения доли трафика.
2. После внедрения отслеживать стабильность ключевой метрики - доли успешных сессий.
3. Контролировать, сохраняется ли прирост вовлечённости на более длинном горизонте.
4. Отдельно проверить эффект для новых и старых пользователей.
5. Провести сегментный анализ по устройствам и регионам.

2. Метрики для дополнительного мониторинга

После внедрения алгоритма рекомендуется отслеживать не только вовлечённость, но и связанные продуктовые и бизнес-метрики:

1. **Retention** - возвращаются ли пользователи в приложение чаще.
2. **Средняя длительность сессии** - проводят ли пользователи больше времени в ленте.
3. **Количество сессий на пользователя** - растёт ли частота использования приложения.
4. **Конверсия в регистрацию** - влияние контента на желание создать аккаунт.
5. **Конверсия в подписку** – влияние вовлечённости на рост платной монетизации.
6. **Негативные действия пользователей** - жалобы, быстрые выходы из приложения.

3. Дополнительные аналитические рекомендации

Рекомендуется провести дополнительный анализ эффекта по сегментам:

- пользователи по платформам;
- пользователи из разных регионов;
- зарегистрированные и незарегистрированные пользователи;
- новые и возвращающиеся пользователи;

Такой анализ поможет понять, одинаково ли хорошо новый алгоритм работает для всех сегментов аудитории или его эффект сосредоточен только в отдельных группах пользователей.

Итоговое заключение

A/B-тестирование нового алгоритма рекомендаций было проведено корректно. Пользователи были равномерно распределены между контрольной и тестовой группами, пересечений пользователей между группами не обнаружено, распределение по устройствам и регионам оказалось сопоставимым.

Итоговый анализ показал, что новый алгоритм рекомендаций увеличил долю успешных сессий с 30,77% до 31,83%. Абсолютный прирост составил около 1,1 процентного пункта.

Статистическая проверка подтвердила значимость результата: p-value z-теста для двух пропорций составило 0.0003, что ниже принятого уровня значимости 0.05.

Следовательно, новый алгоритм рекомендаций действительно повышает пользовательскую вовлечённость в бесконечной ленте. Нововведение рекомендуется внедрить в приложение, параллельно контролируя влияние на удержание пользователей, конверсию в регистрацию и подписку, а также рекламную выручку.