

Описание и цель проекта

Результаты анализа помогут лучше понять предпочтения пользователей и могут быть использованы для улучшения рекомендаций и развития сервиса.


```
|9.809444 |'Биографии и мемуары', 'Бизнес', 'Инвестиции', 'Аудио' |Джер
еми Миллер |
|A00eFBMU|Audiobook|Закон трех отрицаний
|14.834167 |'Художественная литература', 'Детективы', 'Аудио', 'Полицейская драма'|Алек
сандра Маринина |
+-----+-----+-----+-----+-----+-----+-----+-----+
+-----+-----+-----+-----+-----+-----+-----+-----+
+-----+-----+-----+-----+-----+-----+-----+-----+
only showing top 10 rows
```

Чтение файла выполнено без заголовка. Предполагаемая структура таблиц из заадния содержит 11 столбцов для таблицы audition и 6 для таблицы content, описание столбцов и их порядок приведены в описании.

При чтении файлов выявлено расхождение на два столбца в таблице audition и в порядке столбцов в таблице content.

```
In [2]: audition_df = audition_df.toDF(
    "n",
    "audition_id",
    "puid",
    "usage_platform_ru",
    "msk_business_dt_str",
    "app_version",
    "adult_content_flg",
    "hours",
    "hours_sessions_long",
    "kids_content_flg",
    "main_content_id",
    "usage_geo_id_name",
    "usage_country_name"
)

audition_df = audition_df.drop("n")

audition_df.printSchema()
audition_df.show(10, truncate=False)
```

```
root
|-- audition_id: integer (nullable = true)
|-- puid: string (nullable = true)
|-- usage_platform_ru: string (nullable = true)
|-- msk_business_dt_str: string (nullable = true)
|-- app_version: string (nullable = true)
|-- adult_content_flg: boolean (nullable = true)
|-- hours: double (nullable = true)
|-- hours_sessions_long: double (nullable = true)
|-- kids_content_flg: boolean (nullable = true)
|-- main_content_id: string (nullable = true)
|-- usage_geo_id_name: string (nullable = true)
|-- usage_country_name: string (nullable = true)
```

```
[Stage 6:> (0 + 1) / 1]
+-----+-----+-----+-----+-----+-----+-----+-----+
+-----+-----+-----+-----+-----+-----+-----+-----+
+-----+-----+-----+-----+-----+-----+-----+-----+
|audition_id|puid|usage_platform_ru|msk_business_dt_str|
|app_version|adult_content_flg|hours|hours_sessions_long|kids_content_flg|
main_content_id|usage_geo_id_name|usage_country_name|
+-----+-----+-----+-----+-----+-----+-----+-----+
+-----+-----+-----+-----+-----+-----+-----+-----+
|0|68296628-f9d6-11ef-be00-c2c9fa6fd3d5|Станция|2024-11-26|
|null|false|0.03777777777777777|0.03777777777777777|true|
oCURrBKV|Алматы|Казахстан|
```



```

|
|A0FkgwIl      |Comicbook      |Майор Гром. Дополнительные материалы к тому №6
|0.20363636    |                  |'Комиксы'
|Артём Габрелянов |
|A00KAjnf      |Audiobook      |Радикальное Прощение: родители и дети. Почему так ва
жно простить своих близких и как сделать это правильно|5.0780554    |'Пси
хология', 'Саморазвитие', 'Аудио'                  |Колин Типпинг
|
|A0e7vsJT      |Book           |Обоняние. Увлекательное погружение в науку о запахах
|8.896182      |                  |'Наука', 'Психология'
|Паоло Пелоси   |
|A0fAe01q      |Audiobook      |Амулет ведьмы
|10.473333     |                  |'Художественная литература', 'Фэнтези', 'Темное фэнтези',
'Аудио'      |Анна Безбрежная |
|A0mSkD2g      |Audiobook      |Правила инвестирования Уоррена Баффетта
|9.809444      |                  |'Биографии и мемуары', 'Бизнес', 'Инвестиции', 'Аудио'
|Джереми Миллер |
|A0oeFBMU      |Audiobook      |Закон трех отрицаний
|14.834167     |                  |'Художественная литература', 'Детективы', 'Аудио', 'Полице
йская драма'|Александра Маринина |
+-----+-----+-----+-----+-----+-----+-----+-----+-----+
-----+-----+-----+-----+-----+-----+-----+-----+-----+-----+
-----+
only showing top 10 rows

```

Заголовки присвоены вручную, в таблице audition удален первый столбец.

In [4]:

```

# просмотр схем
audition_df.printSchema()
content_df.printSchema()

# количество строк
audition_count = audition_df.count()
content_count = content_df.count()

print("audition rows:", audition_count)
print("content rows:", content_count)

```

```

root
|-- audition_id: integer (nullable = true)
|-- uuid: string (nullable = true)
|-- usage_platform_ru: string (nullable = true)
|-- msk_business_dt_str: string (nullable = true)
|-- app_version: string (nullable = true)
|-- adult_content_flg: boolean (nullable = true)
|-- hours: double (nullable = true)
|-- hours_sessions_long: double (nullable = true)
|-- kids_content_flg: boolean (nullable = true)
|-- main_content_id: string (nullable = true)
|-- usage_geo_id_name: string (nullable = true)
|-- usage_country_name: string (nullable = true)

root
|-- main_content_id: string (nullable = true)
|-- main_content_type: string (nullable = true)
|-- main_content_name: string (nullable = true)
|-- main_content_duration_hours: double (nullable = true)
|-- published_topic_title_list: string (nullable = true)
|-- main_author_id: string (nullable = true)

```

```

audition rows: 1002896
content rows: 31668

```

Разница в объемах ожидаема. Таблица audition значительно больше таблицы content, потому что первая таблица фиксирует множество событий, тогда как вторая является справочником с описанием объектов контента.

Трансформация и преобразование таблиц

In [5]:

```
from pyspark.sql import functions as F

audition_df = (
    audition_df
    .withColumn(
        "minutes_sessions_long",
        (F.col("hours_sessions_long") * 60).cast("int")
    )
    .withColumn(
        "event_date",
        F.to_date(F.col("msk_business_dt_str"), "yyyy-MM-dd")
    )
    .withColumn(
        "is_weekend",
        F.dayofweek(F.col("event_date")).isin([1, 7])
    )
)

audition_df_new = audition_df.select(
    "puid",
    "hours_sessions_long",
    "minutes_sessions_long",
    "is_weekend"
).show(10, truncate=False)
```

```
[Stage 12:> (0 + 1) / 1]
+-----+-----+-----+-----+
|puid|hours_sessions_long|minutes_sessions_long|is_weekend|
+-----+-----+-----+-----+
|68296628-f9d6-11ef-be00-c2c9fa6fd3d5|0.0377777777777777|2|false|
|682966dc-f9d6-11ef-be00-c2c9fa6fd3d5|0.0|0|false|
|682966dc-f9d6-11ef-be00-c2c9fa6fd3d5|0.0|0|false|
|68296704-f9d6-11ef-be00-c2c9fa6fd3d5|0.0|0|false|
|68296722-f9d6-11ef-be00-c2c9fa6fd3d5|0.0|0|false|
|68296740-f9d6-11ef-be00-c2c9fa6fd3d5|0.4890794444444444|29|false|
|68296740-f9d6-11ef-be00-c2c9fa6fd3d5|0.1847275|11|false|
|6829675e-f9d6-11ef-be00-c2c9fa6fd3d5|1.4530555555555555|87|false|
|6829677c-f9d6-11ef-be00-c2c9fa6fd3d5|0.5399818181818182|32|false|
|6829679a-f9d6-11ef-be00-c2c9fa6fd3d5|0.0|0|false|
+-----+-----+-----+-----+
only showing top 10 rows
```

К датафрейму добавлено несколько столбцов для анализа потребления контента в зависимости от дня недели и возрастных ограничений

In [6]:

```
# Сумма minutes_sessions_long для выходных и будней

weekend_totals = (
    audition_df
    .groupBy("is_weekend")
    .agg(F.sum("minutes_sessions_long").alias("total_minutes"))
    .orderBy("is_weekend")
)

weekend_totals.show(truncate=False)
```

[Stage 14:=====> (186 + 1) / 200]

is_weekend	total_minutes
false	17995153
true	6598993

По результатам видно, что в будни суммарное время потребления контента выше - 17 995 153 минут, против 6 598 993 минут в выходные. Из этого можно сделать вывод, что основная активность приходится на рабочие дни, в выходные потребление контента значительно ниже.

Вероятно, в рабочие дни сервис чаще используют, как регулярную часть повседневной активности, в выходные реже или более короткими сессиями.

In [7]:

```
# Аналогично по adult_content_flg и is_weekend, без пропусков

adult_weekend_totals = (
    audition_df
    .groupBy("adult_content_flg", "is_weekend")
    .agg(F.sum("minutes_sessions_long").alias("total_minutes"))
    .dropna()
    .orderBy("adult_content_flg", "is_weekend")
)

adult_weekend_totals.show(truncate=False)
```

[Stage 16:=====> (187 + 2) / 200]

adult_content_flg	is_weekend	total_minutes
false	false	3369978
false	true	1401035
true	false	14625175
true	true	5197958

Потребление контента значительно смещено в сторону взрослого контента, на него приходится большая доля, при этом сохраняется пропорциональное деление длительности активности в будни, этот паттерн не зависит от возрастных ограничений. Сегмент потребления детского контента заметно меньше, это может стать зоной роста, если есть цель диверсифицировать аудиторию.

В общих чертах можно сказать, что сервис используют преимущественно в повседневных сценариях. Но также результаты указывают на высокую зависимость вовлеченности от "взрослого" сегмента.

Соединение таблиц

In [8]:

Соединяем таблицы

```
from pyspark.sql import functions as F
```

```
merged_df = audition_df.join(content_df, on="main_content_id", how="inner")
```

```
print("rows after join:", merged_df.count())
```

```
merged_df.show(5, truncate=False)
```

```
rows after join: 996565
```

[Stage 21:>

$$(0 + 1) / 1]$$
[illegible]

A blank sheet of primary-ruled paper with four horizontal rows. Each row consists of a solid top line, a dashed midline, and a solid bottom line. Small black plus signs are placed at various points along these lines.

loCURrBKV	0	68296628-f9d6-11ef-be00-c2c9fa6fd3d5	Станция	2024-11-26
4-11-26	null	false	0.037777777777777777	0.037777777777777777
true	Алматы	Казахстан	2	2024-11-26
alse	Audiobook	Фиксики. Интернет. Доступ разрешен	0.8302778	
'Детская проза и поэзия', 'Аудио'				

Александр Шаронов	
q0L0JjL5	1 682966dc-f9d6-11ef-be00-c2c9fa6fd3d5 Станция 2024-11-26
null	false 8.333333333333E-4 0.0 true
rue Москва	Россия 0 2024-11-26>false
Audiobook	Собачка Соня на даче 1.2761111

'Детская проза и поэзия', 'Аудио'					
Андрей Усачев					
ndM5nzgT	2	682966dc-f9d6-11ef-be00-c2c9fa6fd3d5	Станция	202	
4-11-26	null	false	0.0044444444444444	0.0	t
rue	Иркутск	Россия	0	2024-11-26	f
alse	Audiobook	Мужской Тип: А что вы мне подарите?	10_1275		

title	Аудиobook	мышонок тим. А что вы мне подарите?	0.1275	
	['Сказки и фольклор', 'Детская проза и поэзия', 'Аудио']			
	Анна Казалис			
HW5y0HqU	4	68296704-f9d6-11ef-be00-c2c9fa6fd3d5	Станция	2024-11-26
4-11-26	null	true	0.0016666666666666	0.0
alse	Санкт-Петербург	Россия	0	2024-11-26

else	Аудиobook	Белые ночи	2.0075	
'Художественная литература', 'Русская литература', 'Книга + кино', 'Классика', 'Ауди				
o' Фёдор Достоевский				
DDP9Jenb	6	68296722-f9d6-11ef-be00-c2c9fa6fd3d5	Станция	202
4-11-26	null	false	0.0069444444444444	0.0

```

rue      |Махачкала      |Россия      |0      |2024-11-26|f
alse     |Audiobook      |Дикие лебеди|0.9175|
|'Детская проза и поэзия', 'Аудио'|
|Ганс Христиан Андерсен|
+-----+-----+-----+-----+-----+

```

[illegible]

only showing top 5 rows

In [9]:

```
#Удаляем лишних столбцов
```

```
merged_df = merged_df.drop("main_author_id", "app_version", "usage_geo_id")
```

```
merged_df.show(5, truncate=False)
```

```
[Stage 23:> (0 + 1) / 1]
```

main_content_id	audition_id	puid	usage_platform_ru	msk
_business_dt_str	adult_content_flg	hours	hours_sessions_long	kids_content_flg
usage_geo_id_name	usage_country_name	minutes_sessions_long	event_date	is_weekend
in_content_type	main_content_name	main_content_duration_hours	publish	ed_topic_title_list
oCURrBKV	0	68296628-f9d6-11ef-be00-c2c9fa6fd3d5	Станция	202
4-11-26	false	0.037777777777777777	0.037777777777777777	true
Алматы	Казахстан	2	2024-11-26	false
book	Фиксики. Интернет. Доступ разрешен	0.8302778		'Детская п
роза и поэзия', 'Аудио'				
qOL0JJL5	1	682966dc-f9d6-11ef-be00-c2c9fa6fd3d5	Станция	202
4-11-26	false	8.333333333333333E-4	0.0	true
Москва	Россия	0	2024-11-26	false
book	Собачка Соня на даче	1.2761111		'Детская п
роза и поэзия', 'Аудио'				
ndM5nzgT	2	682966dc-f9d6-11ef-be00-c2c9fa6fd3d5	Станция	202
4-11-26	false	0.004444444444444444	0.0	true
Иркутск	Россия	0	2024-11-26	false
book	Мышонок Тим. А что вы мне подарите?	0.1275		'Сказки и
фольклор', 'Детская проза и поэзия', 'Аудио'				
HW5y0HqU	4	68296704-f9d6-11ef-be00-c2c9fa6fd3d5	Станция	202
4-11-26	true	0.0016666666666666666	0.0	false
Санкт-Петербург	Россия	0	2024-11-26	false
book	Белые ночи	2.0075		'Художеств
енная литература', 'Русская литература', 'Книга + кино', 'Классика', 'Аудио'				
DDP9Jenb	6	68296722-f9d6-11ef-be00-c2c9fa6fd3d5	Станция	202
4-11-26	false	0.006944444444444444	0.0	true
Махачкала	Россия	0	2024-11-26	false
book	Дикие лебеди	0.9175		'Детская п
роза и поэзия', 'Аудио'				

only showing top 5 rows

Объединены две таблицы и удалены лишние столбцы: main.author_id, app_version, usage_geo_id

In [10]:

```
# Считаем уникальных пользователей
```

```
merged_users = merged_df.select("puid").distinct().count()
```

```
audition_users = audition_df.select("puid").distinct().count()
```

```
print("unique users in merged_users:", merged_users)
print("unique users in audition_users:", audition_users)
```

```
[Stage 29:=====> (173 + 1) / 200]
unique users in merged_users: 31010
unique users in audition_users: 31063
```

Количество уникальных ползователей в объединенной таблице меньше, чем в исходной, потому что при объединении сохранились только строки с найденным соответствием в content_df. Таким образом 53 пользователя не включены в финальную таблицу из-за отсутствия совпадений.